

Notas Curso Análisis de datos

Enric Pallas¹, Julio Sheinbaum^{1,*}

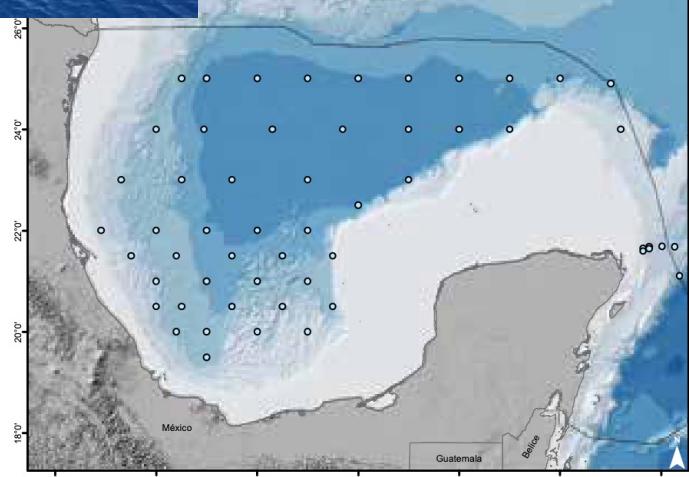
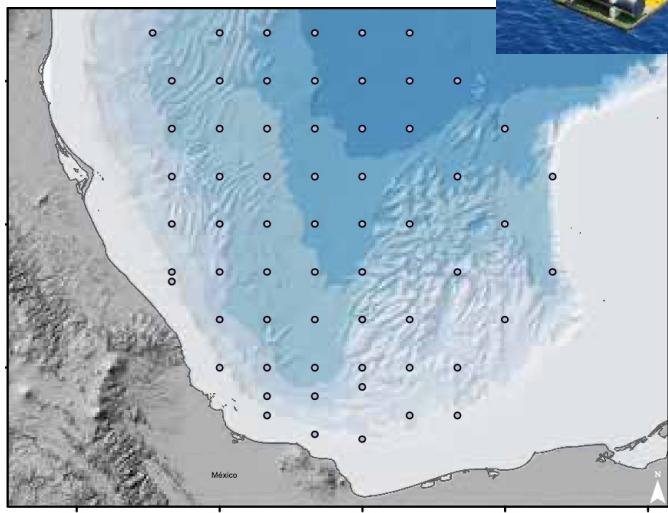
¹Physical Oceanography,, Centro de Investigación Científica y de Educación Superior de Ensenada,
CICESE, Ensenada, Baja California, MEXICO

*Translated template to Quarto.

5 Abstract

6 En el océano conviven una gran cantidad de corrientes de diferentes escalas espaciales
7 y temporales. Las escalas espaciales típicas de la circulación oceánica son la
8 larga escala, la mesoscala, submesoscala, y microescala. La larga escala es del
9 $O(1000\ km)$ y esta determinada por la circulación general en el océano como la ter-
10 mohalina y los grandes giros anticiclónicos de las grandes cuencas oceánicas; las
11 escalas temporales de la larga escala varía entre meses y años. La mesoscala esta
12 definida por corrientes del $O(100\ km)$ como remolinos, corrientes costeras, filamentos,
13 frentes, etc. Son corrientes mas regionales pero pueden tener gran influencia sobre la
14 circulación general o de larga escala. Sus escalas temporales son de semanas a meses.
15 La submesoscala corresponde a corrientes del $O(10\ km)$ de carácter local remolinos,
16 filamentos, frentes, corrientes en playas, puertos, y estuarios. La submesoscala varía
17 temporalmente con rapidez en tiempos que varían de horas a días. Finalmente pode-
18 mos hablar de la microescala que son remolinos del orden de centímetros a metros y
19 generalmente es la escala característica de la turbulencia que transfiere energía desde
20 la submesoscala hacia la disipación molecular. Aquí podemos hablar de fenómenos
21 del orden de segundos y minutos.

Estaciones Hidrográficas



ANCLAJES

1.1.- El proyecto CANEK (CNK)

Correntometría profunda: redes de anclajes

Monitoreo de corrientes y otras variables oceanográficas.

Microcat: Presión, conductividad, temperatura y oxígeno



Termistor: Temperatura



Sensor de presión



Correntómetro puntual

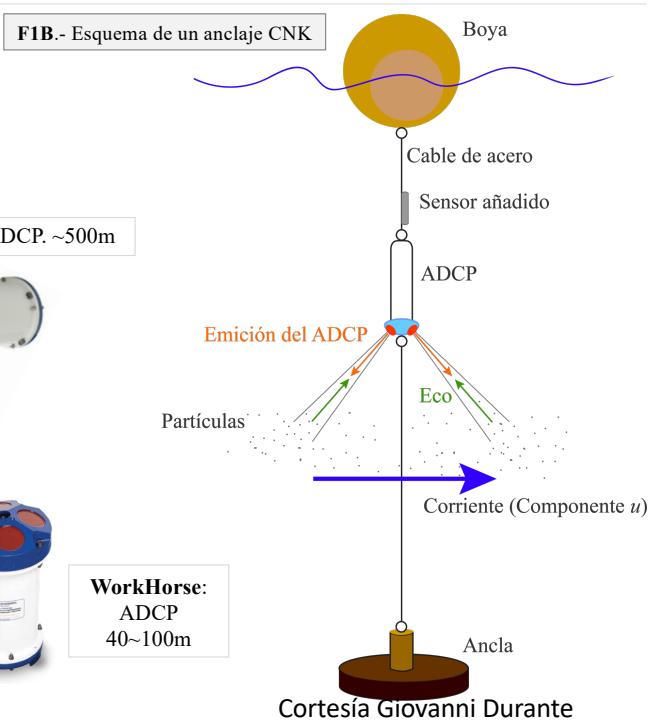


F1A.- Sensores comúnmente instalados en los anclajes CNK

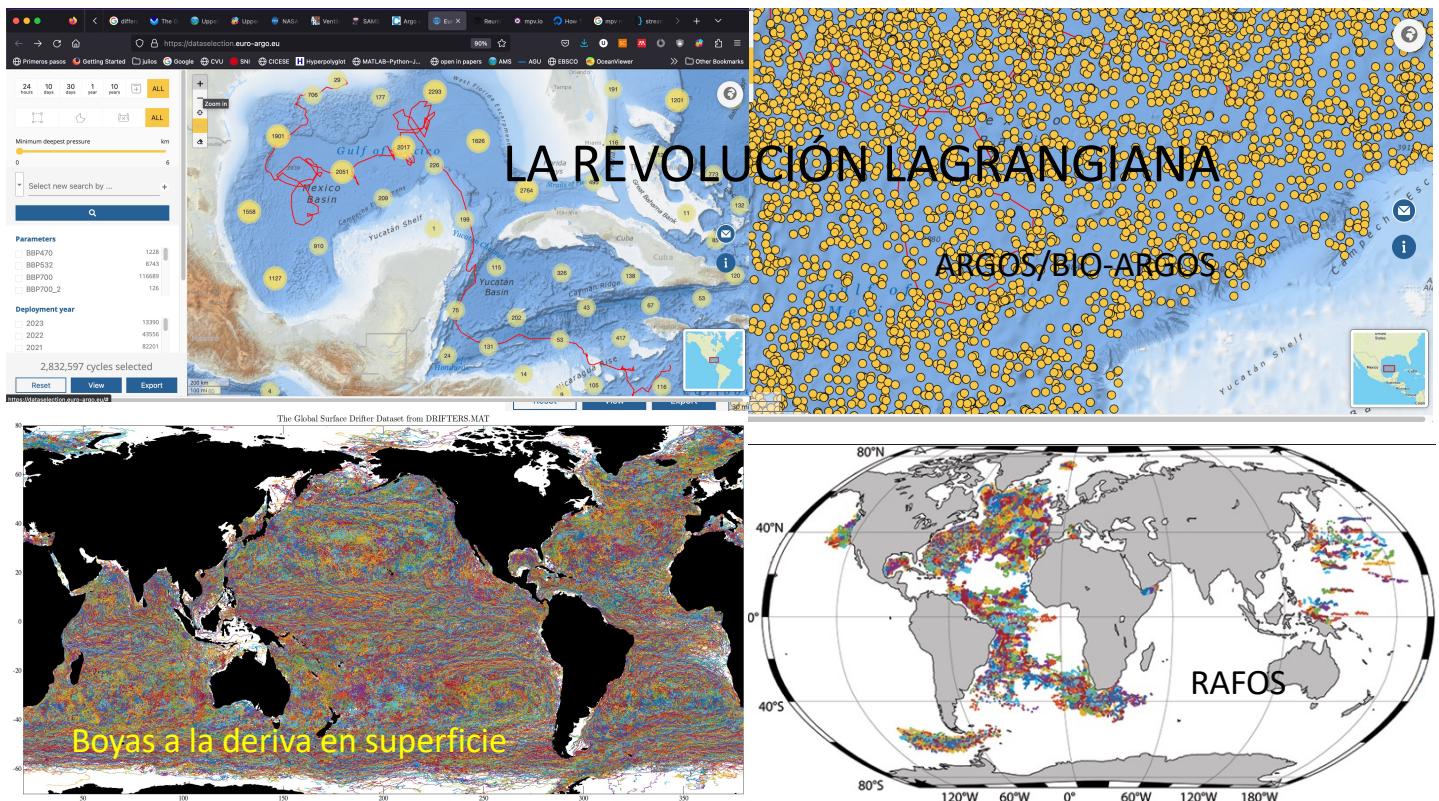
2

1.- Introducción

F1B.- Esquema de un anclaje CNK



Cortesía Giovanni Durante





26 **1 Estadística y conceptos de probabilidad**

27 **1.1 Porqué estudiar la estadística en oceanografía**

28 A pesar de nuestra formación determinista a la hora de resolver problemas matemáticos y aunque consideremos que las ecuaciones de Navier-Stokes que describen el
29 movimiento del océano son deterministas, la estadística es ampliamente utilizada en
30 oceanografía debido a diferentes razones:

- 32 1. Para una descripción completa del océano es necesario especificar una gran
33 cantidad de variables, muchas de las cuales son desconocidas. Un ejemplo
34 de ello son las parametrizaciones que se hacen en oceanografía para describir
35 variables que no pueden medirse directamente. Una parametrización no es
36 nadammas que un modelo estadístico que explica la evolución de una variable
37 dependiente de otras variables independientes. Por ejemplo, parametrización
38 del esfuerzo del viento en función del corte vertical o parametrización del coefi-
39 ciente de arrastre en función de la velocidad del viento a 10m de la superficie
40 del océano.
- 41 2. El océano es altamente no lineal. La evolución de una cierta variable no se
42 puede estudiar de forma aislada.

43 Ejemplo:

44 Supongamos el término de aceleración horizontal en las ecuaciones de Navier Stokes
45 para fluidos incompresibles,

$$\frac{\partial \mathbf{u}_h}{\partial t} + \mathbf{u}_h \cdot \nabla \mathbf{u}_h$$

46 Como ya sabemos por el curso de Mecánica de Fluidos, la aceleración de un fluido
47 es una derivada material y consta de un término local (aceleración local) y de un
48 término advectivo o aceleración advectiva. En general, esta ecuación no se aplica a
49 partículas de agua individuales.

50 En oceanografía hablamos de continuo. No estamos interesados en las caracterís-
51 ticas cinemáticas de las partículas individuales sino en la manifestación promedia
52 del movimiento molecular, es decir, del fluido como un conjunto o contínuo. Es de-
53 cir, asumimos que el fluido es uniforme en el espacio que ocupa sin considerar la
54 estructura molecular.

55 Por ello debemos de promediar de alguna forma para explicar el comportamiento
56 conjunto del fluido y no de una partícula de agua específica? Y como se realiza tal
57 promedio? En general, el promediado se realiza de tal forma que nos permite separar
58 la larga escala que trataremos como determinística, de la pequeña escala que consid-
59 eramos un proceso aleatorio (turbulento). Supongamos entonces la separación de la
60 velocidad horizontal en una velocidad promedio y una velocidad fluctuante alrededor
61 de la media

$$\mathbf{u}_h = \langle \mathbf{u}_h \rangle + \mathbf{u}'_h$$

62 donde $\langle \cdot \rangle$ denotan promedio. Si aplicamos esta descomposición a la compo-
63 nente x de la aceleración obtenemos:

$$\frac{\partial \langle \mathbf{u} \rangle}{\partial t} + \langle \mathbf{u} \rangle \cdot \nabla \langle \mathbf{u} \rangle + \langle \mathbf{u}' \cdot \nabla \mathbf{u}' \rangle$$

$$\frac{\partial \langle \mathbf{u} \rangle}{\partial t} + \nabla \cdot (\langle \mathbf{u} \rangle \langle \mathbf{u} \rangle) + \nabla \cdot \langle \mathbf{u}' \mathbf{u}' \rangle$$

64 Donde usamos la ecuación de continuidad

$$\nabla \cdot (\langle \mathbf{u} \rangle + \mathbf{u}') = 0$$

65 para pasar de la primera a la segunda expresión.

66 Inevitablemente, las pequeñas escalas o fluctuaciones respecto a la larga escala aparecen
67 en la expresión de la aceleración de larga escala. De forma que la separación que
68 deseamos no es tan simple ya que debemos de conocer la estadística de la pequeña
69 escala para poder describir la circulación media.

70 El término $\langle u'_h u' \rangle$ se denomina esfuerzo de Reynolds y nos informa de la cor-
71 relación entre las componentes fluctuantes (alta frecuencia) de la velocidad. Por
72 ejemplo, $\langle u' v' \rangle = 0$ significa que no existe correlación y hablamos de isotropía. Si
73 $\langle u' v' \rangle < 0$, significa que las fluctuaciones están inversamente correlacionadas, i.e.,
74 anisotropía.

75 Este es un gran problema no resuelto en la oceanografía física. El esfuerzo de
76 Reynolds aparece porque la advección es no-lineal de tal forma que no podemos es-
77 tudiar la larga escala sin conocer información de la pequeña escala que es un proceso
78 aleatorio. Por similitud con el flujo laminar, los términos de esfuerzo de Reynolds se
79 parametrizan estadísticamente como proporcionales a los gradientes de velocidad. El
80 factor de proporcionalidad es el coeficiente de viscosidad, en este caso, turbulento.
81 Es aquí donde utilizar herramientas estadísticas tiene sentido.

82 3. No podemos controlar las variables oceanográficas; están en constante cambio
83 a medida que el sistema observado evoluciona.

84 Ejemplo:

85 En el océano coexisten mareas, ondas internas, remolinos, turbulencia de pequeña
86 escala,...las cuales enmascaran el fenómeno oceanográfico que estamos interesados
87 en estudiar. Estos procesos incontrolables por el oceanógrafo en ocasiones es útil
88 considerarlos aleatorios y utilizar herramientas estadísticas para caracterizarlos.

89 Imaginemos que queremos conocer cual es la temperatura superficial promedio en
90 la bahía de Todos Santos. Una forma de proceder sería promediar todos los datos
91 de temperatura superficial que disponemos de los últimos 100 años y promediarlos?
92 Pero, ¿es realmente lo que deseamos? ¿Deberíamos de considerar la estaciones del
93 año y obtener un promedio para cada estación? ¿Qué sucede en años Niño, el cual
94 sabemos que afecta la temperatura del océano? En definitiva, debemos de definir
95 sobre qué conjunto de datos vamos a promediar, y dichos promedio va a reflejar
96 efectivamente esa elección.

97 Este ejemplo precisa de la distinción entre lo que consideramos nuestra *señal* (tem-
98 peratura media) de los procesos que son *ruido* (Estaciones del año, los años Niño,
99 ondas internas, etc.). De esta forma, al definir el promedio estamos haciendo ex-
100 plícita la separación entre *señal* y *ruido*. Finalmente, una vez definido sobre qué
101 promediar, existen en literatura una gran cantidad de herramientas estadísticas que
102 podemos utilizar. Definir *señal* y *ruido*, y determinar sobre qué conjunto de datos
103 vamos a calcular el promedio, es una tarea difícil. Conocer como debemos muestrear
104 el océano también debe hacerse cuidadosamente.

105 En oceanografía física se muestrea el océano de forma discontinua, es decir, se ob-
106 tienen medidas puntuales en el espacio y en el tiempo. Como dijimos anteriormente,
107 el océano contiene procesos de diferentes escalas espaciales y temporales, nolineales,
108 y aleatorios. Es por ello que es sumamente importante saber escoger el intervalo
109 de muestreo Δt dependiendo del fenómeno que se quiere muestrear. Debemos de
110 tener en mente que la frecuencia mas alta que podemos resolver es la frecuencia de
111 Nyquist:

$$f_N = 1/(2\Delta t).$$

112 Por ejemplo, si medimos a intervalos de $\Delta t = 5$ h podremos como máximo resolver
 113 procesos que ocurren con frecuencia $f_N \leq 1/10$ cph. La frecuencia mas baja que
 114 podemos resolver va a depender de la longitud del registro. A esa frecuencia le lla-
 115 mamos frecuencia fundamental

$$f_0 = 1/(\Delta t N),$$

116 donde $T = \Delta t N$ es la duración del muestreo y N es el número de muestras o datos.
 117 En general, debemos de medir suficiente tiempo para registrar varios ciclos del
 118 fenómeno de estudio para tener significancia estadística. Por lo tanto, nuestra res-
 119 olución frecuencial va a depender del intervalo y duración del muestreo. El cociente
 120 $f_N/f_0 = (1/2\Delta t)/(1/N\Delta t) = N/2$ indica el número máximo de componentes de
 121 Fourier que podemos estimar. Una señal periódica se puede descomponer en la suma
 122 de un conjunto (infinito) de funciones oscilatorias de senos y cosenos o componentes
 123 de Fourier. Esto lo veremos en el capítulo~7. A cada muestreo de un fenómeno le
 124 denominamos realización, y a un conjunto de realizaciones se les denomina ensamble.

125 1.2 Estadística básica

126 La estadística trata de describir las características de una población continua a par-
 127 tir de muestras discretas de la misma. Hablamos de población y de muestra de una
 128 población. Si calculamos, por ejemplo, la media de una población, estamos calcu-
 129 lando un {parámetro}. Cuando calculamos la media de una muestra le llamamos un
 130 estadístico de la población.

131 La estadística nos ayuda a organizar, analizar, presentar datos, y nos da información
 132 de cómo planear la recolección de los mismos, i.e. a muestrear.

133

134 1. La media:

135 La media de una muestra de N valores $x_i = x_1, x_2, \dots, x_N$ es

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \langle x \rangle. \quad (1)$$

136 La media debe de diferenciarse de la mediana. La media es el momento de orden
 137 cero. La mediana de una población es aquel valor numérico que separa el 50% de val-
 138 ores mas altos del 50% de valores mas bajos. Se puede calcular ordenando de menor
 139 a mayor el conjunto de valores y escoger el valor central si el conjunto de datos es
 140 impar o el promedio de los dos centrales si es par.

141 2. La varianza:

142 La varianza de un una muestra de N valores x_i es

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2 = \langle x'^2 \rangle, \quad (2)$$

143 donde las primas indican fluctuaciones alrededor de la media. La varianza es una
 144 medida de cuán lejos estan los diferentes puntos de la muestra de la media de la
 145 población. La varianza es el segundo momento alrededor de la media. Al dividir por
 146 N estamos subestimando la verdaderavarianza de la población. Al dividir por $N - 1$
 147 obtenemos un estimador insesgado.

148 NOTA: el sesgo de un estimador se refiere a la diferencia entre su esperanza matemática
 149 y el valor numérico (real) del parámetro que se estima. Un estimador que no tiene
 150 sesgo se dice insesgado. Por ejemplo, para la media:

$$E[x] - \mu \rightarrow 0$$

$$\bar{x} - \mu \rightarrow 0$$

151 EJERCICIO: Demostrar porqué hay que dividir por $N - 1$ en lugar de N para que la
 152 definición de varianza sea un estimador insesgado.

153 3. La desviación típica:

154 Es la raíz cuadrada de la varianza. Se suele escribir como σ para referirse a la
 155 población o como s en estadística

$$s = \sqrt{s^2}. \quad (3)$$

156 4. Momentos de orden superior:

157 Podemos definir un momento alrededor de la media como:

$$m_p = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^p = \langle x'^p \rangle. \quad (4)$$

158 De esta forma m_2 es la varianza, m_3 es la asimetría, y m_4 la curtosis. El momento
 159 m_3 indica la asimetría de la muestra alrededor de la media ($m_3 > 0$ implica dis-
 160 tribución con cola larga en la parte positiva y viceversa). m_4 indica el grado de es-
 161 parcimiento de las muestras alrededor de la media. Una mayor curtosis indica mayor
 162 concentración de puntos alrededor de la media. Los momentos de orden superior
 163 (> 2) se suelen adimensionalizar dividiendo por la desviación estandar:

$$m_3 = \frac{1}{N} \sum_{i=1}^N \left[\frac{x_i - \bar{x}}{\sigma} \right]^3 = \langle (x/\sigma)'^3 \rangle \quad (5)$$

$$m_4 = \frac{1}{N} \sum_{i=1}^N \left[\frac{x_i - \bar{x}}{\sigma} \right]^4 - 3 = \langle (x/\sigma)'^4 \rangle - 3 \quad (6)$$

164 donde el factor -3 hace que la curtosis tome el valor cero para una distribución
 165 Normal.

166

167 Figura 1.1. Distribuciones con $m_3 < 0$ (izquierda) y $m_3 > 0$ (derecha).

168

169 Figura 1.2. Distribuciones con diferentes grados de curtosis; $m_4 > 0$ (Leptocúrtica),
 170 $m_4 = 0$ (Normal o Mesocúrtica), y $m_4 < 0$ (Platicúrtica).

171 (5) Covarianza y correlación:

172 La covarianza entre dos variables x e y puede definirse como un estadístico que
 173 relaciona x e y de la siguiente forma

$$C_{xy} = \langle x'y' \rangle = \langle (x - \bar{x})(y - \bar{y}) \rangle = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}).$$

174 La correlación es la covarianza normalizada

$$\rho_{xy} = \frac{C_{xy}}{s_x s_y} = \frac{\langle x'y' \rangle}{\sqrt{\langle x'^2 \rangle \langle y'^2 \rangle}}.$$

175 Consideremos el modelo estadístico lineal de media cero (es una recta que pasa por
 176 $(\bar{x}, \bar{y}) = (0, 0)$)

$$\hat{y} = \alpha x,$$

177 donde α es una constante. El error cometido por este estimador se define como el
 178 error cuadrático medio

$$\epsilon = \langle (\hat{y} - y)^2 \rangle = \alpha^2 \langle x^2 \rangle + \langle y^2 \rangle - 2\alpha \langle xy \rangle$$

179 y si queremos minimizar dicho error entonces tenemos que encontrar que α es el que
 180 provoca que la derivada $\partial\epsilon/\partial\alpha \rightarrow 0$. Es decir

$$\partial\epsilon/\partial\alpha = 2\alpha \langle x^2 \rangle - 2 \langle xy \rangle = 0,$$

181 y el α es

$$\alpha = \frac{\langle xy \rangle}{\langle x^2 \rangle}.$$

182 El error mínimo cuadrado se encuentra substituyendo el valor de α en la expresión
 183 del error ϵ de arriba

$$\begin{aligned} \epsilon &= \frac{\langle xy \rangle^2}{\langle x^2 \rangle} + \langle y^2 \rangle - 2 \frac{\langle xy \rangle^2}{\langle x^2 \rangle} = \langle y^2 \rangle \left(\frac{\langle xy \rangle^2}{\langle x^2 \rangle \langle y^2 \rangle} + 1 - 2 \frac{\langle xy \rangle^2}{\langle x^2 \rangle \langle y^2 \rangle} \right) = \\ &= \langle y^2 \rangle (1 - \rho_{xy}^2). \end{aligned}$$

184 Si $\rho_{xy}^2 = 1$ entonces el error es cero, es decir, mínimo error. Opuestamente, si
 185 $\rho_{xy}^2 = 0$ entonces el error es igual a la varianza, es decir, máximo error. Si ρ toma
 186 valores intermedios, i.e., $\rho_{xy}^2 = 0.5$, entonces el error es $\epsilon = 0.5 \langle y^2 \rangle$, es decir,
 187 el error del modelo lineal es un 50% de la varianza. Por lo tanto, la correlación al
 188 cuadrado puede definirse también como la eficiencia relativa del estimador \hat{y}^2 o la
 189 fracción de varianza explicada por el modelo lineal

$$\rho_{xy}^2 = \frac{\langle \hat{y}^2 \rangle}{\langle y^2 \rangle} = \frac{\text{varianza explicada}}{\text{varianza total}}.$$

190 A este parámetro se le puede encontrar en literatura inglesa como *skill* del modelo
 191 lineal.

192 **2 Probabilidad**193 **2.1 Distribuciones de probabilidad:**

194 La {función de distribución acumulativa} $D_x(r)$ se define como la probabilidad que
 195 una variable aleatoria x sea menor o igual a r , es decir, $P(x \leq r)$. Matemáticamente:

$$D(x) = \int_{-\infty}^r F(x)dx ,$$

196 donde

$$F(x) = \frac{d}{dx} D(x)$$

197 es la función de densidad de probabilidad (PDF, por sus siglas en inglés). La PDF

198 nos informa de la probabilidad que x sea igual a un cierto valor r , $P(x = r)$.

199 Algunas propiedades de $D(x)$:

200 * $D(r) \leq D(s)$ if $r \leq s$

202 * $D(-\infty) = 0$

203 * $D(\infty) = 1$

204 Algunas propiedades de $F(x)$:

205 (1) $F(x) \geq 0$

206 (2) $\int_{-\infty}^{\infty} F(x)dx = 1$

207 La probabilidad que una variable aleatoria x esté contenida en el intervalo $[r, r + dr]$
 208 es la integral de la función de densidad de probabilidad

$$P(r \leq x \leq r + dr) = \int_r^{r+dr} F(x)dx .$$

209 Ambas definiciones son parecidas aunque no son lo mismo. Para ello veamos el ejem-
 210 plo de la suma del lanzamiento de dos dados al aire.

211
 212 La densidad de probabilidad de que la suma de los dos dados sea 7 es máxima y
 213 que sea 2 o 12 es mínima. Este ejemplo describe dos propiedades fundamentales de
 214 funciones de probabilidad discretas: (i) $P(X = x) \geq 0$ y (ii) $\sum P(x) = 1$. La distribu-
 215 ción de probabilidad acumulativa y la función de densidad de probabilidad tienen las
 216 siguientes distribuciones

218 Momentos estadísticos de una función de densidad de probabilidad:

219 Los momentos centrados (o alrededor de la media) de una distribución de probabili-
 220 dad se definen como

$$m_r = E[(x - E[x])^r] = \int_{-\infty}^{\infty} (x - \mu)^r F(x)dx .$$

221 Como caso particular, los momentos alrededor del origen (i.e., $\mu = 0$) son:

$$m_r^0 = E[x^r] = \int_{-\infty}^{\infty} x^r F(x)dx .$$

222 Entonces, los primeros tres momentos centrados se definen como

$$\begin{aligned}
 223 \quad m_0 &= E[(x - E[x])^0] = E[1] = \int_{-\infty}^{\infty} F(x)dx = 1, \\
 224 \quad m_1 &= E[(x - E[x])^1] = E[x] - \mu = \int_{-\infty}^{\infty} (x - \mu)^1 F(x)dx = 0, \\
 225 \quad m_2 &= E[(x - E[x])^2] = E[x^2 + E[x]^2 - 2xE[x]] = E[x^2] + E[x]^2 - 2E[x]E[x] = \\
 &\quad E[x^2] - E[x]^2 = \underbrace{E[x^2]}_{\sigma^2} - \mu^2 = \int_{-\infty}^{\infty} (x - \mu)^2 F(x)dx = \sigma^2 - \mu^2.
 \end{aligned}$$

226 Los momentos alrededor de cero ($\mu = 0$) tambien pueden ser estandarizados:

$$m_r^* = m_r / \sigma^r = \frac{E[(x - E[x])^r]}{\underbrace{(E[(x - E[x])^2])^{r/2}}_{\sigma^2}}.$$

227 Los cuatro primeros momentos estadísticos alrededor de cero estandarizados son:

$$\begin{aligned}
 228 \quad m_1^* &= m_1 / \sigma^1 = \frac{E[(x - \mu)^1]}{(E[(x - \mu)^2])^{1/2}} = \frac{\mu - \mu}{\sqrt{E[(x - \mu)^2]}} = 0, \\
 229 \quad m_2^* &= m_2 / \sigma^2 = \frac{E[(x - \mu)^2]}{(E[(x - \mu)^2])^{2/2}} = 1, \\
 230 \quad m_3^* &= m_3 / \sigma^3 = \frac{E[(x - \mu)^3]}{(E[(x - \mu)^2])^{3/2}}, \\
 &\quad m_4^* = m_4 / \sigma^4 = \frac{E[(x - \mu)^4]}{(E[(x - \mu)^2])^{4/2}}.
 \end{aligned}$$

231 1. Distribución uniforme:

232 La distribución de probabilidad uniforme viene dada por

$$\begin{aligned}
 233 \quad F(x) &= \frac{1}{b-a}, \quad a \leq x \leq b \\
 &= 0, \quad \text{fuera del intervalo}
 \end{aligned}$$

234 Se deduce de la expresión de área de un cuadrado:

$$Area = base * altura = (b - a)F(x) = 1$$

235 La función de distribución acumulativa es

$$D(x) = 0, \quad x < a$$

$$\begin{aligned}
 236 \quad D(x) &= \frac{x - a}{b - a}, \quad a \leq x \leq b \\
 237 \quad D(x) &= 1, \quad x \geq b
 \end{aligned}$$

238 La media es $\mu = (b + a)/2$ y la varianza es $\sigma^2 = 1/3(a^2 + b^2 + ab)$. Demostración:
239 Los momentos estadísticos alrededor del origen de la distribución uniforme son

$$m_r^0 = E[x^r] = \int_{-\infty}^{\infty} x^r F(x)dx = \int_a^b \frac{x^r}{b-a} dx =$$

$$\frac{1}{b-a} \int_a^b x^r dx = \frac{1}{b-a} \left[\frac{x^{r+1}}{r+1} \right]_a^b = \frac{1}{b-a} \left[\frac{b^{r+1}}{r+1} - \frac{a^{r+1}}{r+1} \right] = \frac{b^{r+1} - a^{r+1}}{(b-a)(r+1)}$$

²⁴¹ y por lo tanto la media es

$$m_1^0 = E(x) = \frac{b^2 - a^2}{2(b-a)} = \frac{(b-a)(b+a)}{2(b-a)} = \frac{b+a}{2},$$

²⁴² y la varianza

$$m_2^0 = E(x^2) = \frac{b^3 - a^3}{3(b-a)} = \frac{(b-a)(a^2 + b^2 + ab)}{3(b-a)} = \frac{1}{3}(a^2 + b^2 + ab).$$

²⁴³ Ejemplo de distribución uniforme: La ruleta rusa. Supongamos que puede tomar 360
²⁴⁴ valores, es decir, $0 \leq x \leq 360$. Entonces

$$F(x) = \frac{1}{360}, \quad 0 \leq x \leq 360,$$

²⁴⁵ y, por ejemplo, la probabilidad de que la bola caiga entre el 50 y el 360 es

$$P(50 \leq x \leq 360) = \int_{50}^{360} \frac{1}{360} dx = \frac{1}{360} [x]_{50}^{360} = \frac{310}{360} = 0.8611 (\sim 86\%).$$

²⁴⁶ La función de distribución acumulativa es

$$D(x) = 0, \quad x < 0$$

$$D(x) = \frac{x}{360}, \quad 0 \leq x \leq 360$$

$$D(x) = 1, \quad x \geq 360$$

²⁴⁹ 2. Distribución normal o Gaussiana:

²⁵⁰ La distribución normal es una de las distribuciones mas recurrente en la naturaleza.
²⁵¹ En general cualquier variable aleatoria medida, especialmente aquellas que son suma
²⁵² de otras variables aleatorias, tiene una distribución normal alrededor de la media

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(x-\bar{x})^2}{2\sigma^2} \right\}.$$

²⁵³

²⁵⁴ La distribución de función acumulativa normal se obtiene integrando la expresión
²⁵⁵ de arriba. Para ello vamos a realizar el cambio de variable (que no es nada mas que
²⁵⁶ estandarizar la variable aleatoria x)

$$z = \frac{x - \bar{x}}{\sigma\sqrt{2}}$$

²⁵⁷ y

$$dz = \frac{dx}{\sigma\sqrt{2}},$$

²⁵⁸ de lo que se deduce

$$D(z) = \frac{\sigma\sqrt{2}}{\sigma\sqrt{2\pi}} \int_{-\infty}^z \exp\{-z^2\} dz = \frac{1}{\sqrt{\pi}} \int_{-\infty}^z \exp\{-z^2\} dz,$$

259 donde $\frac{2}{\sqrt{\pi}} \int_0^z \exp\{-t^2\} dt = \text{erf}(z)$.

260

261 Los momentos estadísticos alrededor del origen de la función de distribución Normal
262 son

$$m_r^0 = E[x^r] = \int_{-\infty}^{\infty} x^r F(x) dx = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x^r \exp\left\{-\frac{(x-\bar{x})^2}{2\sigma^2}\right\} dx$$

263 Hagamos el cambio de variable

264

$$\begin{aligned} u &= \frac{x-\bar{x}}{\sigma\sqrt{2}} \\ du &= \frac{dx}{\sigma\sqrt{2}} \end{aligned}$$

265 Si substituimos en la expresión de m_r obtenemos

$$m_r^0 = \frac{\sigma\sqrt{2}}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (\sigma\sqrt{2}u + \bar{x})^r e^{-u^2} du = \frac{1}{\sqrt{\pi}} \int_{-\infty}^{\infty} (\sigma\sqrt{2}u + \bar{x})^r e^{-u^2} du.$$

266 **Ejercicio:** Deducir los momentos estadísticos de orden 1 y 2 de la distribución
267 Normal, es decir, la media y la varianza. Integrales útiles:

268

$$\begin{aligned} \int e^{-ax^2} dx &= \frac{\sqrt{\pi}}{2\sqrt{a}} \text{erf}(x\sqrt{a}) \\ \int xe^{-ax^2} dx &= -\frac{1}{2a} e^{-ax^2}, \end{aligned}$$

269 donde la función de error se define cómo:

$$\text{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt.$$

270 La función de error cumple las siguientes identidades:

271

$$\text{erf}(0) = \frac{2}{\sqrt{\pi}} \int_0^0 e^{-t^2} dt = 0$$

$$\text{erf}(\infty) = \frac{2}{\sqrt{\pi}} \underbrace{\int_0^{\infty} e^{-t^2} dt}_{\frac{\sqrt{\pi}}{2}} = 1$$

272

$$\text{erf}(-\infty) = \frac{2}{\sqrt{\pi}} \underbrace{\int_0^{-\infty} e^{-t^2} dt}_{-\frac{\sqrt{\pi}}{2}} = -1$$

273

274 **Respuesta:** La media y la varianza son

275

$$\begin{aligned} m_1^0 &= E(x) = \mu \quad ; \quad m_1 = 0 \\ m_2^0 &= Var(x) = \mu^2 + \sigma^2 \quad ; \quad m_2 = \sigma^2 \end{aligned}$$

276

Deducción de la media: El momento de orden 1 centrado es:

$$m_1 = \frac{\sigma\sqrt{2}}{\sqrt{\pi}} \int_{-\infty}^{\infty} ue^{-u^2} du = -\frac{\sigma\sqrt{2}}{2\sqrt{\pi}} e^{-u^2} \Big|_{-\infty}^{\infty} = 0.$$

277

y alrededor de cero (momentos crudos):

$$\begin{aligned} m_1^0 &= \frac{1}{\sqrt{\pi}} \int_{-\infty}^{\infty} (\sigma\sqrt{2}u + \mu)e^{-u^2} du = \frac{\sigma\sqrt{2}}{\sqrt{\pi}} \int_{-\infty}^{\infty} ue^{-u^2} du + \frac{1}{\sqrt{\pi}} \int_{-\infty}^{\infty} \mu e^{-u^2} du = \\ &= \underbrace{\frac{\sigma\sqrt{2}}{\sqrt{\pi}} \left(-\frac{1}{2} e^{-u^2} \right)}_0 \Big|_{-\infty}^{\infty} + \frac{\mu}{\sqrt{\pi}} \left(\frac{\sqrt{\pi}}{2} \operatorname{erf}(u) \right) \Big|_{-\infty}^{\infty} = \frac{\mu}{2} [1 - (-1)] = \mu, \end{aligned}$$

278

Deducción de la varianza:

279

El momento de orden 2 centrado es:

$$m_2 = \frac{(\sigma\sqrt{2})^2}{\sqrt{\pi}} \int_{-\infty}^{\infty} u^2 e^{-u^2} du$$

280

$$\begin{aligned} x &= u \rightarrow dx = du \\ dy &= ue^{-u^2} \rightarrow y = \frac{1}{2} e^{-u^2} \end{aligned}$$

281

$$\begin{aligned} m_2 &= \frac{2\sigma^2}{\sqrt{\pi}} \left[-\frac{1}{2} e^{-u^2} \Big|_{-\infty}^{\infty} + \frac{\sqrt{\pi}}{4} \operatorname{erf}(u) \Big|_{-\infty}^{\infty} \right] = \frac{2\sigma^2}{\sqrt{\pi}} \left[0 + \frac{\pi}{4} (\operatorname{erf}(\infty) - \operatorname{erf}(-\infty)) \right] = \\ &= \frac{2\sigma^2}{\sqrt{\pi}} \left[\frac{\pi}{4} + \frac{\pi}{4} \right] = \sigma^2 \end{aligned}$$

282

y alrededor de cero (momentos crudos):

283

$$\begin{aligned} m_2^0 &= \frac{1}{\sqrt{\pi}} \int_{-\infty}^{\infty} (\sigma\sqrt{2}u + \mu)^2 e^{-u^2} du = \frac{1}{\sqrt{\pi}} \int_{-\infty}^{\infty} 2\sigma^2 u^2 e^{-u^2} du + \\ &\quad + \frac{\mu^2}{\sqrt{\pi}} \int_{-\infty}^{\infty} e^{-u^2} du + \frac{2\sigma\sqrt{2}\mu}{\sqrt{\pi}} \int_{-\infty}^{\infty} ue^{-u^2} du = \\ &= \underbrace{\frac{2\sigma^2}{\sqrt{\pi}} \int_{-\infty}^{\infty} u^2 e^{-u^2} du}_{m_2 = \sigma^2} + \underbrace{\mu \frac{1}{\sqrt{\pi}} \int_{-\infty}^{\infty} ue^{-u^2} du}_{m_1^0 = \mu} + 2\mu \underbrace{\frac{\sigma\sqrt{2}}{\sqrt{\pi}} \int_{-\infty}^{\infty} ue^{-u^2} du}_{m_1 = 0} = \sigma^2 + \mu^2, \end{aligned}$$

284

La probabilidad de que una variable normalmente distribuida caiga en una desviación estandar de su valor medio viene dada por

285

$$\begin{aligned} P(-1 \leq z \leq 1) &= \int_{-1}^{+1} F(z) dz = \frac{1}{\sqrt{2\pi}} \int_{-1}^{+1} e^{-\frac{1}{2}z^2} dz = \\ &= \frac{1}{\sqrt{2\pi}} \frac{\sqrt{\pi}}{2\sqrt{1/2}} [\operatorname{erf}(z\sqrt{1/2})]_{-1}^1 = \frac{1}{2} [\operatorname{erf}(1/\sqrt{2}) - \operatorname{erf}(-1/\sqrt{2})] = \\ &= \frac{1}{2} [0.6827 - (-0.6827)] = 0.6827 (68.27\%), \end{aligned}$$

286

288 y similarmente para 2 y 3 desviaciones estandard

$$P(-2 \leq z \leq 2) = \int_{-2}^{+2} F_x(z) dz = 95.45\%$$

$$P(-3 \leq z \leq 3) = \int_{-3}^{+3} F_x(z) dz = 99.73\%.$$

290 Entonces solo hay un 4.55% de probabilidad de que una variable normalmente dis-
291 tribuida caiga fuera de dos desviaciones estandard respecto de la media. Puesto que
292 es una probabilidad con 2 colas, la probabilidad de que una variable normal exceda
293 su media por mas de 2σ es la mitad de esto, es decir 2.275%, ya que la distribución
294 normal es simétrica.

295 En la práctica una PDF se calcula como un histograma escalado. Es por ello que
296 necesitamos escojer el tamaño y localización de los bins en el histograma. La demo
297 muestra las consecuencias de esta elección (pdf_demo.m).

298

299 3. Distribución de Poisson:

300 La distribución de Poisson expresa la probabilidad de que ocurra un determinado
301 número de eventos durante un cierto intervalo en el tiempo o distancia en el espacio.
302 Se usa generalmente para la ocurrencia de sucesos con muy poca probabilidad o muy
303 “raros”. La expresión para la función acumulativa es:

$$D(x) = P(x \leq r) = e^{-\lambda} \sum_{k=0}^{|r|} \frac{\lambda^k}{k!},$$

304 donde λ es el valor promedio

305 y la función de densidad de probabilidad

$$F(x) = P(x = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

306 Los momentos estadísticos alrededor del origen de la función de distribución de
307 Poisson se pueden calcular directamente con sumatorios y expansion de Taylor:

$$\begin{aligned} m_r^0 &= E[x^r] = \sum_{k \geq 0} k^r P(X = k) = \sum_{k \geq 0} k^r F(x) = \sum_{k \geq 0} k^r \frac{\lambda^k e^{-\lambda}}{k!} = \\ &= \lambda e^{-\lambda} \sum_{k \geq 0} \frac{k^r}{k!} \lambda^{k-1} \end{aligned}$$

311 Veamos el momento de orden 1 alrededor del origen:

$$\begin{aligned} m_1^0 &= E[x] = \lambda e^{-\lambda} \sum_{k \geq 0} \frac{k}{k!} \lambda^{k-1} = \lambda e^{-\lambda} \sum_{k \geq 1} \frac{k}{(k-1)!k} \lambda^{k-1} = \lambda e^{-\lambda} \sum_{k \geq 1} \frac{1}{(k-1)!} \lambda^{k-1} \\ &= \lambda e^{-\lambda} \sum_{j \geq 0} \frac{\lambda^j}{j!}, \end{aligned}$$

313 para $j = k - 1$. Finalmente expandiendo en series de Taylor la función exponencial

$$e^\lambda = \sum_{j \geq 0} \frac{1}{j!} \lambda^j$$

³¹⁴, obtenemos:

$$m_1^0 = \lambda e^{-\lambda} e^\lambda = \lambda$$

³¹⁵ Ejercicio: Demostrar que el momento estadístico alrededor del origen de orden 2 de
³¹⁶ la distribución de Poisson es igual a $m_2^0 = \lambda + \lambda^2$.

$$\begin{aligned} m_2^0 &= E[x^2] = \lambda e^{-\lambda} \sum_{k \geq 0} \frac{k^2}{k!} \lambda^{k-1} = \lambda e^{-\lambda} \left[\sum_{k \geq 1} (k-1) \frac{1}{(k-1)!} \lambda^{k-1} + \sum_{k \geq 1} \frac{1}{(k-1)!} \lambda^{k-1} \right] = \\ &= \lambda e^{-\lambda} \left[\lambda \sum_{k \geq 2} \frac{1}{(k-2)!} \lambda^{k-2} + \sum_{k \geq 1} \frac{1}{(k-1)!} \lambda^{k-1} \right] = \\ &= \lambda e^{-\lambda} \left[\lambda \sum_{j \geq 0} \frac{1}{j!} \lambda^j + \sum_{i \geq 0} \frac{1}{(i)!} \lambda^i \right] = \lambda e^{-\lambda} [\lambda e^\lambda + e^\lambda] = \\ &= \lambda(\lambda + 1) = \lambda^2 + \lambda. \end{aligned}$$

³¹⁸ En el caso que fuera el momento de orden 2 centrado se escribiría:

$$E[(x - E[x])^2] = E[x^2] - (E[x])^2 = \lambda^2 + \lambda - (\lambda)^2 = \lambda.$$

³¹⁹ **Ejemplo:** En los últimos 160 años, han sucedido 680 tormentas intensas en el Golfo
³²⁰ de México, incluyendo depresiones, tormentas tropicales, y huracanes. Asumimos
³²¹ que la frecuencia de ocurrencia de una tormenta intensa en el Golfo de México sigue
³²² una distribución de Poisson (eventos “raros”, poco frecuentes). Calcula la probabili-
³²³ dad de que ocurran 2 huracanes en 1 año:

- ³²⁴ (a) El número promedio de tormentas intensas por año es: $\mu = 680/160 = 4.25$
³²⁵ huracanes/año.
³²⁶ (b) La probabilidad de que ocurran 2 huracanes en 1 año es:

$$P(x = 2) = \frac{\lambda^2 e^{-\lambda}}{2!} = \frac{4.25^2 e^{-4.25}}{2!} = 0.1288 (\sim 12\%)$$

³²⁷ La probabilidad es muy baja debido a que exigimos que sean exactamente 2 hu-
³²⁸ racanes en un año y no, por ejemplo, > 2. En el segundo caso, la probabilidad
³²⁹ aumentaría considerablemente

$$\begin{aligned} P(x > 2) &= P(x = 3) + P(x = 4) + \dots = 1 - P(x \leq 2) = 1 - [P(x = 0) + P(x = 1) + P(x = 2)] = \\ &= 1 - [0.0143 + 0.0606 + 0.1288] = 1 - 0.2037 = 0.7963 (\sim 80\%) \end{aligned}$$

³³¹ 4. Distribución Binomial:

³³² Supongamos que tenemos un conjunto de n tiradas en los cuales pueden suceder
³³³ únicamente dos cosas: ‘acertar’ o ‘fallar’. La probabilidad de acertar en una tirada es

334 p=P. Si X es el número total de aciertos en n tiradas, entonces la probabilidad de
 335 que el número de aciertos sea k es:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, 2, 3, \dots, n,$$

336 }donde la expresión

$$\binom{n}{k} = C(n, k) \equiv \frac{n!}{(n-k)!k!},$$

337 es el número de diferentes combinaciones de grupos de k objetos que pueden ser
 338 elegidos de un conjunto total de n objetos. Estos números se denominan coeficientes
 339 binomiales. La probabilidad de que el número de aciertos caiga en un rango de
 340 valores es

$$P(a \leq X \leq b) = \sum_a^b P(X)$$

341 Ejemplo 1: ¿Cuál es la probabilidad de obtener exactamente 6 caras de 10 lanza-
 342 mientos de moneda? Respuesta:

$$P(x = 6) = C(10, 6)0.5^6(1 - 0.5)^{10-6} = \frac{10!}{(10-6)!6!} 0.5^6(1 - 0.5)^{10-6} \simeq 0.205$$

343 {Ejemplo 2:} ¿Cuál es la probabilidad de obtener mas de 15 caras de 20 lanzamien-
 344 tos de moneda? Respuesta:

$$\sum_{k=16}^{20} \binom{20}{k} 0.5^k (1 - 0.5)^{20-k} = 0.006.$$

345 Si realizas esta operación a mano se vuelve muy tediosa. Es por ello que se utiliza la
 346 aproximación Normal a la distribución Binomial (DeMoivre-Laplace).

347 **Teorema de DeMoivre-Laplace** (aproximación de Binomial a Normal)
 348 La distribución binomial de una variable X definida por n tiradas independientes
 349 cada una de las cuales tienen una probabilidad p de acertar, es aproximadamente
 350 una distribución Normal de media np y desviación típica $\sqrt{np(1-p)}$, cuando n es
 351 suficientemente grande. Entonces se deduce que para cualquier número a y b ,

$$\lim_{n \rightarrow \infty} P\left(a < \frac{X - np}{\sqrt{np(1-p)}} < b\right) = \frac{1}{\sqrt{2\pi np(1-p)}} \int_a^b \exp\left[-\left[\frac{(x - np)^2}{2np(1-p)}\right]\right] dx.$$

352 Esto significa que el estadístico, $\frac{X-np}{\sqrt{np(1-p)}}$, tiene una distribución Normal. Este teo-
 353 rema es un caso particular del teorema del límite central y nos permite de simplificar
 354 la solución de un problema binomial.

355 **Ejemplo de la aproximación Normal a la distribución Binomial:**
 356 El 2% de los XBTs fabricados por una empresa presentan defectos. Si hemos
 357 adquirido 2000 XBTs, ¿Cuál es la probabilidad de que haya menos de 50 defectu-
 358 osos?

359 Respuesta: Se trata de una distribución binomial ya que solo pueden ser defectuosos
 360 o no defectuosos. La probabilidad que sea defectuoso es $p = 0.02$ (2%) y $n = 2000$,
 361 lo que nos da una distribución Binomial $B(2000, 0.02)$. Puesto que la n es grande
 362 podemos hacer una aproximación a la distribución Normal. Calculamos la media
 363 y desviación estandar de la distribución Normal $\mu = np = 200 * 0.02 = 40$ y
 364 $\sigma = \sqrt{np(1-p)} = \sqrt{2000 * 0.02 * (1 - 0.02)} = 6.26$ x es $B(2000, 0.02)$ y x_N es
 365 $N(40, 6.26)$.

366 La probabilidad que $x < 50$ es

$$p(x < 50) = p(x_N \leq 49),$$

367 y si estandarizamos

$$p(x_N \leq 49) = p\left(z \leq \frac{49 - 40}{6.26}\right) = p(z \leq 1.44) = 0.9251.$$

368 EJERCICIOS de estadística y probabilidad:

369 Ejercicio 1: Calcule $E[x]$ si x tiene la función de densidad de probabilidad

$$f(x) = \begin{cases} \frac{1}{4}xe^{-\frac{x}{2}}, & x > 0 \\ 0, & \text{otherwise} \end{cases}.$$

370 La esperanza $E[x]$ de la función $f(x)$ es entonces

$$E[x] = \int_0^\infty x \left(\frac{1}{4}xe^{-\frac{x}{2}}\right) dx = \frac{1}{4} \int_0^\infty x^2 e^{-\frac{x}{2}} dx.$$

371 Definamos $y = x/2$; entonces $x = 2y$ y $dx = 2dy$ y obtenemos

$$E[x] = \frac{1}{4} \int_0^\infty x^2 e^{-\frac{x}{2}} dx = \frac{1}{4} \int_0^\infty (2y)^2 e^{-y} 2dy = 2 \int_0^\infty y^2 e^{-y} dy.$$

372 Vamos ahora a resolver la integral por partes. Hacemos la siguiente sustitución: $u =$
 373 y^2 , $dv = e^{-y}$ y por ende $du = 2ydy$ y $v = -e^{-y}$. La integral se puede reescribir us-
 374 ando la expresión general de integración por partes $h(x) = uv - \int vdu$:

$$E[x] = 2 \int_0^\infty y^2 e^{-y} dy = 2 \left[-y^2 e^{-y} - \int -e^{-y} (2y) dy \right] = 2 \left[-y^2 e^{-y} + 2 \int y e^{-y} dy \right].$$

375 Integraremos de nuevo por partes. Usa $u = y$, $dv = e^{-y}$ y entonces $du = dy$ y $v =$
 376 $-e^{-y}$

$$\begin{aligned} E[x] &= 2 \left[-y^2 e^{-y} + 2 \left\{ -ye^{-y} - \int -e^{-y} dy \right\} \right] = \\ &= 2 \left[-y^2 e^{-y} + 2 \left\{ -ye^{-y} - e^{-y} \right\} \right] = \end{aligned}$$

$$= -2y^2 e^{-y} - 4ye^{-y} - 4e^{-y} =$$

$$= [-2e^{-y}(y^2 + 2y + 2)]_0^\infty =$$

$$= \lim_{n \rightarrow \infty} [-2e^{-y}(y^2 + 2y + 2)] - [-2e^{-y}(y^2 + 2y + 2)]_{y=0}.$$

380 El límite es ahora del tipo ∞/∞ y entonces usamos la regla de l'Hopital

$$E[x] = -2 \lim_{y \rightarrow \infty} \frac{2y+2}{e^y} + 2 [e^{-y}(y^2 + 2y + 2)]_{y=0}$$

381 Usamos la regla de l'Hopital de nuevo

$$E[x] = -2 \lim_{y \rightarrow \infty} \frac{2}{e^y} + 2 [e^{-y}(y^2 + 2y + 2)]_{y=0} = 0 + 2 [e^{-y}(y^2 + 2y + 2)]_{y=0} = 4$$

382 Ejercicio 2: Calcule $E[x]$ si x tiene la función de densidad de probabilidad

$$f(x) = \begin{cases} c(1-x^2) & , -1 < x < 1 \\ 0 & , \text{otherwise} \end{cases} .$$

$$\begin{aligned} E[x] &= \int_{-1}^1 x[c(1-x^2)]dx = c \int_{-1}^1 x[(1-x^2)]dx = \\ 383 &= c \int_{-1}^1 x - x^3 dx = c \left[\frac{x^2}{2} + \frac{x^4}{4} \right]_{-1}^1 = 0 \end{aligned}$$

384 Ejercicio 3: Calcule $E[x]$ si x tiene la función de densidad de probabilidad

$$f(x) = \begin{cases} \frac{5}{x^2} & , x > 5 \\ 0 & , x \leq 5 \end{cases} .$$

$$\begin{aligned} 385 E[x] &= \int_5^\infty x \frac{5}{x^2} dx = \int_5^\infty \frac{5}{x} dx = 5 \int_5^\infty \frac{1}{x} dx \\ &= 5[\ln x]_5^\infty = 5 \left[\left(\lim_{x \rightarrow \infty} \ln x \right) - \ln 5 \right] \rightarrow \infty \end{aligned}$$

386 Ejercicio 4: La variable aleatoria x tiene la siguiente función de proba-
387 bilidad

$$f(x) = \begin{cases} k(2x+3) & -1 \leq x \leq 2 \\ 0 & \text{otherwise} \end{cases} .$$

388 • ¿Cuál es el valor de k ?

$$\int_{-\infty}^\infty k(2x+3)dx = 1$$

$$\int_{-1}^2 k(2x+3)dx = (kx^2 + 3kx) \Big|_{-1}^2 = kx(3+x) \Big|_{-1}^2 = 10k + 2k = 1$$

$$12k = 1 \rightarrow k = \frac{1}{12}$$

389 • Calcula $E[x]$

$$\begin{aligned} E[x] &= \int_{-1}^2 xk(2x+3)dx = 2k \left. \frac{x^3}{3} \right|_{-1}^2 + 3k \left. \frac{x^2}{2} \right|_{-1}^2 = \\ &= k \left[\frac{18}{3} + \frac{9}{2} \right] = \frac{21}{24}. \end{aligned}$$

390 Ejercicio 5: Sea la función $g(x)$ dada por

$$g(x) = \begin{cases} x + 2\alpha & , x \leq -\alpha \\ x & , -\alpha \leq x \leq \alpha \\ x - 2\alpha & , x > \alpha \end{cases}$$

391 donde asumimos que x esta normalmente distribuida. Calcula la media de $g(x)$.

$$\begin{aligned} E[g(x)] &= \int_{-\infty}^{\infty} g(x)F(x)dx = \int_{-\infty}^{-\alpha} (x + 2\alpha)F(x)dx + \int_{-\alpha}^{\alpha} xF(x)dx + \int_{\alpha}^{\infty} (x - 2\alpha)F(x)dx = \\ &= \int_{-\infty}^{-\alpha} xF(x)dx + \int_{-\infty}^{-\alpha} 2\alpha F(x)dx + \int_{-\alpha}^{\alpha} xF(x)dx + \int_{\alpha}^{\infty} xF(x) - \int_{\alpha}^{\infty} 2\alpha F(x)dx = \\ &= \int_{-\infty}^{-\infty} xF(x)dx + 2\alpha \left[\int_{-\infty}^{-\alpha} F(x)dx - \int_{\alpha}^{\infty} F(x)dx \right] = \\ &= \int_{-\infty}^{-\infty} xF(x)dx + 2\alpha \left[D(x = -\alpha) - \left(1 - \int_{-\infty}^{-\alpha} F(x)dx \right) \right] = \\ &= \int_{-\infty}^{-\infty} xF(x)dx + 2\alpha \left[D(x = -\alpha) - \left(1 - D(x = \alpha) \right) \right] = \\ &= \mu + 2\alpha [D(-\alpha) - 1 + D(\alpha)]. \end{aligned}$$

397 donde la media de la distribución Normal es

$$E[x] = \int_{-\infty}^{\infty} xF(x)dx = \int_{-\infty}^{\infty} x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx = \mu.$$

398 **Teorema del límite central:**

399 Definición 1: Sea $X_1, X_2, X_3, \dots, X_n$ un conjunto de variables aleatorias, independientes
400 e idénticamente distribuidas con media μ y varianza σ^2 distinta de cero. Sea

$$S_n = X_1 + X_2 + \dots + X_n,$$

401 entonces

$$\lim_{n \rightarrow \infty} Pr(Z_n \leq z) = \Phi(z),$$

402 donde $\Phi(z)$ es una distribución Normal estandar y $Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ es una
403 estandarización del sumatorio S_n de tal forma que la media de la nueva variable
404 Z_n sea cero y su desviación estándard sea igual a 1. De esta forma, las variables Z_n
405 convergerán a una distribución normal estandar $N(0, 1)$, cuando n tienda a infinito.
406 Definición 2: Sea $X_1, X_2, X_3, \dots, X_n$ un conjunto de variables aleatorias, indepen-
407 dientes e idénticamente distribuidas con media μ y varianza σ^2 distinta de cero.
408 Entonces, si n es suficientemente grande, la variable aleatoria

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

tiene aproximadamente una distribución normal con media $\mu(\bar{X}) = \mu$ y desviación típica $\sigma(\bar{X}) = \sigma/\sqrt{n}$.

NOTA: Es importante remarcar que el teorema del límite central no dice nada acerca de la distribución de X_i , solo de la distibución de su media muestral \bar{X} .

Aplicación 1: Calculo de probabilidades sobre la media muestral.

Ejemplo: La recolección de muestras de agua con una roseta es una variable aleatoria con media $\mu = 150$ ml y varianza de $\sigma^2 = 120$ ml². Si tomamos $n = 40$ muestras aleatorias de agua. (a) ¿Cuál es la media y la desviación estándar de la media muestral?, (b) ¿Cuál es la probabilidad de que la media muestral contenga entre 145 y 153 ml de agua?

(a) $\mu(\bar{X}) = 150$ ml y $\sigma(\bar{X}) = \sigma/\sqrt{n} = \sqrt{120/40} = \sqrt{3}$ ml

(b) Queremos calcular $Pr(145 \leq \bar{X} \leq 153)$. Si escribimos la probabilidad en forma estandarizada, entonces:

$$Pr(145 \leq \bar{X} \leq 153) = Pr\left(\frac{145 - 150}{\sqrt{3}} \leq Z \leq \frac{153 - 150}{\sqrt{3}}\right) \simeq Pr(-2.89 \leq Z \leq 1.73) =$$

$$= Pr(Z \leq 1.73) - Pr(Z \leq -2.89) = 0.9582 - (1 - 0.9981) = 0.9582 - 0.0019 = 0.9563$$

Función de densidad de probabilidad conjunta

La probabilidad que dos variables aleatorias (x, y) caigan en la región R (como por ejemplo un rectángulo) se obtiene integrando su función de probabilidad conjunta

$$P((x, y) \in R) = \int \int_R F(x, y) dx dy .$$

En particular, si R es un rectángulo 2d $(x, y) : r \leq x \leq r + dr, s \leq y \leq s + ds$, entonces

$$P((x, y) \in R) = P(r \leq x \leq r + dr, s \leq y \leq s + ds) = \int_r^{r+dr} \int_s^{s+ds} F(x, y) dx dy .$$

Algunas propiedades:

(1) $F(x, y) \geq 0$ para todo x,y.

(2) $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} F(x, y) dx dy = 1$

Definición: La función de densidad de probabilidad marginal de variables aleatorias x e y son:

$$Fx(x) = \int_{-\infty}^{\infty} F(x, y) dy \text{ y } Fy(y) = \int_{-\infty}^{\infty} F(x, y) dx .$$

Ejemplo del uso de la función de densidad de probabilidad conjunta

Imaginemos que una empresa de instrumentación oceanográfica fabrica boyas Lagrangianas de grosor x y diámetro y , los cuales varian de una boya a la otra. Imaginemos que la función de densidad de probabilidad conjunta de la variable aleatoria “dimensión del instrumento oceanográfico” es:

$$F(x, y) = \frac{1}{6}(r + s) \text{ si } (x, y) \in R = \{1 \leq x \leq 2; 4 \leq y \leq 5\}$$

$$F(x, y) = 0 \text{ si } (x, y) \text{ fuera de } R$$

438 Ahora queremos saber que probabilidad hay de que una boyta tenga un grosor
 439 $1 \leq x \leq 1.5m$ y un diámetro $4.5 \leq y \leq 5m$, es decir

$$P(1 \leq x \leq 1.5, 4.5 \leq y \leq 5) = \int_1^{1.5} \int_{4.5}^5 \frac{1}{6}(r + s) ds dr = 0.253 = 25\%$$

440 Significancia estadística utilizando la distribución Normal
 441 Como vimos en el teorema central del límite, para una población infinita ($N \rightarrow \infty$)
 442 la desviación estandar de la distribución de las medias muestrales es:

$$\sigma(\bar{x}) = \frac{\sigma}{\sqrt{N}} = \text{error estandar del estimado de la media.}$$

443 Aquí, σ es la desviación estandar de la población y N es el número de datos (inde-
 444 pendientes) utilizado para calcular la media muestral. Entonces, si promediamos
 445 observaciones de una población de desviación estandar σ , la desviación estandar de
 446 esos promedios disminuye como el inverso de la raíz cuadrada del tamaño muestral
 447 N .
 448 Si N es suficientemente grande podemos usar las estimaciones de σ y \bar{x} para cal-
 449 cular el denominado estadístico z que corresponde a una distribución normal es-
 450 tandarizada de media $\mu = 0$ y $\sigma = 1$

$$z = \frac{\bar{x} - \mu}{\sigma(\bar{x})} = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{N}}}$$

451 La fórmula de arriba puede modificarse convenientemente para darnos un test de
 452 significancia estadística para la diferencia entre medias muestrales con tamaños
 453 muestrales y desviación estandar diferentes:

$$z = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_{1,2}}{\sqrt{\frac{\sigma_1^2}{N_1} + \frac{\sigma_2^2}{N_2}}},$$

454 donde $\Delta_{1,2}$ es la diferencia esperada entre las dos medias, lo que se suele asumir cero
 455 en la práctica.
 456 Si el tamaño muestral N es menor de 30 entonces no podemos usar el estadístico
 457 z , pero podemos utilizar la distribución *t-student*; o cuando queremos comparar
 458 varianzas, podemos usar la distribución *chi-cuadrada*. La *t-student* converge a una
 459 distribución normal para largos tamaños muestrales y se define como

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{N-1}}} = \frac{\bar{x} - \mu}{\frac{\hat{s}}{\sqrt{N}}}; \hat{s} = \sqrt{\frac{N}{N-1}} s.$$

460 Si consideramos una población normalmente distribuida de media μ la función de
 461 densidad de probabilidad de la *t-student* es

$$F_x(t) = \frac{f_0(\nu)}{\left(1 + \frac{t^2}{\nu}\right)^{\frac{\nu+1}{2}}},$$

462 donde $\nu = N - 1$ es el número de grados de libertad y $f_0(\nu)$ es una constante que
 463 depende en ν y permite que el área bajo la curva $F_x(t)$ sea igual a la unidad. Los
 464 grados de libertad se definen como el número de muestras independientes N menos
 465 el número de parámetros del estadístico que queremos estimar.
 466 A diferencia del estadístico z , la *t-student* depende del número de grados de libertad;
 467 la cola de la distribución es larga para números de grados de libertad bajos (o N
 468 pequeña). Para números altos de grados de libertad (o N grande), la distribución
 469 *t-student* se acerca al estadístico z o distribución Normal.

470 Intervalos de confianza

471 Para calcular valores de los estadísticos z y *t-student* debemos de fijar el nivel de
 472 confianza definido como $1 - \alpha$; porcentaje del nivel de confianza $100(1 - \alpha)\%$. Esto
 473 se puede escribir simbolicamente cómo

$$P(-z_{\alpha/2} < z < z_{\alpha/2}) = 1 - \alpha$$

$$P(-t_{\alpha/2} < t < t_{\alpha/2}) = 1 - \alpha.$$

474 Una vez definido el nivel de confianza y los grados de libertad ν (para la *t-student*)
 475 podemos leer el valor de dichos estadísticos en tablas. En esas tablas $z_{\alpha/2}$ es el valor
 476 de z para el cual solo el $100 * \alpha/2\%$ de los valores de z es esperado ser mas grande
 477 (cola de la derecha de la distribución). Igualmente, $z_{-\alpha/2} = -z_{\alpha/2}$ es el valor de z
 478 para el cual solo el $100 * \alpha/2\%$ de los valores de z es esperado ser mas pequeño (cola
 479 de la izquierda de la distribución). O dicho de otra forma, $z_{\alpha/2}$ es el valor por encima
 480 del cual existe un área bajo la curva de $\alpha/2$. Los valores de z y t son las integrales
 481 bajo las correspondientes funciones de densidad de probabilidad.

482

483 (1) Intervalo de confianza para μ ($N > 30$, σ conocida)

484 Cuando $N > 30$ y σ es conocida, podemos usar el estadístico z para encontrar el
 485 intervalo de confianza para μ . Hay un $100 * (1 - \alpha)\%$ que cualquier estadístico z
 486 caiga en el intervalo

$$\begin{aligned} z_{-\alpha/2} &< \frac{\bar{x} - \mu}{\sigma} \sqrt{N} < z_{\alpha/2} \\ \frac{\sigma}{\sqrt{N}} z_{-\alpha/2} &< \bar{x} - \mu < \frac{\sigma}{\sqrt{N}} z_{\alpha/2} \\ -1 \frac{\sigma}{\sqrt{N}} z_{-\alpha/2} &> \mu - \bar{x} > -1 \frac{\sigma}{\sqrt{N}} z_{\alpha/2} \\ \bar{x} - 1 \frac{\sigma}{\sqrt{N}} z_{-\alpha/2} &> \mu > \bar{x} - 1 \frac{\sigma}{\sqrt{N}} z_{\alpha/2} \end{aligned}$$

490 y sabiendo que es simétrica $-z_{\alpha/2} = z_{-\alpha/2}$:

$$\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{N}} < \mu < \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{N}}.$$

491 Supongamos que queremos encontrar el intervalo de confianza de μ al 95% de con-
 492 fianza, es decir, entonces $\alpha = 0.05$. Entonces $z_{\alpha/2} = 1.96$ (de tablas estadísticas).

493 **Ejemplo:** $N = 40$, $\sigma = 0.5^{\circ}\text{C}$, y $\bar{x} = 12.7^{\circ}\text{C}$:

$$\bar{x} - z_{0.025} \frac{\sigma}{\sqrt{N}} < \mu < \bar{x} + z_{0.025} \frac{\sigma}{\sqrt{N}},$$

$$\begin{aligned} [12.7 - (1.96)0.5/\sqrt{40}]^{\circ}\text{C} &< \mu < [12.7 + (1.96)0.5/\sqrt{40}]^{\circ}\text{C} \\ 12.54^{\circ}\text{C} &< \mu < 12.85^{\circ}\text{C} \end{aligned}$$

494 (2) **Intervalo de confianza** para μ ($N < 30$, σ desconocida)

495 Cuando $N < 30$ y σ es desconocida, podemos usar el estadístico t -student
496 para encontrar el intervalo de confianza para μ . Hay un $100 * (1 - \alpha)\%$ que
497 cualquier estadístico t caiga en el intervalo
498

$$t_{-\alpha/2} < \frac{\bar{x} - \mu}{s} \sqrt{N-1} < t_{\alpha/2},$$

$$\bar{x} - t_{\alpha/2} \frac{s}{\sqrt{N-1}} < \mu < \bar{x} + t_{\alpha/2} \frac{s}{\sqrt{N-1}}.$$

499 Si $\alpha = 0.05$, hay un 95% de probabilidad que cualquier estadístico t caiga en el inter-
500 valo

$$t_{-0.025} < \frac{\bar{x} - \mu}{s} \sqrt{N-1} < t_{0.025},$$

501 de lo cual podemos deducir que la verdadera media μ es de esperar con un 95% de
502 confianza que caiga en el intervalo:

$$\bar{x} - t_{0.025} \frac{s}{\sqrt{N-1}} < \mu < \bar{x} + t_{0.025} \frac{s}{\sqrt{N-1}}.$$

503 De forma general, podemos definir el intervalo de confianza como:

$$\mu = \bar{x} \pm t_c \frac{\hat{s}}{\sqrt{N}},$$

504 donde t_c es el valor crítico del estadístico t (límites del intervalo), el cual depende
505 del número de grados de libertad y del nivel de confiabilidad deseado. El intervalo
506 de confianza con el estadístico z , el cual solo es apropiado para tamaños muestrales
507 grandes ($N > 30$) donde la desviación estandar es conocida:

$$\mu = \bar{x} \pm z_c \frac{\sigma}{\sqrt{N}}.$$

508 Observamos que la teoría para tamaños muestrales pequeños reemplaza el estadístico
509 z por el t y utiliza una desviación estandar muestral modificada

$$\hat{s} = \sqrt{\frac{N}{N-1}} s.$$

510 %% {Diferencias entre medias}\%Supongamos dos muestras de tamaño N_1 y N_2

511 extraídas de una población %%con distribución normal con desviaciones estandar
512 %%siguales. Supongamos %%que las medias muestrales son \bar{x}_1 y \bar{x}_2 y las %%desviaciones
513 %%estandar muestrales son s_1 y s_2 . Para comprobar %%la hipótesis nula (H_0) que ambas
514 %%muestras provienen de la misma población, %%es decir $\mu_1 = \mu_2$ y $\sigma_1 = \sigma_2$ podemos
515 %%usar la siguiente expresión

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{N_1} + \frac{1}{N_2}}};$$

516 donde $\nu = N_1 + N_2 - 2$.

517 (3) **Intervalo de confianza** para la diferencia de medias $\mu_1 - \mu_2\}$

518 El teorema central del límite (TCL) para la diferencia de medias muestrales de dos
 519 poblaciones viene dado por

$$\bar{x}_1 - \bar{x}_2 \sim N(\mu_{\bar{x}_1 - \bar{x}_2}, \sigma_{\bar{x}_1 - \bar{x}_2}),$$

520 donde

$$\text{Media : } \mu_{\bar{x}_1 - \bar{x}_2} = \mu_{\bar{x}_1} - \mu_{\bar{x}_2} = \mu_1 - \mu_2$$

$$\text{Varianza : } \sigma_{\bar{x}_1 - \bar{x}_2}^2 = \sigma^2 \bar{x}_1 + \sigma^2 \bar{x}_2 = \sqrt{\frac{\sigma_1^2}{N_1} + \frac{\sigma_2^2}{N_2}}$$

521 **3.1** Desviaciones estandar poblacionales (σ_1 y σ_2) conocidas; μ_1 y μ_2 desconocidas}
 522 (estadístico z):

$$z = \frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{N_1} + \frac{\sigma_2^2}{N_2}}}$$

523 **3.2** Desviaciones estandar poblacionales (σ_1 y σ_2) y medias poblacionales (μ_1 y μ_2)
 524 desconocidas (estadístico t):

$$t = \frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{N_1} + \frac{s_2^2}{N_2}}}$$

525 **3.3** Desviaciones estandar poblacionales (σ_1 y σ_2) desconocidas pero iguales (estadís-
 526 tico t):

527 Supongamos dos muestras de tamaño N_1 y N_2 extraídas de dos poblaciones Nor-
 528 males con desviaciones estándar iguales ($\sigma_1 = \sigma_2$). Supongamos que conocemos
 529 las medias y desviaciones estándar muestrales \bar{x}_1 y \bar{x}_2 y s_1 y s_2 . Para comprobar
 530 la hipótesis nula H_0 que las muestran proceden de la misma población ($\mu_1 = \mu_2$ y
 531 $\sigma_1 = \sigma_2$) usamos el estadístico t-score (o pooled t):

$$t = \frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\hat{s}_d \sqrt{\frac{1}{N_1} + \frac{1}{N_2}}}$$

532 \\\

$$\hat{s}_d = \sqrt{\frac{(N_1 - 1)s_1^2 + (N_2 - 1)s_2^2}{N_1 + N_2 - 2}},$$

533 donde $\nu = N_1 + N_2 - 2$ es el número de grados de libertad.

534 **Ejemplo:** Un ingeniero que diseña instrumentos oceanográficos está ineteresado en
 535 aumentar el tiempo durante el cuál la pintura “antifouling” evita que los microor-
 536 ganismos se peguen y crezcan sobre el instrumento oceanográfico. Se prueban dos
 537 fórmulas de pintura: fórmula 1 estándar y fórmula 2 con un nuevo ingrediente que
 538 aumenta el tiempo de acción.

539 De la experiencia se sabe que la desviación estándar del tiempo de acción de la pin-
 540 tura es de 8 días y ésta variabilidad no se vé afectada por el nuevo ingrediente. Se
 541 pintan 35 instrumentos con la fórmula 1 y otros 35 con la fórmula 2. Los tiempos
 542 promedios de acción del “antifouling” son de 116 días para la fórmula 1 y 112 días
 543 para la fórmula 2. ¿A qué conclusión puede llegar el ingeniero diseñador del instru-
 544 miento sobre la eficacia del nuevo ingrediente, con un nivel de significancia de 0.01?\\

545 $x_1 \equiv$ Tiempo de acción “antifouling” fórmula 1

546 $x_2 \equiv$ Tiempo de acción “antifouling” fórmula 2

547 $x_1 \sim$ Desconocida ($\mu_1, \sigma_1 = 8$ días)

548 $x_2 \sim$ Desconocida ($\mu_2, \sigma_2 = 8$ días)

549 $\bar{x}_1 - \bar{x}_2 \sim N(\mu_1 - \mu_2, \sigma_1/\sqrt{N_1} + \sigma_2/\sqrt{N_2})$ (TCL)

550 $\bar{x}_1 = 116$ días \ $\bar{x}_2 = 112$ días

551 $N_1 = N_2 = 35$ $\alpha = 0.01$

552 $H_0 : \mu_1 - \mu_2 = 0$

553 $H_1 : \mu_1 - \mu_2 \neq 0$

554 El intervalo de confianza de la diferencia de medias $\mu_1 - \mu_2$

$$\bar{x}_1 - \bar{x}_2 - z_{\alpha/2} \left(\frac{\sigma_1}{\sqrt{N_1}} + \frac{\sigma_2}{\sqrt{N_2}} \right) < \mu_1 - \mu_2 < \bar{x}_1 - \bar{x}_2 + z_{\alpha/2} \left(\frac{\sigma_1}{\sqrt{N_1}} + \frac{\sigma_2}{\sqrt{N_2}} \right)$$

$$\bar{x}_1 - \bar{x}_2 - 2.33(1.9124) < \mu_1 - \mu_2 < \bar{x}_1 - \bar{x}_2 + 2.33(1.9124)$$

$$\bar{x}_1 - \bar{x}_2 - 4.4559 < \mu_1 - \mu_2 < \bar{x}_1 - \bar{x}_2 + 4.4559$$

$$4 - 4.4559 < \mu_1 - \mu_2 < 4 + 4.4559,$$

555 y el intervalo de confianza es:

$$-0.4559 < \mu_1 - \mu_2 < 8.4559 \text{ al } 99\% (\alpha = 0.01)$$

$$H_0 : \mu_1 - \mu_2 = 0 \text{ al } 99\%,$$

556 y aceptamos hipótesis nula H_0 .

557 **(4) Intervalo de confianza para la varianza:**

558 Distribución *chi-cuadrada*

559 En ocasiones queremos definir un intervalo de confianza para la varianza muestral.

560 Para ello podemos usar el estadístico *chi-cuadrado*. Definamos

$$\chi^2 = (N - 1) \frac{s^2}{\sigma^2}.$$

561 **Propiedades:**

- 562 • No es simétrica.
- 563 • La forma de la distribución depende de los grados de libertad.
- 564 • A medida que los grados de libertad aumentan (N aumenta), la distribución
565 se parece más a la Normal.
- 566 • $\chi^2 \geq 0$

567 Para definir el intervalo de confianza sabemos que hay un $100*(1-\alpha)\%$ que cualquier
568 estadístico χ^2 caiga en el intervalo

569 $\chi^2_{1-\alpha/2} < (N - 1) \frac{s^2}{\sigma^2} < \chi^2_{\alpha/2},$

$$\frac{1}{\chi^2_{1-\alpha/2}} > \frac{\sigma^2}{(N - 1)s^2} > \frac{1}{\chi^2_{\alpha/2}},$$

570 y entonces:

$$\frac{(N - 1)s^2}{\chi^2_{\alpha/2}} < \sigma^2 < \frac{(N - 1)s^2}{\chi^2_{1-\alpha/2}}.$$

571

Usamos $1 - \alpha/2$ porque la χ^2 es positiva. El valor $\chi_{\alpha/2}^2$ es mayor que el valor $\chi_{1-\alpha/2}^2$. Las tablas dan la probabilidad a la derecha del valor.

Para una población normalmente distribuida con desviación estandar σ , la función de densidad de probabilidad de la *chi-cuadrada* es:

$$F_x(\chi) = f_0 \chi^{\nu-2} e^{-\frac{1}{2}\chi^2}; \nu = N - 1.$$

Puesto que la distribución *chi* es asimétrica y positiva, si $\alpha = 0.05$ (95% confianza), el intervalo de confianza para la varianza σ^2 como

$$\frac{(N-1)s^2}{\chi_{0.025}^2} < \sigma^2 < \frac{(N-1)s^2}{\chi_{0.975}^2},$$

y si leemos en las tablas para $\nu = 9$ grados de libertad:

$$\frac{(N-1)s^2}{19.023} < \sigma^2 < \frac{(N-1)s^2}{2.700},$$

Ejemplo: Supongamos que tenemos $\nu = 9$ grados de libertad de nuestra estimación espectral de la componente meridional de la velocidad de la corriente. Sabemos que la varianza muestral de un pico espectral es $s^2 = 10 \text{ cm s}^2$? Cuál es el intervalo de confianza al 95% para la varianza?

De las tablas estadísticas vemos que para $\nu = N-1 = 9$ grados de libertad, $\chi_{1-\alpha/2}^2 = \chi_{0.095}^2 = 19.02$ y $\chi_{\alpha/2}^2 = \chi_{0.025}^2 = 2.70$. Entonces, el intervalo es:

$$\frac{(9)10}{19.023} < \sigma^2 < \frac{(9)10}{2.700}$$

585

$$4.7 \text{ cm}^2 \text{ s}^{-2} < \sigma^2 < 33.3 \text{ cm}^2 \text{ s}^{-2}$$

{Grados de libertad}\ El número de grados de libertad es el número de muestras independientes N menos el número de parámetros del estadístico que queremos estimar. Por ejemplo en el estadístico t

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{N-1}}} = \frac{\bar{x} - \mu}{\frac{\hat{s}}{\sqrt{N}}}; \hat{s} = \sqrt{\frac{N}{N-1}}s,$$

calculamos la media muestral \bar{y} y la desviación estandar s a partir de los datos, pero la verdadera media μ debe ser estimada, por lo que $\nu = N - 1$. Similarmente en el estadístico *chi-cuadrada*

$$\chi^2 = (N-1) \frac{s^2}{\sigma^2},$$

conocemos la varianza muestral s^2 y el tamaño muestral N , pero debemos estimar la verdadera varianza, y entonces $\nu = N - 1$.

{Estadístico F } Otro estadístico útil para tests espectrales es el estadístico F . Si s_1^2 y s_2^2 son las varianzas de muestras aleatorias independientes de tamaño N_1 y N_2 , tomadas de dos poblaciones Normales con la misma varianza σ^2 , entonces

$$F = \frac{s_1^2}{s_2^2},$$

597 es el valor de una variable aleatoria cuya distribución es F con los parámetros
 598 $\nu_1 = N_1 - 1$ y $\nu_2 = N_2 - 1$. Este estadístico es muy útil en tests de significan-
 599 cia para los picos de los espectros frecuenciales de potencia. Los dos parámetros son
 600 los grados de libertad para las varianzas del cociente; ν_1 para s_1^2 y ν_2 para s_2^2 .

601 {Tests para hipótesis}\| Para usar los test de significancia estadística debemos de
 602 seguir 5 pasos:

- 603 (1) Definir el nivel de confianza
- 604 (2) Definir la hipótesis nulla H_0 y su alternativa H_1
- 605 (3) Definir el estadístico que usaremos
- 606 (4) Definir la región crítica
- 607 (5) Evaluar el estadístico y concluir

608 Es muy importante definir correctamente la hipótesis nula. Es decir, estar seguro
 609 que rechazar la hipótesis nula H_0 implica únicamente la existencia de su alternativa
 610 H_1 . Normalmente la hipótesis nula y su alternativa son mutualmente excluyentes.

611 Ejemplos:

612 H_0 : Las medias de dos muestras son iguales H_1 : Las medias de dos muestras no son
 613 iguales

614 H_0 : El coeficiente de correlación es cero H_1 : El coeficiente de correlación no es cero

615 Ejemplo:\| En una muestra de 41 inviernos la temperatura media de Enero es $5.55^\circ C$
 616 y la desviación es de $0.65^\circ C$? Cuál es el intervalo de confianza al 95% de que la ver-
 617 dadera temperatura media sea esa? \| (1) Nivel de confianza del 95% \| (2) H_0 es que
 618 la media verdadera se encuentra en el intervalo $5.55 \pm \Delta T$ y su alternativa H_1 es que
 619 se encuentra fuera de este intervalo.

620 (3) Usamos el estadístico t .

621 (4) La región crítica es $|t| < t_{0.025}$, lo cual para $\nu = N - 1 = 40$ es $|t| < 2.26$ (leido
 622 de tablas estadísticas). Escrito en términos de intervalo de confianza para la media
 623 poblacional:

$$\bar{x} - 2.0211 \frac{s}{\sqrt{N-1}} < \mu < \bar{x} + 2.0211 \frac{s}{\sqrt{N-1}}$$

624 (5) Si ponemos en números el intervalo obtenemos $5.06 < \mu < 6.03$. Tenemos un 95%
 625 de confianza que la verdadera temperatura media se encuentra en ese intervalo.

626 {Teorema de Bayes:}\| Sea $E_i, i = 1, 2, 3, \dots, n$ un conjunto de n eventos que consti-
 627 tuyen una partición del espacio muestral S

$$\bigcup_{i=1}^n E_i \in S,$$

628 cada uno de los cuales tiene probabilidad positiva de ocurrir $P(E_i) > 0$ para
 629 $i = 1, 2, \dots, n$ y son exclusivos entre si

$$E_i \cap E_j = \emptyset \quad i \neq j.$$

630 Entonces dada la ocurrencia previa de un evento cualquiera B , la probabilidad de
 631 que suceda el evento E_j es

$$P(E_j|B) = \frac{P(B|E_j)P(E_j)}{\sum_{i=1}^n P(B|E_i)P(E_i)}, \quad (7)$$

632 donde

$$P(E_j|E_i) = \frac{P(E_i \cap E_j)}{P(E_i)},$$

633 es la probabilidad condicional, es decir, la probabilidad que ocurra el evento E_j si
 634 previamente ha ocurrido el evento E_i y $P(E_i \cap E_j)$ es la probabilidad que ambos
 635 eventos ocurran, i.e. la intersección de dos eventos. La intersección se puede escribir

$$P(E_i \cap E_j) = P(E_j|E_i) * P(E_i) = P(E_i|E_j) * P(E_j).$$

636 Si ambos eventos son independientes (no intersecccionan) tal que $P(E_i|E_j) = P(E_i)$
 637 obtenemos

$$P(E_i \cap E_j) = P(E_i) * P(E_j),$$

638 es decir, la definición de independencia estadística entre eventos.

639 {Ejemplo teorema de Bayes:} Imaginemos que queremos saber si una muestra de
 640 agua contiene diatomeas o no. La probabilidad de que una muestra de agua tomada
 641 al azar en la bahía de Todos Santos tenga diatomeas es de 1/100 ($P(D) = 0.01$).
 642 La probabilidad de que si hay diatomeas el test de negativo es cero ($P(+|D) = 1$)
 643 y la probabilidad de que el test de un falso positivo es del 5% ($P(+|noD) = 0.05$).
 644 Si agarramos una muestra de agua y da positivo, ¿Cuál es la probabilidad de que
 645 hayan diatomeas? Intuitivamente, sabemos que existe un 5% de probabilidad de que
 646 el test sea de un falso positivo y por lo tanto, un 95% de que si da positivo tenga di-
 647 atomeas en la muestra de agua. Veamos que nos dice el teorema de Bayes. Sabemos
 648 que $P(D) = 0.01$, $P(+|D) = 1$, y $P(+|noD) = 0.05$. Si usamos el teorema de Bayes:

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|noD)P(noD)} = \frac{1 * 0.01}{1 * 0.01 + 0.05 * 0.99} \sim \frac{1}{6}.$$

649 En verdad solamente existe 1 probabilidad de 6 (~ 16%) que si el test es posi-
 650 tivo existan diatomeas. De cada 100 muestras solamente 1 tiene diatomeas y
 651 $5\% * 100 = 0.05 * 100 = 5$ muestras de las 100 dan positivo y no tienen diatomeas.
 652 Por ello, sabiendo que la muestra que tiene diatomeas dio positivo, de 6 positivos,
 653 solamente 1 es cierto.

Table of the Chi-Squared Distribution.

v	0.995	0.990	0.975	0.950	0.900	0.100	0.050	0.025	0.010	0.005
1	0.000	0.000	0.001	0.004	0.016	2.706	3.841	5.024	6.635	7.879
2	0.010	0.020	0.051	0.103	0.211	4.605	5.991	7.378	9.210	10.597
3	0.072	0.115	0.216	0.352	0.584	6.251	7.815	9.348	11.345	12.838
4	0.207	0.297	0.484	0.711	1.064	7.779	9.488	11.143	13.277	14.860
5	0.412	0.554	0.831	1.145	1.610	9.236	11.070	12.832	15.086	16.750
6	0.676	0.872	1.237	1.635	2.204	10.645	12.592	14.449	16.812	18.548
7	0.989	1.239	1.690	2.167	2.833	12.017	14.067	16.013	18.475	20.278
8	1.344	1.647	2.180	2.733	3.490	13.362	15.507	17.535	20.090	21.955
9	1.735	2.088	2.700	3.325	4.168	14.684	16.919	19.023	21.666	23.589
10	2.156	2.558	3.247	3.940	4.865	15.987	18.307	20.483	23.209	25.188
11	2.603	3.053	3.816	4.575	5.578	17.275	19.675	21.920	24.725	26.757
12	3.074	3.571	4.404	5.226	6.304	18.549	21.026	23.337	26.217	28.300
13	3.565	4.107	5.009	5.892	7.041	19.812	22.362	24.736	27.688	29.819
14	4.075	4.660	5.629	6.571	7.790	21.064	23.685	26.119	29.141	31.319
15	4.601	5.229	6.262	7.261	8.547	22.307	24.996	27.488	30.578	32.801
16	5.142	5.812	6.908	7.962	9.312	23.542	26.296	28.845	32.000	34.267
17	5.697	6.408	7.564	8.672	10.085	24.769	27.587	30.191	33.409	35.718
18	6.265	7.015	8.231	9.390	10.865	25.989	28.869	31.526	34.805	37.156
19	6.844	7.633	8.907	10.117	11.651	27.204	30.144	32.852	36.191	38.582
20	7.434	8.260	9.591	10.851	12.443	28.412	31.410	34.170	37.566	39.997
21	8.034	8.897	10.283	11.591	13.240	29.615	32.671	35.479	38.932	41.401
22	8.643	9.542	10.982	12.338	14.041	30.813	33.924	36.781	40.289	42.796
23	9.260	10.196	11.689	13.091	14.848	32.007	35.172	38.076	41.638	44.181
24	9.886	10.856	12.401	13.848	15.659	33.196	36.415	39.364	42.980	45.558
25	10.520	11.524	13.120	14.611	16.473	34.382	37.652	40.646	44.314	46.928
26	11.160	12.198	13.844	15.379	17.292	35.563	38.885	41.923	45.642	48.290
27	11.808	12.878	14.573	16.151	18.114	36.741	40.113	43.195	46.963	49.645
28	12.461	13.565	15.308	16.928	18.939	37.916	41.337	44.461	48.278	50.994
29	13.121	14.256	16.047	17.708	19.768	39.087	42.557	45.722	49.588	52.335
30	13.787	14.953	16.791	18.493	20.599	40.256	43.773	46.979	50.892	53.672
40	20.707	22.164	24.433	26.509	29.051	51.805	55.758	59.342	63.691	66.766
50	27.991	29.707	32.357	34.764	37.689	63.167	67.505	71.420	76.154	79.490
75	47.206	49.475	52.942	56.054	59.795	91.061	96.217	100.839	106.393	110.285
100	67.328	70.065	74.222	77.929	82.358	118.498	124.342	129.561	135.807	140.170

Table of the F-statistic for a probability level of 0.01 (Denominator to left, Numerator across top)

d.f.	1	2	3	4	5	6	7	8	9	10	20	30	40	50	75	100
1	161	199	5404	5624	5764	5859	5928	5981	6022	6056	6209	6260	6286	6302	6324	6334
2	18.51	19.00	99.16	99.25	99.30	99.33	99.36	99.38	99.39	99.40	99.45	99.47	99.48	99.48	99.48	99.49
3	10.13	9.55	29.46	28.71	28.24	27.91	27.67	27.49	27.34	27.23	26.69	26.50	26.41	26.35	26.28	26.24
4	7.71	6.94	16.69	15.98	15.52	15.21	14.98	14.80	14.66	14.55	14.02	13.84	13.75	13.69	13.61	13.58
5	6.61	5.79	12.06	11.39	10.97	10.67	10.46	10.29	10.16	10.05	9.55	9.38	9.29	9.24	9.17	9.13
6	5.99	5.14	9.78	9.15	8.75	8.47	8.26	8.10	7.98	7.87	7.40	7.23	7.14	7.09	7.02	6.99
7	5.59	4.74	8.45	7.85	7.46	7.19	6.99	6.84	6.72	6.62	6.16	5.99	5.91	5.86	5.79	5.75
8	5.32	4.46	7.59	7.01	6.63	6.37	6.18	6.03	5.91	5.81	5.36	5.20	5.12	5.07	5.00	4.96
9	5.12	4.26	6.99	6.42	6.06	5.80	5.61	5.47	5.35	5.26	4.81	4.65	4.57	4.52	4.45	4.41
10	4.96	4.10	6.55	5.99	5.64	5.39	5.20	5.06	4.94	4.85	4.41	4.25	4.17	4.12	4.05	4.01
11	4.84	3.98	6.22	5.67	5.32	5.07	4.89	4.74	4.63	4.54	4.10	3.94	3.86	3.81	3.74	3.71
12	4.75	3.89	5.95	5.41	5.06	4.82	4.64	4.50	4.39	4.30	3.86	3.70	3.62	3.57	3.50	3.47
13	4.67	3.81	5.74	5.21	4.86	4.62	4.44	4.30	4.19	4.10	3.66	3.51	3.43	3.38	3.31	3.27
14	4.60	3.74	5.56	5.04	4.69	4.46	4.28	4.14	4.03	3.94	3.51	3.35	3.27	3.22	3.15	3.11
15	4.54	3.68	5.42	4.89	4.56	4.32	4.14	4.00	3.89	3.80	3.37	3.21	3.13	3.08	3.01	2.98
16	4.49	3.63	5.29	4.77	4.44	4.20	4.03	3.89	3.78	3.69	3.26	3.10	3.02	2.97	2.90	2.86
17	4.45	3.59	5.19	4.67	4.34	4.10	3.93	3.79	3.68	3.59	3.16	3.00	2.92	2.87	2.80	2.76
18	4.41	3.55	5.09	4.58	4.25	4.01	3.84	3.71	3.60	3.51	3.08	2.92	2.84	2.78	2.71	2.68
19	4.38	3.52	5.01	4.50	4.17	3.94	3.77	3.63	3.52	3.43	3.00	2.84	2.76	2.71	2.64	2.60
20	4.35	3.49	4.94	4.43	4.10	3.87	3.70	3.56	3.46	3.37	2.94	2.78	2.69	2.64	2.57	2.54
21	4.32	3.47	4.87	4.37	4.04	3.81	3.64	3.51	3.40	3.31	2.88	2.72	2.64	2.58	2.51	2.48
22	4.30	3.44	4.82	4.31	3.99	3.76	3.59	3.45	3.35	3.26	2.83	2.67	2.58	2.53	2.46	2.42
23	4.28	3.42	4.76	4.26	3.94	3.71	3.54	3.41	3.30	3.21	2.78	2.62	2.54	2.48	2.41	2.37
24	4.26	3.40	4.72	4.22	3.90	3.67	3.50	3.36	3.26	3.17	2.74	2.58	2.49	2.44	2.37	2.33
25	4.24	3.39	4.68	4.18	3.85	3.63	3.46	3.32	3.22	3.13	2.70	2.54	2.45	2.40	2.33	2.29
26	4.23	3.37	4.64	4.14	3.82	3.59	3.42	3.29	3.18	3.09	2.66	2.50	2.42	2.36	2.29	2.25
27	4.21	3.35	4.60	4.11	3.78	3.56	3.39	3.26	3.15	3.06	2.63	2.47	2.38	2.33	2.26	2.22
28	4.20	3.34	4.57	4.07	3.75	3.53	3.36	3.23	3.12	3.03	2.60	2.44	2.35	2.30	2.23	2.19
29	4.18	3.33	4.54	4.04	3.73	3.50	3.33	3.20	3.09	3.00	2.57	2.41	2.33	2.27	2.20	2.16
30	4.17	3.32	4.51	4.02	3.70	3.47	3.30	3.17	3.07	2.98	2.55	2.39	2.30	2.25	2.17	2.13
40	4.08	3.23	4.31	3.83	3.51	3.29	3.12	2.99	2.89	2.80	2.37	2.20	2.11	2.06	1.98	1.94
50	4.03	3.18	4.20	3.72	3.41	3.19	3.02	2.89	2.78	2.70	2.27	2.10	2.01	1.95	1.87	1.82
75	3.97	3.12	4.05	3.58	3.27	3.05	2.89	2.76	2.65	2.57	2.13	1.96	1.87	1.81	1.72	1.67
100	3.94	3.09	3.98	3.51	3.21	2.99	2.82	2.69	2.59	2.50	2.07	1.89	1.80	1.74	1.65	1.60

Table of the F-statistic for a significance level of 0.05 (Denominator to left, Numerator across top)

d.f.	1	2	3	4	5	6	7	8	9	10	20	30	40	50	75	100
1	161.45	199.50	215.71	224.58	230.16	233.99	236.77	238.88	240.54	241.88	248.02	250.10	251.14	251.77	252.62	253.04
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40	19.45	19.46	19.47	19.48	19.48	19.49
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.66	8.62	8.59	8.58	8.56	8.55
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.80	5.75	5.72	5.70	5.68	5.66
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.56	4.50	4.46	4.44	4.42	4.41
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	3.87	3.81	3.77	3.75	3.73	3.71
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.44	3.38	3.34	3.32	3.29	3.27
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.15	3.08	3.04	3.02	2.99	2.97
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	2.94	2.86	2.83	2.80	2.77	2.76
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.77	2.70	2.66	2.64	2.60	2.59
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.65	2.57	2.53	2.51	2.47	2.46
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.54	2.47	2.43	2.40	2.37	2.35
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.46	2.38	2.34	2.31	2.28	2.26
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.39	2.31	2.27	2.24	2.21	2.19
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.33	2.25	2.20	2.18	2.14	2.12
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.28	2.19	2.15	2.12	2.09	2.07
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.23	2.15	2.10	2.08	2.04	2.02
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.19	2.11	2.06	2.04	2.00	1.98
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42	2.38	2.16	2.07	2.03	2.00	1.96	1.94
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.12	2.04	1.99	1.97	1.93	1.91
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37	2.32	2.10	2.01	1.96	1.94	1.90	1.88
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34	2.30	2.07	1.98	1.94	1.91	1.87	1.85
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32	2.27	2.05	1.96	1.91	1.88	1.84	1.82
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30	2.25	2.03	1.94	1.89	1.86	1.82	1.80
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.28	2.24	2.01	1.92	1.87	1.84	1.80	1.78
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.27	2.22	1.99	1.90	1.85	1.82	1.78	1.76
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.25	2.20	1.97	1.88	1.84	1.81	1.76	1.74
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.24	2.19	1.96	1.87	1.82	1.79	1.75	1.73
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.28	2.22	2.18	1.94	1.85	1.81	1.77	1.73	1.71
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	1.93	1.84	1.79	1.76	1.72	1.70
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	1.84	1.74	1.69	1.66	1.61	1.59
50	4.03	3.18	2.79	2.56	2.40	2.29	2.20	2.13	2.07	2.03	1.78	1.69	1.63	1.60	1.55	1.52
75	3.97	3.12	2.73	2.49	2.34	2.22	2.13	2.06	2.01	1.96	1.71	1.61	1.55	1.52	1.47	1.44
100	3.94	3.09	2.70	2.46	2.31	2.19	2.10	2.03	1.97	1.93	1.68	1.57	1.52	1.48	1.42	1.39

$$P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}, k=1,2,3,\dots,n \quad (1.47)$$

Example: What is the probability of getting more than 15 heads in 20 tosses of a fair coin? Answer:

$$\sum_{k=16}^{20} \binom{20}{k} 0.5^k (1-0.5)^{20-k} = 0.006$$

The binomial distribution is helpful in assessing “field significance”, the significance of multiple tests as when an array of variables are tested against the same hypothesis. An example would be correlating the sunspot index with a map of pressure at many points over the earth. How many individual “significant” events do you expect to get by chance in such cases. As an example, consider the plot below, which shows for N tries of a test at the p=0.05 significance level, what the binomial distribution (1.47) says about how many you should get by chance.

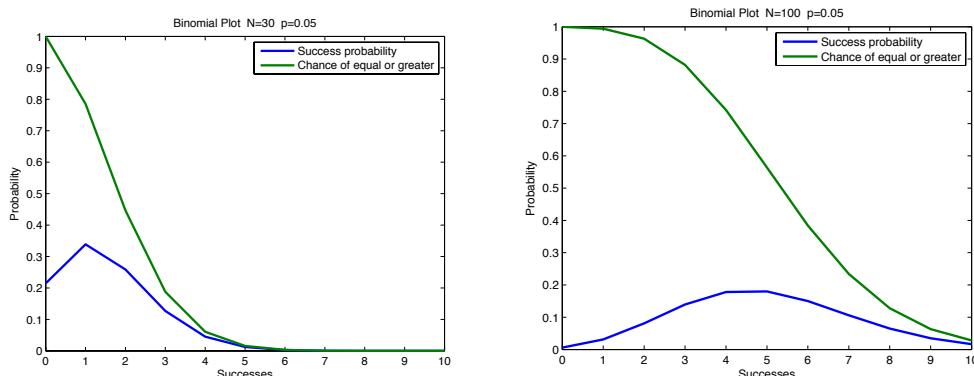


Figure Blue line shows probability of a given number of successes in N tries (N=30 on left and N=100 on right) where the probability of each event succeeding is p=0.05. Green line shows the probability of getting the number of successes or more.

Note that the probability of getting 5 successes or more in 30 tries is less than 0.05 and getting 10 successes or more in 100 tries is less than 0.05. That is 16.7% are successes for 30 tries and only 10% are successes for 100 tries at same probability level. For smaller samples, the fraction of total tries that can succeed by chance is greater. Even for 100 tries, 10% can succeed by chance, where the probability of each individual occurrence is p=5%. The most likely outcome is shown by the peak of the blue line and is what you expect, about 5% of the chances will succeed. But the chances of getting significantly more than that are quite good, and ten or fifteen percent of the field points could succeed by chance at the 5% level (See Wilks 2006, and Livezey and Chen 1983).

If you did the calculations above by hand you would find it tedious. This gets worse when the sample is larger. To assist in this it is useful to use the following Normal Approximation to the Binomial.

Normal Approximation to the Binomial (DeMoivre-Laplace)

From the central limit theorem, it can be shown that the distribution of sample means approaches the Normal Distribution, even if the population from which the means are derived is not normally distributed. This is also true for the Binomial distribution, for which values have a probability of being either zero or one, but nothing else. The distribution of sample means from a binomial population is nonetheless normally distributed about its mean value of 0.5.

Here is a Java Applet that allows you to play with the Normal Approximation http://www.ruf.rice.edu/~lane/stat_sim/normal_approx/. Try calculating the probability of getting more than 40 hits in a sample of 60 with P=0.5. That's 40 or more heads out of 60 coin tosses. You can compare the exact and approximate probabilities. Try this with small samples. For example, try 4 or more heads out of 6 tosses.

DeMoivre-Laplace Theorem.

X is a binomial variable defined on n independent trials each having success probability p . Then for any numbers a and b ,

$$\lim_{n \rightarrow \infty} P\left(a < \frac{X - np}{\sqrt{np(1-p)}} < b\right) = \frac{1}{\sqrt{2\pi np(1-p)}} \int_a^b e^{-x^2/2} dx \quad (1.48)$$

This means that the statistic, $\frac{X - np}{\sqrt{np(1-p)}}$, has the Normal distribution. We can use this fact to simplify the solution of binomial problems, as illustrated in the example below.

Example of the Normal approximation to the Binomial: An earthquake forecaster has forecast 200 earthquakes. How many times in 200 trials must she be successful so we can say with 95% certainty that she has nonzero skill?

The null hypothesis is that she has no skill and the confidence level is 0.05, or 95%. We then want,

$$P(s > s^* | H_0) = 0.025 = \sum_{s=s^*}^{200} \binom{200}{s} \left(\frac{1}{2}\right)^s \left(1 - \frac{1}{2}\right)^{200-s}$$

Solving this equation for $s > s^*$, the number of occurrences necessary to leave only a 0.025 probability to the right, is extremely tedious to do by hand, which nobody these days would do. However, we can use the Normal approximation to the Binomial to convert this to the problem,

$$P(s > s^* | H_0) = P\left(\frac{s - np}{\sqrt{np(1-p)}} > \frac{s^* - np}{\sqrt{np(1-p)}}\right) = P\left(Z > \frac{s^* - np}{\sqrt{np(1-p)}}\right)$$

Now $P(Z > 1.96) = 0.025$ (two-tailed 95%), so we want,

$$\frac{s - np}{\sqrt{np(1-p)}} > 1.96, \text{ or } s > 114$$

Where we have inserted $n=200$ and $p=0.5$ to get the numerical value shown. So to pass a no-skill test on a sample of this size, the forecaster must be right 57% of the time. Of course, this level of skill, while significantly different from zero, may not be practically useful.

1.8 Non-Parametric Statistical Tests

The statistical tests applied above mostly assume that the samples come from populations for which the statistical distributions are known, or assumed, a priori. We very often assume that the statistics we are testing are Normally distributed, so we can use the shape of the Normal distribution in our tests. Tests have also been developed that do not require the assumption of a theoretical distribution. These are called ‘non-parametric’ or ‘distribution-free’ statistical tests. This approach can be easily illustrated with the Signs Test.

660 3 Repaso de álgebra Lineal

661 Una matriz es un elemento matemático compuesto por filas y columnas. Una matriz
 662 rectangular de dimensiones $m \times n$ se define como

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}.$$

663 Un elemento de la matriz \mathbf{A} queda definida como $\mathbf{A} = [a_{ij}]$, $i = 1, 2, \dots, m; j =$
 664 $1, 2, \dots, n$. El primer índice i denota filas y el segundo j columnas.

665 {Definición} Un vector es una matriz con solo una columna ($m \times 1$)

$$\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ \vdots \\ v_m \end{pmatrix}.$$

666 {Vectores ortogonales}

667 Sean dos vectores $\mathbf{u} = [u_1, u_2, \dots, u_N]$ y $\mathbf{v} = [v_1, v_2, \dots, v_N]$ de longitud N , decimos
 668 que son ortogonales si

$$\mathbf{u} \cdot \mathbf{v} = (\mathbf{u}, \mathbf{v}) = \sum_{i=1}^N u_i v_i = \mathbf{u}^T \mathbf{v} = 0.$$

669 {Norma, módulo, longitud de un vector}

670 Sea el vector $\mathbf{u} = [u_1, u_2, \dots, u_N]$, entonces la norma de dicho vector se define como

$$\|\mathbf{u}\| = |\mathbf{u}| = \sqrt{u_1^2 + u_2^2 + \dots + u_N^2} = (\mathbf{u}, \mathbf{u})^{1/2} = (\mathbf{u}^T \mathbf{u})^{1/2}.$$

671 En general se puede obtener un {vector unitario} (de módulo = 1) dividiendo el vec-
 672 tor por su norma:

$$\mathbf{u}_I = \frac{\mathbf{u}}{\|\mathbf{u}\|}.$$

673 Vectores ortonormales

674 Dos vectores ortogonales \mathbf{u} y \mathbf{v} si tienen módulo la unidad, entonces se denominan
 675 vectores ortonormales.

676 {Suma de vectores}

677 La suma de 2 vectores $\mathbf{u} = [u_1, u_2, \dots, u_N]$ y $\mathbf{v} = [v_1, v_2, \dots, v_N]$ de longitud N se de-
 678 fine como

$$\mathbf{u} + \mathbf{v} = [u_1 + v_1, u_2 + v_2, \dots, u_N + v_N] = \sum_{i=1}^N u_i + v_i.$$

679 {Combinación lineal de vectores}

680 Un vector \mathbf{y} se dice que es combinación lineal de un conjunto de vectores $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$
 681 si se puede expresar como la suma de los N vectores multiplicados por N coefi-
 682 cientes escalares a_1, a_2, \dots, a_N :

$$\mathbf{y} = a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \dots + a_N \mathbf{x}_N = \sum_{i=1}^N a_i \mathbf{x}_i.$$

683 {Independencia lineal}

684 Un conjunto de vectores $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N$ se dice que es linealmente independiente si
 685 existe una combinación lineal finita de los vectores del conjunto tal que:

$$\sum_{i=1}^N a_i \mathbf{y}_i = a_1 \mathbf{y}_1 + a_2 \mathbf{y}_2 + \dots + a_N \mathbf{y}_N = 0,$$

686 que se satisface cuando no todos los coeficientes son cero. En caso contrario, se dice
 687 que son linealmente dependientes.

688 Ortonormalización Gram-Schmidt

689 Es un método para convertir un conjunto de vectores \mathbf{v} en vectores ortonormales.
 690 De forma general el proceso definido por Gram-Schmidt para ortonormalizar el vec-
 691 tor ortogonal \mathbf{w}_k a partir de un conjunto de vectores ortonormales $\mathbf{u}_i = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_{k-1}]$
 692 se define como:

$$\mathbf{w}_k = \mathbf{v}_k - \sum_{i=1}^{k-1} \mathbf{u}_i \cdot \mathbf{v}_k \mathbf{u}_i.$$

$\mathbf{v}_k \equiv$ vectores originales

$\mathbf{u}_i \equiv$ vectores ortonormales

$\mathbf{w}_k \equiv$ vectores ortogonales a \mathbf{u}_j

693 Ejemplo:

694 Convertir el conjunto de vectores de la base A en una base ortonormal:

$$\mathbf{A} = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 2 & 0 \\ 2 & 3 & 1 \\ 1 & 1 & 0 \end{pmatrix}.$$

695 Primero normalizamos el primer vector columna \mathbf{v}_1 :

$$\mathbf{u}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|} = \left[\frac{1}{\sqrt{6}}, 0, \frac{2}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right].$$

696 (1er vector ortonormal)

697 Ahora usamos la fórmula de arriba para encontrar el vector \mathbf{w}_2 ortogonal a \mathbf{u}_1

$$\begin{aligned}\mathbf{w}_2 &= \mathbf{v}_2 - \mathbf{u}_1 \cdot \mathbf{v}_2 \mathbf{u}_1 = [2, 2, 3, 1] - \left[\frac{1}{\sqrt{6}}, 0, \frac{2}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right] \cdot [2, 2, 3, 1] \left[\frac{1}{\sqrt{6}}, 0, \frac{2}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right] = \\ &= [2, 2, 3, 1] - \left(\frac{9}{\sqrt{6}} \right) \left[\frac{1}{\sqrt{6}}, 0, \frac{2}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right] = [2, 2, 3, 1] - \left[\frac{3}{2}, 0, \frac{3}{2}, \frac{3}{2} \right] = \left[\frac{1}{2}, 2, 0, \frac{-1}{2} \right].\end{aligned}$$

698 (vector ortogonal a u_1)

699 Normalizamos \mathbf{w}_2 para obtener el primer vector ortonormal a \mathbf{u}_1

$$\mathbf{u}_2 = \frac{\mathbf{w}_2}{\|\mathbf{w}_2\|} = \left[\frac{\sqrt{2}}{6}, \frac{2\sqrt{2}}{3}, 0, \frac{-\sqrt{2}}{6} \right]$$

700 (2o vector ortonormal)

701 Ahora calculamos \mathbf{w}_3 en términos de \mathbf{u}_1 y \mathbf{u}_2

$$\mathbf{w}_3 = \mathbf{v}_3 - \mathbf{u}_1 \cdot \mathbf{v}_3 \mathbf{u}_1 - \mathbf{u}_2 \cdot \mathbf{v}_3 \mathbf{u}_2 = \left[\frac{4}{9}, \frac{-2}{9}, 0, \frac{-4}{9} \right],$$

702 (vector ortogonal a u_1 y u_2) \ \ y si normalizamos

$$\mathbf{u}_3 = \left[\frac{2}{3}, \frac{-1}{3}, 0, \frac{-2}{3} \right].$$

703 (3er vector ortonormal)

704 La matriz o conjunto de vectores ortonormal es

$$\mathbf{A} = \begin{pmatrix} \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{6} & \frac{2}{3} \\ 0 & \frac{2\sqrt{2}}{3} & \frac{-1}{3} \\ \frac{\sqrt{6}}{3} & 0 & 0 \\ \frac{\sqrt{6}}{6} & \frac{-\sqrt{2}}{6} & \frac{-2}{3} \end{pmatrix}$$

705 (base ortonormal)

706 Aplicación lineal

707 Sean dos espacios vectoriales V y W , decimos que una aplicación $f : V \rightarrow W$ es lineal si la ‘imagen’ de la combinación lineal es la combinación lineal de las imágenes.
708 Es decir,

$$f(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha f(\mathbf{u}) + \beta f(\mathbf{v}).$$

710 La imagen de una aplicación es el resultado de aplicar al vector una aplicación.

711 Ejemplos:

712 (1) La aplicación $f : R^3 \rightarrow R^2$ definida por $f(x, y, z) = (x + y, y + 2z)$ es lineal.

713 Demostración: Definimos $\mathbf{u} = [u_1, u_2, u_3]$ y $\mathbf{v} = [v_1, v_2, v_3]$. Entonces f es lineal si

$$f(\alpha(u_1, u_2, u_3) + \beta(v_1, v_2, v_3)) = \alpha f(u_1, u_2, u_3) + \beta f(v_1, v_2, v_3) =$$

$$f(\alpha u_1 + \beta v_1, \alpha u_2 + \beta v_2, \alpha u_3 + \beta v_3) = \alpha[u_1 + u_2, u_2 + 2u_3] + \beta[v_1 + v_2, v_2 + 2v_3]$$

$$[\alpha u_1 + \beta v_1 + \alpha u_2 + \beta v_2, \alpha u_2 + \beta v_2 + 2(\alpha u_3 + \beta v_3)] = [\alpha u_1 + \alpha u_2 + \beta v_1 + \beta v_2, \alpha u_2 + 2\alpha u_3 + \beta v_2 + 2\beta v_3]$$

715 (2) La aplicación $f: R^3 \rightarrow R^2$ definida por $f(x, y, z) = (x + y + 1, y + 2z)$ no es
716 lineal.

717 (3) La aplicación $\mathbf{R}: R^2 \rightarrow R^2$ definida por

$$\mathbf{x}' = \mathbf{R}\mathbf{x},$$

$$\mathbf{R} = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix},$$

718 rota el vector un ángulo θ en sentido contrario a las agujas del reloj. Si queremos
719 cambiar el sentido de la rotación solo debemos tomar el signo de θ negativo. Aquí \mathbf{x}'
720 es el vector rotado o la imagen de la aplicación rotación.

721 Matriz Identidad

722 Se define la matriz identidad \mathbf{I} como una matriz diagonal compuesta por unos

$$\mathbf{I} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

723 El producto matricial de cualquier matriz \mathbf{A} por la matriz identidad \mathbf{I} es igual a la
724 matriz original

$$\mathbf{AI} = \mathbf{A}.$$

725 {Matriz transpuesta}

726 Sea \mathbf{A} una matriz $m \times n$ con elementos $[a_{ij}]$ para $i = 1, 2, \dots, m; j = 1, 2, \dots, n$. Se de-
727 fine el elemento de su transpuesta como

$$\mathbf{A}^T = [a_{ji}].$$

728 La inversa de la matriz transpuesta es

$$(\mathbf{A}^T)^{-1} = \mathbf{A},$$

729 si \mathbf{A} es ortogonal.

730 Demostración:

$$(\mathbf{A}^T)^{-1} = \mathbf{A}$$

$$\mathbf{A}^T (\mathbf{A}^T)^{-1} = \mathbf{A}^T \mathbf{A} = \mathbf{I}$$

$$\mathbf{A} \mathbf{A}^T (\mathbf{A}^T)^{-1} = \mathbf{A} \mathbf{I}$$

733 Matriz Ortogonal

734 Una matriz \mathbf{A} es ortogonal si $\mathbf{A}\mathbf{A}^T = \mathbf{A}^T\mathbf{A} = \mathbf{I}$.

735 Matriz Diagonal

736 Una matriz es diagonal si únicamente contiene algunos elementos diferentes de cero
737 en la diagonal principal (ceros en la matriz triangular superior e inferior).

$$\mathbf{D} = \begin{pmatrix} a_{11} & 0 & 0 \\ 0 & a_{22} & 0 \\ 0 & 0 & a_{33} \end{pmatrix}$$

738 Matriz Simétrica

739 Una matriz simétrica se define como aquella matriz \mathbf{A} tal que sea igual a su traspuesta

$$\mathbf{A} = \mathbf{A}^T \quad (a_{ij} = a_{ji})$$

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & a_{31} \\ a_{12} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$$

740 Matriz Antisimétrica

741 Una matriz antisimétrica se define como aquella matriz \mathbf{A} tal que sea igual a su
742 traspuesta

$$\mathbf{A} = -\mathbf{A}^T \quad (a_{ij} = -a_{ji})$$

$$\mathbf{A} = \begin{pmatrix} 0 & a_{12} & a_{13} \\ -a_{12} & 0 & a_{23} \\ -a_{13} & -a_{23} & 0 \end{pmatrix}$$

743 **NOTA:** Cualquier matriz \mathbf{A} se puede descomponer en una parte simétrica y otra
744 antisimétrica:

$$A = \frac{1}{2}(\mathbf{A} + \mathbf{A}^T) + \frac{1}{2}(\mathbf{A} - \mathbf{A}^T).$$

745 Matriz Singular

746 Una matriz singular es aquella matriz cuadrada cuyo determinante es igual a cero.
747 Las matrices singulares no tienen matriz inversa. \ \ Ejemplo:

$$\mathbf{S} = \begin{pmatrix} 3 & 2 \\ 6 & 4 \end{pmatrix}$$

748 Si nos fijamos las 2 filas de la matriz singular \mathbf{S} son linealmente dependientes, es
749 decir, podemos recuperar la segunda fila multiplicando la primera fila por 2. Si la
750 matriz tiene columnas o filas linealmente dependientes, el determinante es cero.

751 Si \mathbf{A} es ortogonal

$$752 \quad \mathbf{A}^{-1} = \mathbf{A}^T$$

$$753 \quad \mathbf{A}^{-1}(\mathbf{A}^T)^{-1} = \mathbf{I}$$

$$754 \quad \mathbf{A}^{-1} \underbrace{(\mathbf{A}^T)^{-1}(\mathbf{A}^T)}_{\mathbf{I}} = \mathbf{A}^T$$

755 Una matriz cualquiera se puede convertir en matriz cuadrada si es multiplicada por su transpuesta.

756 Determinante de una matriz

757 El determinante de una matriz \mathbf{A} 3×3 se puede calcular como

$$758 \quad |\mathbf{A}| = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - (a_{31}a_{22}a_{13} + a_{32}a_{23}a_{11} + a_{33}a_{21}a_{12}).$$

759 Para matrices de orden superior se puede utilizar la formula de adjuntos. El determi-
760 nante de una matriz $n \times n$ es el producto escalar entre cualquier fila o columna con sus adjuntos

$$761 \quad |\mathbf{A}| = a_{i1}C_{i1} + a_{i2}C_{i2} + \dots + a_{in}C_{in},$$

762 donde los adjuntos C_{ij} son subdeterminantes (de orden $n-1$, sin contar la columna j y fila i) con el signo adecuado

$$C_{ij} = (-1)^{i+j}|\mathbf{M}_{ij}|.$$

763 Rango de una matriz

764 Definición 1: El rango de una matriz se define como el número de filas o columnas
765 de la matriz que son linealmente independientes.

766 Definición 2: El orden de la mayor submatriz cuadrada no nula

767 Así para calcular el rango debemos de hacer cero todos los elementos posibles de la
768 matriz hasta obtener una submatriz no nula que nos indicará el rango de la matriz.

$$\left[\begin{array}{ccc} 1 & 2 & 1 \\ -2 & -3 & 1 \\ 3 & 5 & 0 \end{array} \right] \xrightarrow[2r_1+r_2]{\substack{\rightarrow \\ -3r_1+r_3}} \left[\begin{array}{ccc} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 3 & 5 & 0 \end{array} \right] \xrightarrow[-3r_1+r_3]{\substack{\rightarrow \\ r_2+r_3}} \left[\begin{array}{ccc} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 0 & -1 & -3 \end{array} \right] \xrightarrow[r_2+r_3]{\substack{\rightarrow \\ -2r_2+r_1}} \left[\begin{array}{ccc} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 0 \end{array} \right] \xrightarrow[-2r_2+r_1]{\substack{\rightarrow \\ -2r_2+r_1}} \left[\begin{array}{ccc} 1 & 0 & -5 \\ 0 & 1 & 3 \\ 0 & -1 & -3 \end{array} \right],$$

769 y entonces el rango de la matriz es 2. El rango lo podíamos haber encontrado simpli-
770 mente viendo que sustrayendo la segunda fila de la matriz a la primera obtenemos la
771 tercera fila; solamente hay 2 vectores linealmente independientes.

772 Matriz inversa

773 La matriz cuadrada \mathbf{A} es invertible si existe una matriz \mathbf{A}^{-1} tal que

$$774 \quad \mathbf{A}^{-1}\mathbf{A} = \mathbf{I} \text{ and } \mathbf{A}\mathbf{A}^{-1} = \mathbf{I}.$$

775 Proposición: Si \mathbf{A} es invertible entonces la única solución de $\mathbf{Ax} = \mathbf{b}$ es

$$776 \quad \mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

775 **Proposición:** Si \mathbf{A} es una matriz cuadrada de dimensión 2×2 y $|\mathbf{A}| = a_{11}a_{22} - a_{12}a_{21}$ no es cero, entonces
776

$$\mathbf{A}^{-1} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}^{-1} = \frac{1}{|\mathbf{A}|} \begin{pmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{pmatrix}.$$

777 **Cálculo de matriz inversa con método Gauss-Jordan**

778 El método de Gauss-Jordan usa la siguiente identidad matemática $[\mathbf{A}|\mathbf{I}] \rightarrow [\mathbf{I}|\mathbf{A}^{-1}]$.
779 **Ejemplo:** Calcula la matriz inversa de

$$\begin{pmatrix} 2 & 3 \\ 4 & 7 \end{pmatrix}$$

$$[\mathbf{A}\mathbf{I}] = \begin{pmatrix} 2 & 3 & 1 & 0 \\ 4 & 7 & 0 & 1 \end{pmatrix} \xrightarrow[-2r_1+r_2]{} \begin{pmatrix} 2 & 3 & 1 & 0 \\ 0 & 1 & -2 & 1 \end{pmatrix} \xrightarrow[-3r_2+r_1]{} \begin{pmatrix} 2 & 0 & 7 & -3 \\ 0 & 1 & -2 & 1 \end{pmatrix} \rightarrow$$

$$\xrightarrow[r_1/2]{} \begin{pmatrix} 1 & 0 & 7/2 & -3/2 \\ 0 & 1 & -2 & 1 \end{pmatrix}.$$

780 Entonces

$$\mathbf{A}^{-1} = \begin{pmatrix} 7/2 & -3/2 \\ -2 & 1 \end{pmatrix}.$$

781 **Ejemplo 2:**

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & 2 \\ 2 & 0 & 3 \\ 0 & 1 & -1 \end{bmatrix} \rightarrow \mathbf{A}^{-1} = \begin{bmatrix} 3 & -1 & 3 \\ -2 & 1 & -1 \\ -2 & 1 & -2 \end{bmatrix}.$$

782 **Factorización LU**

783 Es la descomposición de una matriz en una matriz triangular inferior \mathbf{L} y una matriz
784 triangular superior \mathbf{U} , es decir

$$\mathbf{A} = \mathbf{LU},$$

785 donde

$$\mathbf{L} = \begin{pmatrix} a_{12} & 0 \\ a_{21} & a_{22} \end{pmatrix}$$

786 es una matriz triangular inferior (L; lower) y

$$\mathbf{U} = \begin{pmatrix} a_{12} & a_{21} \\ 0 & a_{12} \end{pmatrix},$$

787 es una matriz triangular superior (U; superior). Esta factorización se suele usar
788 para resolver un sistema de ecuaciones lineal $\mathbf{Ax} = \mathbf{b}$ y no es única. Es decir,
789 pueden existir más de una factorización. Si sustituimos la definición de arriba

$$\mathbf{Ax} = (\mathbf{LU})\mathbf{x} = \mathbf{b},$$

790 lo que implica que

$$\mathbf{L}(\mathbf{U}\mathbf{x}) = \mathbf{b}.$$

791 Si definimos $\mathbf{U}\mathbf{x} = \mathbf{z}$, entonces tenemos que

$$\mathbf{L}\mathbf{z} = \mathbf{b}.$$

792 Como \mathbf{L} es una matriz triangular inferior, podemos resolver para \mathbf{z} utilizando susti-
793 tución hacia delante. Luego, como \mathbf{U} es una matriz triangular superior, resolvemos
794 $\mathbf{U}\mathbf{x} = \mathbf{z}$ por sustitución en reversa.

795 **Ejemplo:**

796 Encuentre la descomposición LU de la matriz

$$\begin{pmatrix} 2 & 5 \\ -3 & -4 \end{pmatrix}.$$

797 Si multiplicamos la primera fila por $L_{21} = 3/2$ y le sumamos la segunda fila hacemos
798 cero el elemento $a_{21} = -3$

$$\mathbf{U} = \begin{pmatrix} 2 & 5 \\ 0 & 7/2 \end{pmatrix}.$$

799 Esta matriz ya es una matriz triangular superior, es decir, la matriz \mathbf{U} . Para en-
800 contrar la matriz triangular inferior solo debemos de conocer el valor del elemento
801 L_{21} . Ese elemento es el multiplicador con signo opuesto usado en la eliminación de
802 Gauss-Jordan. Es decir, $L_{21} = -3/2$. La matriz \mathbf{L} es

$$\mathbf{L} = \begin{pmatrix} 1 & 0 \\ -3/2 & 1 \end{pmatrix}.$$

803 Vamos a comprobar que

$$\begin{pmatrix} 1 & 0 \\ -3/2 & 1 \end{pmatrix} \begin{pmatrix} 2 & 5 \\ 0 & 7/2 \end{pmatrix} = \begin{pmatrix} 2 & 5 \\ -3 & -4 \end{pmatrix}.$$

804 **Ejemplo:**

805 Resuelva el siguiente sistema de ecuaciones con la descomposición LU

$$806 \quad 2x_1 + 3x_2 + 4x_3 = 6$$

$$807 \quad 4x_1 + 5x_2 + 10x_3 = 16$$

$$808 \quad 4x_1 + 8x_2 + 2x_3 = 2$$

La matriz de coeficientes es

$$\mathbf{A} = \begin{pmatrix} 2 & 3 & 4 \\ 4 & 5 & 10 \\ 4 & 8 & 2 \end{pmatrix}.$$

809 Si factorizamos

$$\mathbf{L} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 2 & -2 & 1 \end{pmatrix},$$

810 y

$$\mathbf{U} = \begin{pmatrix} 2 & 3 & 4 \\ 0 & -1 & 2 \\ 0 & 0 & 0 \end{pmatrix}.$$

811 Si utilizamos la identidad $\mathbf{Lz} = \mathbf{b}$ obtenemos

$$\begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \\ z_3 \end{pmatrix} = \begin{pmatrix} 6 \\ 16 \\ 2 \end{pmatrix}.$$

812 Si resolvemos para \mathbf{z}

$$z_1 = 6$$

$$z_2 = 16 - 2z_1 = 4$$

$$z_3 = 2 + 2z_2 - 2z_1 = -2$$

815 Así que

$$\mathbf{z} = \begin{pmatrix} 6 \\ 4 \\ -2 \end{pmatrix}.$$

816 Si utilizamos ahora la definición $\mathbf{Ux} = \mathbf{z}$,

$$\begin{pmatrix} 2 & 3 & 4 \\ 0 & -1 & 2 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 6 \\ 4 \\ -2 \end{pmatrix},$$

817 y obtenemos

$$x_3 = 1$$

$$x_2 = \frac{4 - 2x_3}{-1} = -2$$

$$x_1 = \frac{6 - 4x_3 - 3x_2}{2} = 4$$

820 Por lo tanto la solución del sistema de ecuaciones es

$$\mathbf{x} = \begin{pmatrix} 4 \\ -2 \\ 1 \end{pmatrix}.$$

821 **3.0.1 Valores propios y vectores propios**

822 Sea \mathbf{A} una matriz cuadrada, un número real λ se dice que es un valor propio de \mathbf{A} si
823 existe un vector, diferente del vector cero, \mathbf{x} tal que

$$\mathbf{Ax} = \lambda\mathbf{x}.$$

824 Es decir, \mathbf{x} es un vector que al transformarlo mediante la multiplicación por \mathbf{A} el
825 vector resultante mantiene la misma dirección; solamente se modifica su longitud
826 (magnitud) y/o sentido. El valor propio λ nos informa si el vector propio \mathbf{x} se acorta
827 o alarga o cambia de signo cuando es multiplicado por \mathbf{A} .

828 {Definición} El número λ es un valor propio si y solo si

$$|\mathbf{A} - \lambda\mathbf{I}| = 0.$$

829 {Ejemplo:}

830 Calcula los valores propios y vectores propios de la matriz

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}.$$

831 Sabemos

$$|\mathbf{A} - \lambda\mathbf{I}| = \begin{vmatrix} 1 - \lambda & 2 \\ 2 & 4 - \lambda \end{vmatrix} = \lambda^2 - 5\lambda = 0.$$

832 El polinomio de arriba se llama polinomio característico y es igual a cero cuando λ
833 es un valor propio. Resolviendo obtenemos dos soluciones $\lambda = 0$ y $\lambda = 5$. Ahora
834 para encontrar los vectores propios debemos resolver el sistema $(\mathbf{A} - \lambda\mathbf{I})\mathbf{x} = 0$
835 separadamente para las dos λ :

$$(\mathbf{A} - 0\mathbf{I})\mathbf{x} = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \mathbf{x} = \begin{pmatrix} 2 \\ -1 \end{pmatrix} \text{ para } \lambda_1 = 0,$$

836 y

$$(\mathbf{A} - 5\mathbf{I})\mathbf{x} = \begin{pmatrix} -4 & 2 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \mathbf{x} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \text{ para } \lambda_2 = 5.$$

837 **Ejercicio:** Calcule los valores y vectores propios de la matriz de rotación

$$\mathbf{R} = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}.$$

838 {Multiplicación de matrices}

839 El producto matricial de dos matrices \mathbf{A} ($m \times n$) y \mathbf{B} ($n \times p$) se define como

$$\mathbf{C} = \mathbf{AB},$$

840 donde \mathbf{C} es una matriz $m \times p$, con el elemento (i, j) definido por

$$c_{ij} = \sum_{k=1}^n a_{ik} b_{kj},$$

841 para todo $i = 1, 2, \dots, m; j = 1, 2, \dots, p$.

842 **{Multiplicación de matrices}**

843 Sea \mathbf{A} una matriz $m \times n$, y \mathbf{v} un vector $n \times 1$, entonces el elemento del producto

$$\mathbf{z} = \mathbf{A}\mathbf{v}$$

844 viene dado por

$$z_i = \sum_{k=1}^n a_{ik} v_k,$$

845 para todo $i = 1, 2, \dots, m$. Similarmente, si \mathbf{u} es un vector $m \times 1$, entonces el elemento
846 del producto

$$\mathbf{z}^T = \mathbf{u}^T \mathbf{A}$$

847 viene dado por

$$z_i = \sum_{k=1}^n a_{ki} u_k,$$

848 para todo $i = 1, 2, \dots, n$. Finalmente, el escalar que resulta del producto $\alpha = \mathbf{u}^T \mathbf{A} \mathbf{v}$,
849 viene dado por

$$\alpha = \sum_{j=1}^m \sum_{k=1}^n a_{jk} u_j v_k.$$

850 **{Proposición:}**

851 Sea $\mathbf{C} = \mathbf{AB}$ una matriz $m \times p$, entonces

$$\mathbf{C}^T = \mathbf{B}^T \mathbf{A}^T.$$

852 **{Proposición:}** Sea \mathbf{A} y \mathbf{B} matrices cuadradas $n \times n$ invertibles. Sea el producto matr-
853 cial $\mathbf{C} = \mathbf{AB}$, entonces

$$\mathbf{C}^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

854 **{Derivada de matrices}**

855 **{Proposición:}**

856 Sea

$$\mathbf{y} = \mathbf{Ax},$$

857 donde \mathbf{y} es $m \times 1$, \mathbf{x} es $n \times 1$, \mathbf{A} es $m \times n$, y \mathbf{A} no depende de \mathbf{x} , entonces la derivada
858 de \mathbf{y} es

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{A}.$$

859 **{Proposición:}**

860 Sea

$$\mathbf{y} = \mathbf{Ax},$$

861 donde \mathbf{y} es $m \times 1$, \mathbf{x} es $n \times 1$, \mathbf{A} es $m \times n$, y \mathbf{A} no depende de \mathbf{x} . Supongamos que \mathbf{x}
862 es una función del vector \mathbf{z} , mientras que \mathbf{A} es independiente de \mathbf{z} . Entonces

$$\frac{\partial \mathbf{y}}{\partial \mathbf{z}} = \mathbf{A} \frac{\partial \mathbf{x}}{\partial \mathbf{z}}.$$

863 {Proposición:}

864 Sea el escalar α definido como

$$\alpha = \mathbf{x}^T \mathbf{Ax},$$

865 donde \mathbf{x} es $n \times 1$, \mathbf{A} es $n \times n$, y \mathbf{A} es independiente de \mathbf{x} , entonces

$$\frac{\partial \alpha}{\partial \mathbf{x}} = \mathbf{x}^T (\mathbf{A} + \mathbf{A}^T) = \mathbf{x}^T \mathbf{A}^T + \mathbf{x}^T \mathbf{A} = \mathbf{x}(\mathbf{A}^T + \mathbf{A})$$

866 {Proposición:}

867 Sea el escalar α definido como

$$\alpha = \mathbf{y}^T \mathbf{Ax},$$

868 donde \mathbf{y} es $m \times 1$, \mathbf{x} es $n \times 1$, y \mathbf{A} es $m \times n$, y \mathbf{A} es independiente de \mathbf{x} y \mathbf{y} , entonces

$$\frac{\partial \alpha}{\partial \mathbf{x}} = \mathbf{y}^T \mathbf{A}$$

869 y

$$\frac{\partial \alpha}{\partial \mathbf{y}} = \mathbf{x}^T \mathbf{A}.$$

870 {Definición} Sea \mathbf{A} una matriz $m \times n$ cuyos elementos son funciones de un escalar
871 α . Entonces la derivada de \mathbf{A} con respecto α es una matriz $m \times n$ compuesta por las
872 derivadas de elemento por elemento:

$$\frac{\partial \mathbf{A}}{\partial \alpha} = \begin{pmatrix} \frac{\partial a_{11}}{\partial \alpha} & \frac{\partial a_{12}}{\partial \alpha} & \dots & \frac{\partial a_{1n}}{\partial \alpha} \\ \frac{\partial a_{21}}{\partial \alpha} & \frac{\partial a_{22}}{\partial \alpha} & \dots & \frac{\partial a_{2n}}{\partial \alpha} \\ \vdots & \vdots & & \vdots \\ \frac{\partial a_{m1}}{\partial \alpha} & \frac{\partial a_{m2}}{\partial \alpha} & \dots & \frac{\partial a_{mn}}{\partial \alpha} \end{pmatrix}.$$

873 4 Cuadrados mínimos y regresión

874 En esta sección se van a introducir algunos modelos lineales estadísticos o modelos
875 de regresión. Aquí se incluyen ajustes lineales por mínimos cuadrados, coeficientes
876 de correlación, regresión múltiple, etc.

877 4.1 Métodos de cuadrados mínimos

878 Estos métodos son utilizados para ajustar un modelo dependiente de un conjunto
879 compuesto por k variables independientes $x_i; i = 1, 2, \dots, k$.

880 {(A) Mínimos cuadrados lineales} \ Empezamos aplicando el método
881 en términos de estimación lineal. Nos referimos a lineal en cuanto a

882 los coeficientes b_0, b_1, \dots, b_k , es decir, $y = b_0 + b_1x_1 + \epsilon$ es lineal, pero
 883 $y = b_0 + \sin(b_1x_1)$ no lo es. \

884 (1) {Ajuste de una recta a un conjunto de datos} \ Queremos usar
 885 los mejores coeficientes b_0 y b_1 en el sentido que se reduzca la
 886 desviación estandar de la recta ajustada versus los datos. Sea
 887 $i = 1, 2, \dots, N$ observaciones, entonces

$$y_i = \hat{y}_i + \epsilon,$$

888 donde

$$\hat{y}_i = b_0 + b_1x_i$$

889 es el estimador estadístico y ϵ es el residuo (medida de la diferen-
 890 cia de la recta ajustada versus conjunto de puntos). Para encon-
 891 trar b_0, b_1 debemos de minimizar la suma de los errores cuadrados
 892 (SEC), donde SEC es la varianza total que no es explicada por
 893 nuestro modelo de regresión lineal

$$SEC = \sum_{i=1}^N \epsilon_i^2 = \sum_{i=1}^N (y_i - \hat{y}_i)^2 = \sum_{i=1}^N [y_i - (b_0 + b_1x_i)]^2.$$

894 \

895 La suma de los cuadrados totales se define como

$$SCT = \sum_{i=1}^N (y_i - \bar{y})^2,$$

896 y la suma de los cuadrados residuales

$$SCR = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2.$$

897 La SCT es proporcional a la varianza de los datos y SCR es propor-
 898 cional a la cantidad de varianza explicada por nuestra regresión. La
 899 varianza total (o SCT) se puede descomponer en función de SCR y SEC
 900 como:

$$\begin{aligned} SCT &= \sum_{i=1}^N (y_i - \bar{y})^2 = \sum_{i=1}^N (\hat{y}_i + \epsilon_i - \bar{y})^2 = \sum_{i=1}^N ((\hat{y}_i - \bar{y}) + \epsilon_i)^2 = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2 + \\ &\quad + \sum_{i=1}^N \epsilon_i^2 + 2 \sum_{i=1}^N (\hat{y}_i - \bar{y})\epsilon_i, \end{aligned}$$

901 y por lo tanto

$$SCT = SCR + SEC$$

902

ya que por las ecuaciones normales $2 \sum_{i=1}^N (\hat{y}_i - \bar{y})\epsilon_i = 0$.
 El problema de mínimos cuadrados consiste en minimizar la SEC con
 respecto los coeficientes, cuyas condiciones son

$$\frac{\partial SEC}{\partial b_0} = 0; \quad \frac{\partial SEC}{\partial b_1} = 0.$$

Substituyendo obtenemos para b_0

$$\begin{aligned} \frac{\partial SEC}{\partial b_0} &= \frac{\partial}{\partial b_0} \left\{ \sum_{i=1}^N [y_i - (b_0 + b_1 x_i)]^2 \right\} = -2 \sum_{i=1}^N [y_i - (b_0 + b_1 x_i)] = \\ &= -2 \left(\sum_{i=1}^N y_i - Nb_0 - b_1 \sum_{i=1}^N x_i \right) = 0, \end{aligned}$$

y para b_1

$$\begin{aligned} \frac{\partial SEC}{\partial b_1} &= \frac{\partial}{\partial b_1} \left\{ \sum_{i=1}^N [y_i - (b_0 + b_1 x_i)]^2 \right\} = -2 \sum_{i=1}^N x_i [y_i - (b_0 + b_1 x_i)] = \\ &= -2 \left(\sum_{i=1}^N x_i y_i - b_0 \sum_{i=1}^N x_i - b_1 \sum_{i=1}^N x_i^2 \right) = 0. \end{aligned}$$

Si resolvemos para b_0

$$b_0 = \bar{y} - b_1 \bar{x},$$

y sustituimos en la segunda ecuación, obtenemos:

$$\begin{aligned} b_1 &= \frac{N \sum_{i=1}^N x_i y_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i}{N \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2} = \frac{\sum_{i=1}^N x_i y_i - \frac{1}{N} \sum_{i=1}^N x_i \sum_{i=1}^N y_i}{\sum_{i=1}^N x_i^2 - \frac{1}{N} \left(\sum_{i=1}^N x_i \right)^2} = \\ &= \frac{(N-1)C_{xy}}{(N-1)s_x^2} = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2} = \frac{\langle x'y' \rangle}{\langle x'^2 \rangle}, \end{aligned}$$

donde $C_{xy} = \langle x'y' \rangle$ es la covarianza entre x e y , y $s_x^2 = \langle x'^2 \rangle$ es la varianza de x . Así, una vez hemos calculado las medias de las variables x e y , podemos encontrar el coeficiente b_1 y, a partir de este, calcular el segundo coeficiente b_0 .

916

917 Si sustituimos $b_0 = \bar{y} - b_1 \bar{x}$ en la ecuación de la regresión lineal $\hat{y}_i = b_0 +$
 918 $b_1 x_i$
 919 obtenemos

$$\hat{y}_i = \bar{y} + b_1(x_i - \bar{x}),$$

920 O

$$\hat{y}_i = \bar{y} + b_1 x'_i,$$

921 o finalmente

$$\hat{y}'_i = b_1 x'_i,$$

922 que nos informa que cuando $x'_i = 0$ ($x_i = \bar{x}$) entonces $\hat{y}'_i = 0$ ($\hat{y} = \bar{y}$),
 923 es decir, la recta pasa por el punto (\bar{x}, \bar{y}) , de tal forma, que puesto que
 924 $\partial SEC/\partial b_0 = 0$ minimiza la suma del error, $\sum \epsilon_i = 0$, los puntos estan
 925 dispersos respecto a la recta ajustada de tal forma que los residuos posi-
 926 tivos ($\epsilon > 0$) siempre se cancelan con los residuos negativos ($\epsilon < 0$). El
 927 parámetro b_0 se interpreta como la intersección (corte con el eje y) y b_1
 928 es la pendiente de la recta ajustada.

929 El cociente

$$100(SCR/SCT),$$

931 es el porcentaje de varianza explicada por nuestra regresión lineal (var-
 932 ianza explicada/varianza total) y nos informa de la bondad del ajuste
 933 denominado *coeficiente de correlación*, r^2 . Si la regresión se ajusta per-
 934 fectamente a todos los datos, todos los residuos son cero y por lo tanto
 935 $SEC = 0$ y $SCR/SCT = r^2 = 1$. A medida que el ajuste empeora el
 936 coeficiente r^2 disminuye hasta un mínimo posible de $r^2 = 0$.

937 {Error estandar de la estimación}

938 Una medida de la magnitud absoluta de la bondad del ajuste es el error
 939 estandar del estimado, s_ϵ , definido como

$$s_\epsilon = [SEC/(N-2)]^{1/2} = \left[\frac{1}{N-2} \sum_{i=1}^N (y - \hat{y})^2 \right]^{1/2}.$$

940 El número de grados de libertad, $N - 2$, se debe a que necesitamos es-
 941 timar dos parámetros para encontrar realizar la regresión lineal. Si ϵ es
 942 una variable aleatoria que sigue una distribución Normal de media cero
 943 y desviación estandar s_ϵ , entonces, el 68.3% de las observaciones caen
 944 dentro del intervalo $\pm s_\epsilon$ unidades de la recta ajustada, 95.4% caerá

945 dentro del intervalo $\pm 2s_\epsilon$ unidades de la recta, y 99.7% caerán en el
 946 intervalo $\pm 3s_\epsilon$ unidades de la recta. s_ϵ es la desviación estandar de y
 947 alrededor de su media, i.e., la recta ajustada $b_0 + b_1x$.

948 **Generalización de mínimos cuadrados en notación matricial**

949 Supongamos el modelo dependiente de k variables independientes X_k

$$Y = b_0 + b_1X_1 + b_2X_2 + \dots + b_kX_k + \epsilon,$$

950 y supongamos que hacemos N observaciones independientes y_1, y_2, \dots, y_N
 951 de Y . Por lo tanto podemos escribir el modelo como

$$y_i = b_0 + b_1x_{i1} + b_2x_{i2} + \dots + b_kx_{ik} + \epsilon_i,$$

952 donde x_{ij} es la observación i del de la variable independiente j . Es de-
 953 cir,

N ; observaciones

954 k ; variables independientes

955 $k + 1$; coeficientes

Si escribimos en notación matricial

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ \vdots \\ y_N \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{21} & \dots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & \dots & x_{Nk} \end{pmatrix}$$

$$\mathbf{B} = \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ \vdots \\ b_k \end{pmatrix} \quad \mathbf{E} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \vdots \\ \epsilon_N \end{pmatrix}.$$

956 De esta forma, podemos escribir nuestro modelo en notación matricial
 957 como

$$\mathbf{Y} = \mathbf{XB} + \mathbf{E}.$$

958 Si restringimos el modelo a una variable independiente ($k = 1$), i.e. dos
 959 coeficientes (b_0, b_1), entonces

$$\mathbf{B} = \begin{pmatrix} b_0 \\ b_1 \end{pmatrix},$$

960 es la matriz de coeficientes, e

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} \\ 1 & x_{21} \\ \dots & \dots \\ \dots & \dots \\ 1 & x_{N1} \end{pmatrix},$$

961 es la matriz de variables independientes. Si utilizamos la definición de
962 los residuos como

$$\mathbf{E} = \mathbf{Y} - \mathbf{XB},$$

963 podemos encontrar la suma de los residuos al cuadrado como

$$SEC = \sum_{i=1}^N \epsilon_i^2 = \sum_{i=1}^N \epsilon_i \epsilon_i = \mathbf{E}^T \mathbf{E} = (\mathbf{Y} - \mathbf{XB})^T (\mathbf{Y} - \mathbf{XB}) =$$

$$\mathbf{Y}^T \mathbf{Y} - \mathbf{Y}^T \mathbf{XB} - \mathbf{B}^T \mathbf{X}^T \mathbf{Y} + \mathbf{B}^T \mathbf{X}^T \mathbf{XB}.$$

964 Si queremos minimizar esa suma de errores entonces

$$\frac{\partial SEC}{\partial \mathbf{B}} = 0.$$

965 Para calcular las derivadas de SEC respecto de los coeficientes \mathbf{b} vamos
966 a asumir las siguientes consideraciones

967 (i) $\mathbf{Y}^T \mathbf{XB} = \mathbf{B}^T \mathbf{X}^T \mathbf{Y}$ ya que son matrices elemento (1×1) y siempre
968 son simétricas. Por lo tanto $-\mathbf{Y}^T \mathbf{XB} - \mathbf{B}^T \mathbf{X}^T \mathbf{Y} = -2\mathbf{B}^T \mathbf{X}^T \mathbf{Y}$, y
969 su derivada

$$-2\mathbf{X}^T \mathbf{Y}.$$

970 (ii) $\partial \mathbf{B}^T \mathbf{X}^T \mathbf{XB} / \partial \mathbf{B} = 2\mathbf{X}^T \mathbf{XB}$. Para demostrar esto tomemos el caso
971 para el ajuste lineal (2 parámetros). Definamos los elementos de
972 $\mathbf{X}^T \mathbf{X}$ como c_{ij} $i, j = 1, 2$ y $c_{12} = c_{21}$ por ser simétrica. Entonces

$$\mathbf{B}^T \mathbf{X}^T \mathbf{XB} = c_{11}b_0^2 + c_{22}b_1^2 + 2c_{12}b_0b_1,$$

973 y su derivada respecto b_0 es

$$2c_{11}b_0 + 2c_{12}b_1$$

974 y respecto a b_1 es

$$2c_{12}b_0 + 2c_{22}b_1.$$

975 Si acomodamos las derivadas en un vector columna 2×1 obtenemos

$$\begin{pmatrix} 2c_{11}b_0 + 2c_{12}b_1 \\ 2c_{12}b_0 + 2c_{22}b_1 \end{pmatrix} = 2\mathbf{X}^T \mathbf{XB}.$$

976 y por lo tanto

$$\frac{\partial S}{\partial \mathbf{B}} = -2\mathbf{X}^T \mathbf{Y} + 2\mathbf{X}^T \mathbf{XB},$$

977 y las ecuaciones normales quedan

$$-2\mathbf{X}^T \mathbf{Y} + 2\mathbf{X}^T \mathbf{XB} = 0.$$

978 Finalmente, el problema de mínimos cuadrados es

$$(\mathbf{X}^T \mathbf{X})\mathbf{B} = \mathbf{X}^T \mathbf{Y}.$$

979 Y resolviendo para \mathbf{B} la forma general del método de regresión por míni-
980 mos cuadrados es

$$\mathbf{B} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y},$$

981 o equivalentemente

$$\mathbf{B}^T = \mathbf{Y}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1}.$$

982 **4.1.1 Propiedades estadísticas**

983 Algunas de las consideraciones de un modelo de regresión múltiple son:

- 984 1. Distribuciones aleatorias con media cero. El vector $N \times 1$ de er-
985 rores, ϵ , sigue una distribución aleatoria de media cero tal que
986 $E[\epsilon] = 0$, es decir, $E[\epsilon_i] = 0$ ($i = 1, 2, \dots, N$).
- 987 2. Homoscedasticidad. La matriz de covarianzas de los errores $E[\epsilon\epsilon']$
988 existe y los elementos de la diagonal principal son igual a σ^2 , es
989 decir, $E[\epsilon_i^2] = \sigma^2$ ($i = 1, 2, \dots, N$).
- 990 3. No correlación. Los elementos fuera de la diagonal principal de la
991 matriz de errores $E[\epsilon\epsilon']$ son iguales a cero, es decir, $E[\epsilon_i \epsilon_j] = 0$ for
992 todo $i \neq j$.
- 993 4. Parámetros constantes. Los elementos del vector $k \times 1$, β , y el
994 escalar σ son números fijos desconocidos con $\sigma > 0$.
- 995 5. Modelo lineal. Los valores del vector dependiente y han sido gener-
996 ados a partir de el modelo de regresión lineal multivariado:

$$y = \mathbf{X}\beta + \epsilon$$

- 997 6. Normalidad. Las distribuciones aleatorias de los errores siguen una
 998 distribución Normal. Las consideraciones 2 y 3 pueden expresarse
 999 en notación matricial

$$E[\epsilon\epsilon'] = \sigma^2 \mathbf{I},$$

donde \mathbf{I} es la matrix identidad $N \times N$. Si además la consideración 1 se cumple, entonces ϵ sigue una distribución Normal

$$\epsilon \sim N(0, \sigma^2 \mathbf{I}).$$

1000 Las consideraciones 3 y 6 implican que las distribuciones aleatorias
 1001 $\epsilon_i, i = 1, 2, \dots, N$ son linealmente independientes.

1002 Mínimos cuadrados no tienen sesgo

1003 La esperanza del vector de coeficientes $k \times 1, b$, se obtiene a partir de
 1004 las consideraciones 1,4, y 5. La consideración 5 implica que el estimador
 1005 de los coeficientes $b = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \epsilon$ y se puede escribir cómo

$$b = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{X}\beta + \epsilon) = \mathbf{I}\beta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \epsilon.$$

1006 \

1007 De las consideraciones 1, y 4 obtenemos

$$E[b] = E[\beta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \epsilon] = \beta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \underbrace{E[\epsilon]}_0 = \beta,$$

1008 lo que implica que b es insesgado.

1009 Matriz de varianza de b

1010 Usando el resultado de arriba, bajo las consideraciones 1-6, la matriz de
 1011 varianza de los estimadores de los coeficientes b (o momento centrado de
 1012 orden 2) viene dada por

$$\begin{aligned} \text{var}(b) &= E[(b - \beta)(b - \beta)^T] = E[(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \epsilon \epsilon^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1}] = \\ &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T E[\epsilon \epsilon^T] \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\sigma^2 \mathbf{I}) \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}. \end{aligned}$$

1013 Los elementos de la diagonal principal de esta matriz son las varian-
 1014 zas asociadas a los estimadores de los coeficientes b , y los elementos
 1015 fuera de la diagonal principal representan la covarianza entre esos esti-
 1016 madores.

1017 Si asumimos que las variables del problema han sido estandarizadas, es
 1018 decir la media ha sido extraída de las variables x_{ij} e y_i y hemos dividido
 1019 por las desviaciones estandar

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} \sum_{i=1}^N x_{i1}x_{i1} & \sum_{i=1}^N x_{i1}x_{i2} & \dots & \sum_{i=1}^N x_{i1}x_{ik} \\ \sum_{i=1}^N x_{i2}x_{i1} & \sum_{i=1}^N x_{i2}x_{i2} & \dots & \sum_{i=1}^N x_{i2}x_{ik} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^N x_{ik}x_{i1} & \sum_{i=1}^N x_{ik}x_{i2} & \dots & \sum_{i=1}^N x_{ik}x_{ik} \end{pmatrix},$$

1021 es una matriz $k \times k$ y en notación índice se puede escribir como

$$[\mathbf{X}^T \mathbf{X}]_{nm} = (N - 1)\rho_{x_{in}x_{im}} ; (i = 1, 2, \dots, N),$$

1022 que se puede interpretar como la matriz de correlaciones entre las vari-
1023 ables independientes. La matriz

$$\mathbf{X}^T \mathbf{Y} = \begin{pmatrix} \sum_{i=1}^N y_i x_{i1} \\ \sum_{i=1}^N y_i x_{i2} \\ \vdots \\ \vdots \\ \sum_{i=1}^N y_i x_{ik} \end{pmatrix},$$

1024 es una matriz $k \times 1$ y en notación índice es

$$[\mathbf{Y}^T \mathbf{X}]_n = (N - 1)\rho_{y_i x_{in}} ; (i = 1, 2, \dots, N).$$

1025 Esta matriz se puede interpretar como la matriz de correlación entre las
1026 variables independientes y dependientes.

1027 El modelo multivariado en notación índice es

$$(N - 1)\rho_{x_{in}x_{im}} b_m = (N - 1)\rho_{y_i x_{in}}$$

1028 O

$$\rho_{x_{in}x_{im}} b_m = \rho_{y_i x_{in}} ; m = n = 1, 2, \dots, k; i = 1, 2, \dots, N$$

1029 y para una única observación i dada obtenemos

$$\rho_{x_n x_m} b_m = \rho_{y x_n}$$

1030 Ahora supongamos, por simplicidad, que solo tenemos dos variables
 1031 independientes. Entonces:

$$\rho_{x_1 x_1} b_1 + \rho_{x_1 x_2} b_2 = \rho_{y x_1}$$

$$\rho_{x_2 x_1} b_1 + \rho_{x_2 x_2} b_2 = \rho_{y x_2},$$

1032 y puesto que $\rho_{x_1 x_1} = \rho_{x_2 x_1} = 1$, y $\rho_{x_1 x_2} = \rho_{x_2 x_1}$, podemos escribir el sis-
 1033 tema como:

$$\begin{pmatrix} 1 & \rho_{x_1 x_2} \\ \rho_{x_1 x_2} & 1 \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} \rho_{y x_1} \\ \rho_{y x_2} \end{pmatrix}.$$

1034 De forma que los coeficientes quedan como

$$\begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 1 & \rho_{x_1 x_2} \\ \rho_{x_1 x_2} & 1 \end{pmatrix}^{-1} \begin{pmatrix} \rho_{y x_1} \\ \rho_{y x_2} \end{pmatrix} = \frac{1}{1 - \rho_{x_1 x_2}^2} \begin{pmatrix} 1 & -\rho_{x_1 x_2} \\ -\rho_{x_1 x_2} & 1 \end{pmatrix} \begin{pmatrix} \rho_{y x_1} \\ \rho_{y x_2} \end{pmatrix}.$$

1035

$$b_1 = \frac{1}{1 - \rho_{x_1 x_2}^2} (\rho_{y x_1} - \rho_{x_1 x_2} \rho_{y x_2})$$

1036

$$b_2 = \frac{1}{1 - \rho_{x_1 x_2}^2} (\rho_{y x_2} - \rho_{x_1 x_2} \rho_{y x_1}).$$

1037 Finalmente puntualizar que el problema de mínimos cuadrados se puede
 1038 resolver utilizando la descomposición *LU*. Para ello solo es necesario un
 1039 cambio de variable en la ecuación

$$\mathbf{X}^T \mathbf{X} \mathbf{B} = \mathbf{X}^T \mathbf{Y}$$

1040 para obtener un sistema de ecuaciones tipo $\mathbf{A}\mathbf{x} = \mathbf{b}$, donde ahora $\mathbf{A} =$
 1041 $\mathbf{X}^T \mathbf{X}$, $\mathbf{x} = \mathbf{B}$, y $\mathbf{b} = \mathbf{X}^T \mathbf{Y}$.

1042 (2) Cuadrados Mínimos con restricciones

1043 **NOTA:** Multiplicadores de Lagrange

1044 Dada la función $f(x) = f(x_1, x_2, \dots, x_N)$ que depende de N variables
 1045 y p restricciones $g_1(x) = d_1, g_2(x) = d_2, \dots, g_p(x) = d_p$ entonces el
 1046 teorema de Lagrange nos dice que para minimizar la función $f(x)$ bajo
 1047 esas p restricciones debemos resolver el sistema de ecuaciones

$$\frac{\partial}{\partial x_i} \left[f(x) + \sum_{j=1}^p \lambda_j g_j(x) \right] = 0 ; i = 1, 2, \dots, N$$

1048

$$g_j(x) = d_j ; j = 1, 2, \dots, p$$

1049 Vamos a usar los multiplicadores de Lagrange para resolver el problema
 1050 de cuadrados mínimos

$$\mathbf{Y} = \mathbf{XB},$$

1051 pero incluyendo p restricciones de la forma

$$\mathbf{GB} = \mathbf{d}.$$

1052 Queremos minimizar la función:

$$L = (\mathbf{Y} - \mathbf{XB})^T(\mathbf{Y} - \mathbf{XB}) + {}^T(\mathbf{GB} - \mathbf{d}).$$

1053 Aquí hemos introducido p incógnitas pero también tenemos p nuevas
1054 ecuaciones $\mathbf{GB} = \mathbf{d}$. Derivando L e igualando a cero

$$\frac{\partial L}{\partial \mathbf{B}} = -2\mathbf{X}^T\mathbf{Y} + 2\mathbf{X}^T\mathbf{XB} + \mathbf{G}^T = 0,$$

1055 lo cual tiene la solución

$$\mathbf{B} = (\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{Y} - \frac{1}{2}\mathbf{G}^T),$$

1056 que para $= 0$ se reduce a la expresión de los mínimos cuadrados sin re-
1057 stricciones

$$\mathbf{B} = (\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{Y}).$$

1058 Si sustituimos en la ecuación de las restricciones

$$\mathbf{G}(\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{Y} - \frac{1}{2}\mathbf{G}^T) = \mathbf{d},$$

1059 y resolvemos para $$, obtenemos

$$\frac{1}{2} = [\mathbf{G}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{G}^T]^{-1} [\mathbf{G}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} - \mathbf{d}].$$

1060 Finalmente, si sustituimos en la solución para la matriz de coeficientes
1061 \mathbf{B} obtenemos

$$\mathbf{B} = (\mathbf{X}^T\mathbf{X})^{-1} \left(\mathbf{X}^T\mathbf{Y} - \mathbf{G}^T [\mathbf{G}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{G}^T]^{-1} [\mathbf{G}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} - \mathbf{d}] \right).$$

1062 Un ejemplo sería ajustar una recta a un conjunto de observaciones pero
1063 imponiendo que la recta pase por algún punto determinado del espacio
1064 xy .

1065 (3) Cuadrados Mínimos pesados

1066 En ocasiones debido a las incertidumbres asociadas a la medidas de las
 1067 variables independientes es conveniente asignarles un peso diferencial
 1068 en el problema de mínimos cuadrados. Supongamos que unas variables
 1069 independientes son conocidas con mayor precisión que otras. Entonces
 1070 el modelo de mínimos cuadrados pesados es:

$$SEC = (\mathbf{Y} - \mathbf{XB})^T \mathbf{W}_\epsilon (\mathbf{Y} - \mathbf{XB}),$$

1071 donde \mathbf{W}_ϵ es una matriz diagonal con los elementos σ_j^{-2} , el inverso de
 1072 la varianza de cada variable independiente.

1073 Sin embargo, en general, los errores en los datos están correlacionados,
 1074 y \mathbf{W}_ϵ no es diagonal. Una elección razonable para \mathbf{W}_ϵ es el inverso de
 1075 la matriz de covarianzas. Si asumimos que \mathbf{Y} se compone de un valor
 1076 medio más un error o fluctuación respecto la media

$$\mathbf{Y} = \bar{\mathbf{Y}} + \mathbf{Y}',$$

1077 entonces la matriz de covarianzas es $\langle \mathbf{Y}' \mathbf{Y}'^T \rangle$ y

$$\mathbf{W}_\epsilon = \langle \mathbf{Y}' \mathbf{Y}'^T \rangle^{-1}.$$

1078 **Ejemplo (1):** Emery and Thompson (sección 3.12.4).

1079 En la tabla adjunta se muestran 5 observaciones de la variable indepen-
 1080 diente (x_i) y dependiente (y_i). Se pide ajustar una recta al conjunto
 1081 de datos y calcular las medidas de error (varianza s^2 y coeficiente de
 1082 correlación al cuadrado r^2) asociadas al ajuste lineal.

x_i	y_i	$x_i y_i$	x_i^2
-2	0	0	4
-1	0	0	1
0	1	0	0
1	1	1	1
2	3	6	4

1084 Los coeficientes del modelo lineal se pueden calcular con las expresiones:

$$\hat{b}_1 = \frac{\left[N \sum_{i=1}^N x_i y_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i \right]}{N \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2} =$$

$$\frac{[(5)(7) - (0)(5)]}{[(5)(10) - 10^2]} = 0.7$$

$$b_0 = \bar{y} - b_1 \bar{x} = 5/5 - (0.7)(0) = 1$$

1086 En notación matricial obtenemos el mismo resultado:

$$\mathbf{Y} = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 3 \end{pmatrix}$$

$$\mathbf{X} = \begin{pmatrix} 1 & -2 \\ 1 & -1 \\ 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$$

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 5 & 0 \\ 0 & 10 \end{pmatrix}$$

$$\mathbf{X}^T \mathbf{Y} = \begin{pmatrix} 5 \\ 7 \end{pmatrix}$$

$$(\mathbf{X}^T \mathbf{X})^{-1} = \begin{pmatrix} 1/5 & 0 \\ 0 & 1/10 \end{pmatrix}$$

$$(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} = \begin{pmatrix} 1/5 & 0 \\ 0 & 1/10 \end{pmatrix} \begin{pmatrix} 5 \\ 7 \end{pmatrix} = \begin{pmatrix} 1 \\ 0.7 \end{pmatrix}.$$

1087 Como ya vimos, para calcular la varianza de nuestro ajuste usamos

$$s^2 = \frac{1}{N-2} \sum_{i=1}^N (y_i - \hat{y}_i)^2 = \frac{1}{N-2} SEC,$$

1088 donde SEC es la suma de los errores cuadrados y $N - 2$ resulta debido
1089 a que en la regresión lineal se requiere la estimación de dos parámetros.
1090 En notación matricial

$$SEC = \mathbf{Y}^T \mathbf{Y} - \mathbf{Y}^T \mathbf{X} \mathbf{B} - \mathbf{B}^T \mathbf{X}^T \mathbf{Y} + \mathbf{B}^T \mathbf{X}^T \mathbf{X} \mathbf{B} = \mathbf{Y}^T \mathbf{Y} - 2\mathbf{B}^T \mathbf{X}^T \mathbf{Y} + \mathbf{B}^T \mathbf{X}^T \mathbf{X} \mathbf{B} =$$

$$= \mathbf{Y}^T \mathbf{Y} - 2\mathbf{B}^T \mathbf{X}^T \mathbf{Y} + \mathbf{B}^T \mathbf{X}^T \mathbf{Y} = \mathbf{Y}^T \mathbf{Y} - \mathbf{B}^T \mathbf{X}^T \mathbf{Y},$$

1091 donde hemos usado la identidad $\mathbf{X}^T \mathbf{X} \mathbf{B} = \mathbf{X}^T \mathbf{Y}$.

1092 Si sustituimos las matrices de nuestro ejemplo, obtenemos

$$SEC = (0 \ 0 \ 1 \ 1 \ 3) \begin{pmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 3 \end{pmatrix} - (1 \ 0.7) \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ -2 & -1 & 0 & 1 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 3 \end{pmatrix} =$$

$$= 11 - (1 \ 0.7) \begin{pmatrix} 5 \\ 7 \end{pmatrix} = 11 - 9.9 = 1.1$$

1093 SEC puede ser calculado directamente con la expresión:

$$SEC = \sum_{i=1}^N (\hat{y}_i - y_i)^2 = (-0.4)^2 + (-0.3)^2 + (0)^2 + (0.7)^2 + (0.6)^2 = 1.1$$

1094 Y entonces la desviación estandar de nuestro ajuste lineal es

$$s = \sqrt{\frac{1}{N-2} SEC} = \sqrt{\frac{1}{5-2} 1.1} = \sqrt{1.1/3} \simeq 0.366.$$

1095 El coeficiente de correlación se puede escribir como

$$r^2 = \frac{SCR}{SCT} = \frac{\sum_{i=1}^N (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^N (y_i - \bar{y})^2} = \frac{4.9}{6} \simeq 0.8167$$

1096 (4) **Ajuste de curvas con mínimos cuadrados**

1097 En general, podemos escribir nuestro modelo lineal como

$$Y = b_0 + b_1 x + b_2 x^2 + \dots + b_k x^k + \epsilon.$$

1098

1099 El procedimiento es el mismo que para el caso de la línea recta, pero
1100 ahora la matriz \mathbf{X} tiene una columna mas. Es decir, para $k = 2$ y para
1101 N observaciones independientes las ecuaciones independientes son

$$\begin{aligned} y_1 &= b_0 + b_1 x_1 + b_2 x_1^2 + \epsilon_1 \\ y_2 &= b_0 + b_1 x_2 + b_2 x_2^2 + \epsilon_2 \\ &\dots \\ y_N &= b_0 + b_1 x_N + b_2 x_N^2 + \epsilon_N \end{aligned}$$

1107 y pueden resolverse matricialmente para \mathbf{B} como

$$\mathbf{B} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y},$$

1108 donde \mathbf{X} tiene una columna mas que el caso del ajuste de una recta,
1109 i.e. $k + 1$ columnas.

1110 **Ejemplo (2):** Ajustes por cuadrados mínimos con restricciones.
1111 Supongamos que queremos ajustar dos polinomios $f(x)$ y $g(x)$ de or-
1112 den $d-1$ a dos conjunto de datos continuos de M y N observaciones,
1113 respectivamente, $x_1, x_2, \dots, x_M \leq a$ y $x_{M+1}, x_{M+2}, \dots, x_N > a$, tal que,
1114 queremos minimizar:

$$\sum_{i=1}^M (f(x_i) - y_i)^2 + \sum_{i=M+1}^N (g(x_i) - y_i)^2,$$

1115 sujeto a las restricciones:

$$f(a) = g(a) \text{ y } f'(a) = g'(a).$$

1116 Primero debemos de construir las matrices del problema lineal de
1117 cuadrados mínimos:

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 & \dots & x_1^{d-1} & 0 & 0 & \dots & 0 \\ \vdots & \ddots & & \ddots & \ddots & \ddots & & \ddots \\ \vdots & \ddots & & \ddots & \ddots & \ddots & & \ddots \\ \vdots & \ddots & & \ddots & \ddots & \ddots & & \ddots \\ 1 & x_M & \dots & x_M^{d-1} & 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & 1 & x_{M+1} & \dots & x_{M+1}^{d-1} \\ \vdots & \ddots & & \ddots & \ddots & \ddots & & \ddots \\ \vdots & \ddots & & \ddots & \ddots & \ddots & & \ddots \\ 0 & 0 & \dots & 0 & 1 & x_N & \dots & x_N^{d-1} \end{pmatrix}$$

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_M \\ y_{M+1} \\ y_{M+2} \\ \dots \\ y_N \end{pmatrix},$$

$$\mathbf{G} = \begin{pmatrix} 1 & a & \dots & a^{d-1} & -1 & -a & \dots & -a^{d-1} \\ 0 & 1 & \dots & (d-1)a^{d-2} & 0 & -1 & \dots & -(d-1)a^{d-2} \end{pmatrix}, \mathbf{d} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

1118 Segundo debemos de calcular los coeficientes del ajuste \mathbf{B} con la expre-
1119 sión para mínimos cuadrados con restricciones.

$$\mathbf{B} = (\mathbf{X}^T \mathbf{X})^{-1} \left(\mathbf{X}^T \mathbf{Y} - \mathbf{G}^T \left[\mathbf{G}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{G}^T \right]^{-1} \left[\mathbf{G}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} - \mathbf{d} \right] \right).$$

1120 Aplicemos el caso particular del ajuste de dos rectas

1121 $f(x) = b_1 + b_2x$ y $g(x) = b_3 + b_4x$:

1122 • Minimizar: $\sum_{i=1}^M (f(x_i) - y_i)^2 + \sum_{i=M+1}^N (g(x_i) - y_i)^2$

• Restricciones:

$$f(h) = g(h) \rightarrow b_1 + b_2h - b_3 - b_4h = 0$$

$$f'(h) = g'(h) \rightarrow b_1 - b_3 = 0,$$

1123 donde h es el valor donde ambas rectas interseccionan. Por ello exigimos que ambas rectas tomen el mismo valor y sus derivadas sean iguales en $x = h$. Se resuleve el sistema de ecuaciones:

1126 $\mathbf{X}\mathbf{B} = \mathbf{Y}$

1127 $(1)b_1 + (x_1)b_2 + (\theta)b_3 + (\theta)b_4 = y_1$

1128 $(1)b_1 + (x_2)b_2 + (\theta)b_3 + (\theta)b_4 = y_2$

1129 $(1)b_1 + (x_3)b_2 + (\theta)b_3 + (\theta)b_4 = y_3$

1130 $(1)b_1 + (x_4)b_2 + (\theta)b_3 + (\theta)b_4 = y_4$

1131 $(\theta)b_1 + (\theta)b_2 + (1)b_3 + (x_5)b_4 = y_5$

1132 $(\theta)b_1 + (\theta)b_2 + (1)b_3 + (x_6)b_4 = y_6$

1133 $(\theta)b_1 + (\theta)b_2 + (1)b_3 + (x_7)b_4 = y_7$

1134 $(\theta)b_1 + (\theta)b_2 + (1)b_3 + (x_8)b_4 = y_8,$

1135 bajo el sistema de ecuaciones de restricciones:

1136 $\mathbf{G}\mathbf{B} = \mathbf{d}$

1137 $(1)b_1 + (h)b_2 + (-1)b_3 + (-1)b_4 = 0$

1138 $(1)b_1 + (\theta)b_2 + (-1)b_3 + (\theta)b_4 = 0$

En notación matricial:

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 & 0 & 0 \\ 1 & x_2 & 0 & 0 \\ 1 & x_3 & 0 & 0 \\ 1 & x_4 & 0 & 0 \\ 0 & 0 & 1 & x_5 \\ 0 & 0 & 1 & x_6 \\ 0 & 0 & 1 & x_7 \\ 0 & 0 & 1 & x_8 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \\ y_6 \\ y_7 \\ y_8 \end{pmatrix}, \mathbf{G} = \begin{pmatrix} 1 & h & -1 & -h \\ 0 & 1 & 0 & -1 \end{pmatrix}, \mathbf{d} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

4.1.2 Cuadrados Mínimos no-lineales

Los mínimos cuadrados no-lineales se aplican cuando queremos ajustar un conjunto de observaciones a un modelo que no es lineal en cuanto a los coeficientes.

1. Linealización del problema no lineal En ocasiones se puede linealizar el problema y resolverlo utilizando la solución de mínimos cuadrados lineales. Por ejemplo, supongamos que queremos ajustar un conjunto de N observaciones a una función no-lineal exponencial:

$$\hat{y} = ae^{bx} .$$

Este ejemplo se puede linealizar:

$$\hat{y} = ae^{bx} \rightarrow \ln(\hat{y}) = \ln(a) + bx ,$$

y resolver el problema lineal:

$$Y = B_1 + B_2 X ,$$

donde hemos hecho el cambio de variables:

$$Y = \ln(\hat{y}) , B_1 = \ln(a) , B_2 = b \text{ y } X = x .$$

Resolvemos para B_1 y B_2 :

$$B = \begin{pmatrix} B_1 \\ B_2 \end{pmatrix} = (X^T X)^{-1} X^T Y ,$$

y calculamos los coeficientes originales a y b con el cambio de variables.

2. Resolución numérica del problema no lineal

Cuando no es posible linealizar la función no-lineal que queremos ajustar, debemos minimizar la suma de los errores cuadráticos medios y resolver numéricamente. La SEC del modelo exponencial

$$SEC = \sum_{i=1}^N (y_i - \hat{y}_i)^2 = \sum_{i=1}^N \underbrace{(y_i - ae^{bx_i})}_{\epsilon_i}^2$$

es minimizada derivando con respecto los coeficientes:

$$\frac{\partial SEC}{\partial a} = 2 \sum_{i=1}^N (y_i - ae^{bx_i}) \frac{\partial \epsilon_i}{\partial a} = 0$$

$$\frac{\partial SEC}{\partial b} = 2 \sum_{i=1}^N (y_i - ae^{bx_i}) \frac{\partial \epsilon_i}{\partial b} = 0 .$$

Debemos resolver el sistema de ecuaciones de arriba, lo cual se puede hacer con descomposiciones algebráicas tipo **LU**, minimizando SEC

con la función de Matlab *fminsearch.m* (o implementando un método numérico manual), o directamente utilizando la función de mínimos cuadrados no-lineales de Matlab *nlinfit.m*.

Otro ejemplo no-lineal es ajustar la siguiente función trigonométrica:

$$\hat{y} = \phi_1 e^{\phi_2 x} \cos(\phi_3 x + \phi_4),$$

donde la suma de los errores cuadráticos es:

$$SEC = \sum_{i=1}^N (y_i - \hat{y}_i)^2 = \sum_{i=1}^N \underbrace{(y_i - \phi_1 e^{\phi_2 x_i} \cos(\phi_3 x_i + \phi_4))^2}_{\epsilon_i},$$

y sus derivadas respecto los coeficientes ϕ_1 , ϕ_2 , ϕ_3 , y ϕ_4 son:

$$\frac{\partial SEC}{\partial \phi_1} = 2 \sum_{i=1}^N (y_i - \phi_1 e^{\phi_2 x_i} \cos(\phi_3 x_i + \phi_4)) \frac{\partial \epsilon_i}{\partial \phi_1} = 0$$

$$\frac{\partial SEC}{\partial \phi_2} = 2 \sum_{i=1}^N (y_i - \phi_1 e^{\phi_2 x_i} \cos(\phi_3 x_i + \phi_4)) \frac{\partial \epsilon_i}{\partial \phi_2} = 0$$

$$\frac{\partial SEC}{\partial \phi_3} = 2 \sum_{i=1}^N (y_i - \phi_1 e^{\phi_2 x_i} \cos(\phi_3 x_i + \phi_4)) \frac{\partial \epsilon_i}{\partial \phi_3} = 0$$

$$\frac{\partial SEC}{\partial \phi_4} = 2 \sum_{i=1}^N (y_i - \phi_1 e^{\phi_2 x_i} \cos(\phi_3 x_i + \phi_4)) \frac{\partial \epsilon_i}{\partial \phi_4} = 0$$

Relación entre regresión y correlación

El coeficiente de correlación, r , nos informa de que tanto dos (o mas) variables covarian en el espacio-tiempo. Para dos variables aleatorias x e y , el coeficiente de correlación es

$$r = \rho_{xy} = \frac{\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2} \sqrt{\frac{1}{N-1} \sum_{i=1}^N (y_i - \bar{y})^2}} = \frac{C_{xy}}{s_x s_y},$$

donde C_{xy} es la covarianza de x e y , y s_x y s_y son las correspondientes desviaciones estandar.

Propiedades del coeficiente de correlación

- (1) r es adimensional.
- (2) la magnitud de r se encuantra acotada entre -1 y 1 , ya que es una normalización de la covarianza por el producto de la desviación estandar de las dos variables aleatorias.

1180 Si $r = \pm 1$ entonces el ajuste es perfecto. Para $r = 0$ los puntos estan
 1181 dispersos aleatoriamente y no existe relación alguna entre las variables.
 1182 Normalmente encontramos el estadístico r^2 en lugar de r . r^2 se puede
 1183 reescribir como

$$r^2 = SCR/SCT = \frac{SCT - SEC}{SCT} = 1 - \frac{SEC}{SCT} = \frac{C_{xy}^2}{(s_x s_y)^2},$$

1184 lo que nos informa del porcentaje de la varianza explicada ($r^2 =$ varianza explicada/varianza total)
 1185 como vimos anteriormente. Un valor de $r = 0.75$ significa que la regre-
 1186 sión lineal de y sobre x , es decir \hat{y} , explica $100 * r^2 = 56.25\%$ de la
 1187 varianza total de la muestra.
 1188 Finalmente puntualizar que también podemos calcular el coeficiente
 1189 de correlación utilizando los estimados de los coeficientes de regresión.
 1190 Para el caso de una línea recta sabemos

$$\hat{b}_1 = \frac{C_{xy}}{s_x^2}.$$

1191 Si sustituimos en la definición de r obtenemos

$$r = \hat{b}_1 \frac{s_x^2}{s_x s_y} = \hat{b}_1 \frac{s_x}{s_y}.$$

1192 Coeficiente de correlación ajustado

1193 Con el fin de considerar los grados de libertad del modelo de regresión
 1194 lineal, el coeficiente de correlación debe ser ajustado en función del
 1195 número de variables independientes k . Para ello hay que considerar la
 1196 verdadera varianza de los errores

$$Var(SEC) = \frac{SEC}{N - k - 1},$$

1197 y de la variable dependiente

$$Var(SCT) = \frac{SCT}{N - 1}.$$

1198 Puesto que los grados de libertad no son iguales ($N - 1$ vs $N - k - 1$), el
 1199 coeficiente de correlación ajustado al cuadrado (\tilde{r}^2) se define como

$$\begin{aligned} \tilde{r}^2 &= 1 - \frac{Var(SEC)}{Var(SCT)} = 1 - \frac{SEC/N - k - 1}{SCT/N - 1} = 1 - \frac{N - 1}{N - k - 1}(1 - r^2) = \\ &= 1 - (1 - r^2) \frac{N - 1}{N - k - 1}, \end{aligned}$$

1201 donde para $k = 0$ obtenemos la definición clásica del coeficiente de
 1202 correlación.

Intervalo de confianza para el coeficiente de correlación

Podemos calcular intervalos de confianza para el coeficiente de correlación r por medio de la denominada transformación Z de Fisher. Básicamente transforma r en una variable normal estandar Z

$$Z = \frac{1}{2} \frac{\ln(1+r)}{\ln(1-r)},$$

con desviación estandar

$$\sigma(Z) = \frac{1}{\sqrt{(N-3)}},$$

y media

$$\mu(Z) = \frac{1}{2} \frac{\ln(1+\rho_0)}{\ln(1-\rho_0)},$$

donde $\mu(Z)$ es la media esperada (media poblacional) del estadístico Z .

El intervalo de confianza se escribe entonces como

$$Z - Z_{\alpha/2} < Z < Z + Z_{\alpha/2}$$

****Ejemplo**:**

Supongamos $N = 21$ y $r = 0.8$. Encuentra el intervalo de confianza al 95% para el coeficiente de correlación poblacional ρ_0 .

$$Z = \frac{1}{2} \frac{\ln(1+0.8)}{\ln(1-0.8)} = 1.0986$$

Puesto que Z esta Normalmente distribuida, entonces todos los valores deben de caer dentro de 1.96 desviaciones estandar de Z . Entonces, al 95%, la verdadera media μ_Z esta contenida en

$$Z - 1.96\sigma(Z) < \mu(Z) < Z + 1.96\sigma(Z)$$

$$Z - 1.96 \frac{1}{\sqrt{(21-3)}} < \mu(Z) < Z + 1.96 \frac{1}{\sqrt{(21-3)}} \\ 0.6366 < \mu(Z) < 1.5606$$

Los límites encontrados para $\mu(Z)$ los podemos transformar en términos de la verdadera correlación

$$\mu(Z) = 0.6366 = \frac{1}{2} \left\{ \frac{1+\rho}{1-\rho} \right\} \rightarrow \rho = 0.56,$$

donde hemos usado

$$\begin{aligned} e^{2\mu} &= \frac{1+\rho}{1-\rho} \\ e^{2\mu}-1 &= \rho(1+e^{2\mu}) \\ \rho &= \frac{(e^{2\mu(Z)}-1)}{(e^{2\mu(Z)}+1)}. \end{aligned}$$

1222

1223

1224 Podemos afirmar con un 95% de confianza que la verdadera correlación
 1225 ρ esta en el intervalo $0.56 < \rho, 0.92$, dado un tamaño muestral $N = 21$
 1226 y una correlación muestral $r = 0.8$.

1227

Verdaderos grados de libertad

1228

1229

1230

1231

1232

1233

Ya hemos definido anteriormente los grados de libertad se define como el número de muestras independientes N menos el número de parámetros que se quieren estimar. Esta definición es un tanto incorrecta puesto que debemos de también asegurar que las N muestras son efectivamente independientes, es decir, no estan autocorreladas en el espacio-tiempo. Para considerar esto N debe reescribirse como

$$\begin{aligned} N^* &= \frac{N}{\left[\sum_{\tau=-\infty}^{\infty} C_{xx}(\tau)C_{yy}(\tau) + C_{xy}(\tau)C_{yx}(\tau) \right] / [C_{xx}(0)C_{yy}(0)]} = \\ &\frac{N}{\overline{\left[\sum_{\tau=-\infty}^{\infty} \rho_{xx}(\tau)\rho_{yy}(\tau) + \rho_{xy}(\tau)\rho_{yx}(\tau) \right]}}. \end{aligned}$$

1234

1235

1236

1237

1238

1239

1240

1241

1242

En general, series de datos suelen estar correlacionados en el espacio-tiempo y $N^* << N$. Cuanto mayores las escalas de correlación espaciales-temporales, menores los N^* . Esto nos hace pensar que es muy importante la selección de las escalas espaciales-temporales sobre las que queremos calcular un estadístico. Para extraer las escalas de interés podemos usar métodos espectrales y filtros. El proceso de filtrado se encarga de eliminar aquellas escalas que esperamos no contribuyen a la verdadera correlación pero pueden adicionar correlación artificial debido a errores instrumentales y de muestreo.

1243

5 Propagación de errores

1244

Regla 1

1245

1246

Si x e y tienen errores aleatorios independientes δx y δy , entonces el error en la suma $z = x + y$ es

$$\delta z = \sqrt{\delta x^2 + \delta y^2}.$$

1247

Regla 2

1248 Si x e y tienen errores aleatorios independientes δx y δy , entonces el
 1249 error en la multiplicación $z = xy$ es

$$\frac{\delta z}{z} = \sqrt{\left(\frac{\delta x^2}{x}\right) + \left(\frac{\delta y^2}{y}\right)}.$$

1250 **Regla 3**

1251 Si $z = f(x)$, donde $f()$ es una función dada, entonces

$$\delta z = |f'(x)|\delta x.$$

1252 **Formula general para propagación del error**

1253 Sea x_1, x_2, \dots, x_N medidas con incertidumbres $\delta x_1, \delta x_2, \dots, \delta x_N$. Supong-
 1254 amos que queremos determinar q , el cual es una función de x_1, x_2, \dots, x_N :

$$q = f(x_1, x_2, \dots, x_N).$$

1255 El error asociado a q es entonces

$$\delta q = \sqrt{\left(\frac{\partial q}{\partial x_1}\delta x_1\right)^2 + \dots + \left(\frac{\partial q}{\partial x_N}\delta x_N\right)^2}$$

1256 Si $q = x_1 + x_2$ entonces obtenemos la regla 1:

$$\frac{\partial q}{\partial x_1} = 1,$$

$$\frac{\partial q}{\partial x_2} = 1,$$

$$\delta q = \sqrt{\delta x_1^2 + \delta x_2^2}.$$

1257 Si $q = x_1 x_2$ entonces obtenemos la regla 2:

$$\frac{\partial q}{\partial x_1} = x_2,$$

$$\frac{\partial q}{\partial x_2} = x_1,$$

$$\delta q = \sqrt{x_2^2 \delta x_1^2 + x_1^2 \delta x_2^2} = \sqrt{q^2 \left[\left(\frac{\partial x_1}{x_1}\right)^2 + \left(\frac{\partial x_2}{x_2}\right)^2 \right]}.$$

$$\frac{\delta q}{q} = \sqrt{\left(\frac{\delta x_1^2}{x_1}\right) + \left(\frac{\delta x_2^2}{x_2}\right)}.$$

1260 *Demstración:*

1261 Queremos calcular la desviación estándar de la función

$$q = q(x_1, x_2, \dots, x_N),$$

1262 que depende de N variables independientes x_1, x_2, \dots, x_N . El desarrollo
1263 de Taylor de la función q alrededor de la media \bar{q} se puede escribir:

$$q - \bar{q} = (x_1 - \bar{x}_1) \frac{\partial q}{\partial x_1} + (x_2 - \bar{x}_2) \frac{\partial q}{\partial x_2} + \dots + (x_N - \bar{x}_N) \frac{\partial q}{\partial x_N}.$$

1264 La varianza de la función q es:

$$\begin{aligned} s_q^2 &= \frac{1}{N-1} \sum_{i=1}^N (q_i - \bar{q})^2 = \frac{1}{N-1} \left[(x_1 - \bar{x}_1) \frac{\partial q}{\partial x_1} + (x_2 - \bar{x}_2) \frac{\partial q}{\partial x_2} + \dots + (x_N - \bar{x}_N) \frac{\partial q}{\partial x_N} \right]^2 = \\ &= \frac{1}{N-1} \left[(x_1 - \bar{x}_1)^2 \left(\frac{\partial q}{\partial x_1} \right)^2 + (x_2 - \bar{x}_2)^2 \left(\frac{\partial q}{\partial x_2} \right)^2 + 2(x_1 - \bar{x}_1)(x_2 - \bar{x}_2) \frac{\partial q}{\partial x_1} \frac{\partial q}{\partial x_2} + \dots \right] = \\ &= s_{x_1}^2 \left(\frac{\partial q}{\partial x_1} \right)^2 + s_{x_2}^2 \left(\frac{\partial q}{\partial x_2} \right)^2 + 2s_{x_1 x_2} \frac{\partial q}{\partial x_1} \frac{\partial q}{\partial x_2} + \dots \end{aligned}$$

1265 y finalmente la expresión general para la propagación del error es:

$$s_q = \sqrt{s_{x_1}^2 \left(\frac{\partial q}{\partial x_1} \right)^2 + s_{x_2}^2 \left(\frac{\partial q}{\partial x_2} \right)^2 + 2s_{x_1 x_2} \frac{\partial q}{\partial x_1} \frac{\partial q}{\partial x_2} + \dots}$$

1266 **Ejemplo:**

1267 La ecuación para el cálculo de la salinidad a partir de la conductividad
1268 (C) y temperatura (T) es (Unesco EOS-80)

$$S = a_0 + a_1 R_T^{1/2} + a_2 R_T + a_3 R_T^{3/2} + a_4 R_T^2 + a_5 R_T^{5/2} + \Delta S,$$

1269 donde

$$R_T = \frac{R}{R_p r_t}, \quad R = \frac{C(S, T, 0)}{C(35, 15, 0)},$$

¹²⁷⁰ $C(35, 15, 0)$ es la conductividad de un agua de salinidad práctica 35 a
¹²⁷¹ los 15 °C,

$$r_t = c_0 + c_1 T + c_2 T^2 + c_3 T^3 + c_4 T^4,$$

$$R_p = 1 + \frac{P(e_1 + e_2 P + e_3 P^2)}{(1 + d_1 T + d_2 T^2 + (d_3 + d_4 T)R)},$$

¹²⁷² y

$$\Delta S = \frac{T - 15}{1 + k(T - 15)} (b_0 + b_1 R_T^{1/2} + b_2 R_T + b_3 R_T^{3/2} + b_4 R_T^2 + b_5 R_T^{5/2}),$$

¹²⁷³ con los coeficientes a_i, b_i, c_i, d_i , y e_i

$$\begin{aligned} a_0 &= 0.0080 & b_0 &= 0.0005 & c_0 &= 0.6766097 & d_1 &= \\ 3.426 e^{-2} & & e_1 &= 2.070 e^{-5} & a_1 &= -0.1692 & b_1 &= -0.0056 & c_1 &= \\ 2.00564 e^{-2} & & d_2 &= 4.464 e^{-4} & e_2 &= -6.370 e^{-10} & & & \\ a_2 &= 25.3851 & b &= -0.0066 & c_2 &= 1.104259 e^{-4} & d_3 &= \\ 4.215 e^{-1} & & e_3 &= 3.989 e^{-15} & & & & \\ a_3 &= 14.0941 & b &= -0.0375 & c_3 &= -6.9698 e^{-7} & d_4 &= -3.107 e^{-3} \\ a_4 &= -7.0261 & b_4 &= 0.0636 & c_4 &= 1.0031 e^{-9} & & & \\ a_5 &= 2.7081 & b_5 &= -0.0144 & & & & & \\ \sum a_i &= 35.0000 & \sum b_i &= 0.0000 & & & & & \\ k &= 0.0162 & & & & & & & \end{aligned}$$

¹²⁸⁴ Si el error de precisión del termistor y de la celda de conductividad del
¹²⁸⁵ CTD es $\delta T = 0.001^\circ\text{C}$ y $\delta C = 0.001 \text{ Sm}^{-1}$, respectivamente, calcule
¹²⁸⁶ la incertidumbre asociada al cálculo de la salinidad S a partir de la for-
¹²⁸⁷ mula general de propagación del error para $C = 5 \text{ S m}^{-1}$, $T = 28^\circ\text{C}$,
¹²⁸⁸ y $P = 50 \text{ dbar}$. Suponga que $\delta P = 0$, es decir, el altímetro no tiene
¹²⁸⁹ errores de precisión.

¹²⁹⁰ Resultado:

¹²⁹¹ El error estándar asociado a la salinidad es

$$\delta S = \sqrt{\left(\frac{\partial S}{\partial T} \delta T\right)^2 + \left(\frac{\partial S}{\partial C} \delta C\right)^2},$$

¹²⁹² donde

$$\begin{aligned} \frac{\delta S}{\delta T} &= [(1 + k(T - 15))^{-1} - (k(T - 15))(1 + k(T - 15))^{-2}] \\ &\quad \left(b_0 + b_1 R_T^{1/2} + b_2 R_T + b_3 R_T^{3/2} + b_4 R_T^2 + b_5 R_T^{5/2}\right), \end{aligned}$$

¹²⁹⁴ y

$$\frac{\delta S}{\delta C} = \frac{1}{2} a_1 \frac{R_T^{-1/2}}{C(35, T, 0)} + a_2 \frac{1}{C(35, T, 0)} + \frac{3}{2} a_3 \frac{R_T^{1/2}}{C(35, T, 0)} +$$

$$+2a_4 \frac{R_T}{C(35, T, 0)} + \frac{5}{2}a_5 \frac{R_T^{3/2}}{C(35, T, 0)} + \frac{T - 15}{(1 + k(T - 15))}$$

$$\left(b_1 \frac{R_T^{-1/2}}{C(35, T, 0)} + b_2 \frac{1}{C(35, T, 0)} + \frac{3}{2}b_3 \frac{R_T^{1/2}}{C(35, T, 0)} + 2b_4 \frac{R_T}{C(35, T, 0)} + \frac{5}{2}b_5 \frac{R_T^{3/2}}{C(35, T, 0)} \right).$$

Por lo tanto, dada una medida de conductividad C y temperatura T podemos calcular $\delta S/\delta T$ y $\delta S/\delta C$ y obtener la desviación estándar asociado al cálculo de la salinidad δS .

Ejercicio:

Calcule el error estándar asociado a la densidad referenciada a la superficie que se obtiene al usar el algoritmo del estado del agua de mar (Unesco EOS-80)

$$\rho(S, T, 0) = \rho_w + (b_0 + b_1 T + b_2 T^2 + b_3 T^3 + b_4 T^4) S +$$

$$+ (c_0 + c_1 T + c_2 T^2) S^{3/2} + d_0 S^2,$$

con los coeficientes b_i , c_i , y d_0

$$b_0 = 8.24493 e^{-1} \quad c_0 = -5.72466 e^{-3} \quad b_1 = -4.0899 e^{-3} \quad c_1 = 1.0227 e^{-4}$$

$$b_2 = 7.6438 e^{-5} \quad c_2 = -1.6546 e^{-6}$$

$$b_3 = -8.2467 e^{-7} \quad b_4 = 5.3875 e^{-9} \quad d_0 = 4.8314 e^{-4},$$

y la densidad de referencia para agua pura (ρ_w) definida como:

$$\rho_w = a_0 + a_1 T + a_2 T^2 + a_3 T^3 + a_4 T^4 + a_5 T^5,$$

donde los coeficientes a_i son:

$$a_0 = 999.842594 \quad a_1 = 6.793952 e^{-2} \quad a_2 = -9.095290 e^{-3} \quad a_3 = 1.001685 e^{-4} \quad a_4 = -1.120083 e^{-6} \quad a_5 = 6.536332 e^{-9}.$$

6 Métodos de Interpolación

Interpolación es el procedimiento para el cual obtenemos valores de propiedades en posiciones o tiempos que nunca fueron muestreados a partir de observaciones existentes en otras localizaciones o tiempos. En oceanografía necesitamos interpolar (i) para llenar huecos cuando el instrumento dejó de medir, (ii) para obtener mapas espaciales de contornos (2D), (iii) para calcular alguna propiedad derivada en un punto concreto

6.1 Interpolación Lineal

La interpolación mas sencilla, pero no por ello peor, es la interpolación lineal. Esta interpolación se basa en ajustar una línea recta entre los puntos conocidos, e interpolar cualquier punto intermedio como un punto a lo largo de la recta. Este tipo de interpolación puede ser usado

para rellenar huecos en nuestras series temporales. La interpolación lineal de unas serie $y(t)$ se puede escribir como

$$y(t_i) = y(t_0) + \frac{y(t_1) - y(t_0)}{t_1 - t_0}(t_i - t_0).$$

6.2 Interpolación polinómica

En el caso que queramos interpolar entre mas de dos puntos simultáneamente, debemos de usar polinomios de orden superior a la recta (orden 1). Es decir,

$$y(x) = a_0 + a_1x + a_2x^2 + \dots + a_{n-1}x^{n-1} + a_nx_n.$$

Si tomamos N observaciones ($y_i(x) ; i = 0, 2, \dots, N - 1$) obtenemos un sistema de N ecuaciones

$$\begin{pmatrix} 1 & x_0 & \dots & x_0^{N-1} & x_0^N \\ 1 & x_1 & \dots & x_1^{N-1} & x_1^N \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 1 & x_N & \dots & x_N^{N-1} & x_N^N \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ \vdots \\ a_N \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ \vdots \\ y_N \end{pmatrix},$$

lo cual se puede resolver con eliminación Gauss-Jordan. Este método es muy lento y por ello se usa el método de Lagrange.

{ Método de Lagrange}

De nuevo asumimos

$$p(x) = a_0 + a_1x + a_2x^2 + \dots + a_{n-1}x^{n-1} + a_nx_n = \sum_{k=0}^N a_kx^k = \sum_{i=1}^{N+1} y_iL_i(x),$$

donde

$$L_i(x) = \prod_{\substack{k=1 \\ k \neq i}}^{N+1} \frac{x - x_k}{x_i - x_k},$$

son los denominados polinomios de Lagrange, y \prod es el operador producto. Puesto que este operador cuando $k \neq i$ no incluye el producto, a pesar que varíe de 1 a $N + 1$, obtendremos un polinomio de orden N .

Esta suma de polinomios de Lagrange es el polinomio de menor grado que interpola un conjunto de datos, es decir,

$$p(x_j) = \sum_{i=1}^{N+1} y_iL_i(x_j) = y_j.$$

{Demostración:}

Los polinomios de Lagrange para $i \neq j$ son iguales a cero, y para $i = j$ son iguales a 1. Veamos esto:

$$(1) \text{ Para } i \neq j : L_i(x_j) = \prod_{\substack{k=1 \\ k \neq i}}^{N+1} \frac{x_j - x_k}{x_i - x_k} =$$

1345

$$= \frac{x_j - x_1}{x_i - x_1} \frac{x_j - x_2}{x_i - x_2} \dots \frac{x_j - x_j}{x_i - x_j} \dots \frac{x_j - x_{N+1}}{x_i - x_{N+1}}$$

$$(2) \text{ Para } i = j : L_i(x_j) = \prod_{\substack{k=1 \\ k \neq i}}^{N+1} \frac{x_j - x_k}{x_j - x_k} = 1$$

1346

De modo que

$$L_i(x_j) = \delta_{ij} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}.$$

1347

Finalmente podemos concluir entonces que

$$p(x_j) = \sum_{i=1}^{N+1} y_i L_i(x_j) = \sum_{i=1}^{N+1} y_i \delta_{ij} = y_j.$$

1348

es un polinomio de grado no mayor a N y que $p(x_j) = y_j$.

1349

El polinomio se puede reescribir en términos de la función Q_i como

$$p(x) = \sum_{i=1}^{N+1} y_i [Q_i(x)/Q_i(x_i)],$$

1350

donde

$$Q_i(x) = (x - x_1)(x - x_2) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_{N-1}),$$

1351

es el producto de todas las diferencias excepto la posición i (i.e., $x - x_i$).

1352

Si expandemos $p(x)$

$$\begin{aligned} p(x) = y_1 \frac{(x - x_2)(x - x_3) \dots (x - x_{N+1})}{(x_1 - x_2)(x_1 - x_3) \dots (x_1 - x_{N+1})} + y_2 \frac{(x - x_1)(x - x_3) \dots (x - x_{N+1})}{(x_2 - x_1)(x_2 - x_3) \dots (x_2 - x_{N+1})} + \\ + \dots + y_{N+1} \frac{(x - x_1)(x - x_2) \dots (x - x_N)}{(x_{N+1} - x_1)(x_{N+1} - x_2) \dots (x_{N+1} - x_N)}. \end{aligned}$$

1353

1354

{ Ejemplo: }

1355

Considere los puntos $(0,2)$, $(1,2)$, $(2,0)$ y $(3,0)$ para los cuales queremos ajustar un polinomio de orden 3

$$\begin{aligned} y(x) = 2 \frac{(x-1)(x-2)(x-3)}{(0-1)(0-2)(0-3)} + 2 \frac{(x-0)(x-2)(x-3)}{(1-0)(1-2)(1-3)} + 0 + 0 = \\ = \frac{2}{3}x^3 - 3x^2 + \frac{7}{3}x + 2. \end{aligned}$$

1356

1357

1358 6.3 Spline cúbico

1359 La interpolación por spline cúbicos es un método de ajuste de poli-
 1360 nomios de orden 3 por segmentos. Veamos este método con un ejemplo.

1361 Supongamos que queremos interpolar los siguientes datos $(x_i, y_i) =$
 1362 $[(2, -1), (3, 2), (5, -7)]$ con una spline cúbica. Primero definimos un
 1363 polinomio cúbico para cada intervalo:

$$1364 s(x) = a_1x^3 + b_1x^2 + c_1x + d_1 \quad \text{si } x \in [2, 3]$$

$$s(x) = a_2x^3 + b_2x^2 + c_2x + d_2 \quad \text{si } x \in [3, 5]$$

1365 A continuación debemos de asegurar que los polinomios pasan por los
 1366 puntos del problema:

$$1367 s(2) = 8a_1 + 4b_1 + 2c_1 + d_1 = -1$$

$$1368 s(3) = 27a_1 + 9b_1 + 3c_1 + d_1 = 2$$

$$1369 s(3) = 27a_2 + 9b_2 + 3c_2 + d_2 = 2$$

$$s(5) = 125a_2 + 25b_2 + 5c_2 + d_2 = -7$$

1370 Ahora calculamos la primera y segundas derivadas para cada intervalo

$$1371 s'(x) = 3a_1x^2 + 2b_1x + c_1 \quad \text{si } x \in [2, 3]$$

$$1372 s'(x) = 3a_2x^2 + 2b_2x + c_2 \quad \text{si } x \in [3, 5]$$

$$1373 s''(x) = 6a_1x + 2b_1 \quad \text{si } x \in [2, 3]$$

$$s''(x) = 6a_2x + 2b_2 \quad \text{si } x \in [3, 5]$$

1374 y aseguramos que sean continuas. Para ello debemos de igualar las
 1375 derivadas entre intervalos de manera que no hayan discontinuidades

$$1376 3a_1(3)^2 + 2b_1(3) + c_1 = 3a_2(3)^2 + 2b_2(3) + c_2 \rightarrow 27a_1 + 6b_1 + c_1 = 27a_2 + 6b_2 + c_2$$

$$6a_1(3) + 2b_1 = 6a_2(3) + 2b_2 \rightarrow 18a_1 + 2b_1 = 18a_2 + 2b_2$$

1377 En este momento tenemos 6 ecuaciones y 8 incógnitas. Debemos por lo
 1378 tanto encontrar dos ecuaciones mas. Para ello vamos a forzar que en los
 1379 extremos la segunda derivada sea nula, es decir, no haya curvatura

$$1380 s''(x_0) = s''(2) = 0 \rightarrow 6a_1(2) + 2b_1 = 0 \rightarrow 12a_1 + 2b_1 = 0$$

$$s''(x_N) = s''(5) = 0 \rightarrow 6a_2(5) + 2b_2 = 0 \rightarrow 30a_2 + 2b_2 = 0$$

1381 Ahora ya tenemos un sistema determinado, es decir, 8 ecuaciones y 8
 1382 incógnitas

$$1383 8a_1 + 4b_1 + 2c_1 + d_1 = -1$$

$$1384 27a_1 + 9b_1 + 3c_1 + d_1 = 2$$

$$27a_2 + 9b_2 + 3c_2 + d_2 = 2$$

$$1385 125a_2 + 25b_2 + 5c_2 + d_2 = -7$$

$$\begin{aligned}
 1386 \quad & 27a_1 + 6b_1 + c_1 = 27a_2 + 6b_2 + c_2 \\
 1387 \quad & 18a_1 + 2b_1 = 18a_2 + 2b_2 \\
 1388 \quad & 12a_1 + 2b_1 = 0 \\
 1389 \quad & 30a_2 + 2b_2 = 0
 \end{aligned}$$

1390 Lo cual en notación matricial se puede escribir

$$\left(\begin{array}{ccccccc} 8 & 4 & 2 & 1 & 0 & 0 & 0 \\ 27 & 9 & 3 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 27 & 9 & 3 \\ 0 & 0 & 0 & 0 & 125 & 25 & 5 \\ 27 & 6 & 1 & 0 & -27 & -6 & -1 \\ 18 & 2 & 0 & 0 & -18 & -2 & 0 \\ 12 & 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 30 & 2 & 0 \end{array} \right) \left(\begin{array}{c} a_1 \\ b_1 \\ c_1 \\ d_1 \\ a_2 \\ b_2 \\ c_2 \\ d_2 \end{array} \right) = \left(\begin{array}{c} -1 \\ 2 \\ 2 \\ -7 \\ 0 \\ 0 \\ 0 \\ 0 \end{array} \right)$$

1391 Este sistema se puede resolver facilmente si la matriz de datos es invertible.
 1392 Los coeficientes resultantes son

$$\begin{aligned}
 1393 \quad & a_1 = -1.25 \quad b_1 = 7.5 \quad c_1 = -10.75 \quad d_1 = 0.5 \\
 & a_1 = 0.625 \quad b_1 = -9.375 \quad c_1 = 39.875 \quad d_1 = -50.125,
 \end{aligned}$$

1394 y los polinomios de nuestra spline cúbica es

$$\begin{aligned}
 1395 \quad & s(x) = -1.25x^3 + 7.5x^2 - 10.75x + 0.5 \quad \text{si } x \in [2, 3] \\
 & s(x) = 0.625x^3 + -9.375x^2 + 39.875x + 50.125 \quad \text{si } x \in [3, 5]
 \end{aligned}$$

Figura. Comparación entre ajuste de un polinomio de orden 6 por método de cuadrados mínimos, interpolación de Lagrange, e interpolación spline cúbica.

7 Interpolación Objetiva

Un mapa objetivo se obtiene como una regresión múltiple (donde el error cuadrático medio es mínimo) de un conjunto de observaciones discretas. Se utiliza en oceanografía para obtener mapas continuos (mallas regulares) a partir de datos discretos distribuidos irregularmente en el espacio. Las variables representadas en el mapa objetivo pueden modificarse de una realización a otra, con lo que deben de considerarse las anomalías de las variables en lugar de las variables en si mismas. Se debe de definir un ensemble (promedio), climatología, o candidato y extraerlo a cada variable para obtener anomalías. Este proceso de elección de la media es una parte delicada de la interpolación objetiva. En general, para el océano, la media es desconocida ya que solamente tenemos pocas realizaciones de nuestro muestreo. Una forma de operar es estimar la media ajustando un polinomio de bajo orden a nuestros datos discretos, extraer esta a los datos y proceder con la interpolación objetiva. La media se añade de nuevo despues de calcular el mapa objetivo de las fluctuaciones. \

1413 Típicamente se debe asumir dos condiciones: \

- 1414 (1) El error (o ruido) asociado a la interpolación no esta correla-
 1415 cionado con nuestra señal (variable a interpolar)

$$\langle \phi_i \epsilon_i \rangle = 0$$

- 1416 \\\
 1417 (2) El error no esta correlacionado de una estación a la otra

$$\langle \epsilon_i \epsilon_j \rangle = \begin{cases} \langle \epsilon^2 \rangle & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}$$

1418 Supongamos entonces fluctuaciones respecto un estado climatológico o
 1419 media

$$\phi'_i = \phi_i - \bar{\phi}; i = 1, 2, \dots, N$$

1420 Ahora vamos a intentar aproximar el valor de ϕ' en un punto de una
 1421 malla, ϕ_g , en términos de una combinación lineal de los valores en esta-
 1422 ciones vecinas ϕ_i (señal). Entonces el problema de mínimos cuadrados
 1423 es

$$\phi'_g = \sum_{i=1}^N b_i \phi'_i$$

1424 donde ϕ'_g son anomalías en la malla regular y ϕ'_i son anomalías en las
 1425 estaciones. Los mejores coeficientes son aquellos que minimizan el error
 1426 cuadrático medio, es decir,

$$\begin{aligned} SEC &= \sum_{i=1}^N \left(\phi'_g - \sum_{i=1}^N b_i \phi'_i \right)^2 = \sum_{i=1}^N \left(\phi'_g - \sum_{i=1}^N b_i \phi'_i \right) \left(\phi'_g - \sum_{i=1}^N b_i \phi'_i \right) = \\ &\quad \sum_{i=1}^N \left[\phi'_g \phi'_g - 2 \sum_{i=1}^N b_i \phi'_g \phi'_i + \sum_{i=1}^N \sum_{j=1}^N b_i b_j \phi'_i \phi'_j \right] = \\ &= \sum_{i=1}^N \phi'_g \phi'_g - 2 \sum_{i=1}^N b_i \sum_{i=1}^N \phi'_g \phi'_i + \sum_{i=1}^N \sum_{j=1}^N b_i b_j \sum_{i=1}^N \phi'_i \phi'_j. \end{aligned}$$

1429 El error normalizado se puede escribir como

$$\begin{aligned} \epsilon &= \frac{SEC}{\sum_{i=1}^N \phi'_g \phi'_g} = 1 - 2 \sum_{i=1}^N b_i \frac{\sum_{i=1}^N \phi'_g \phi'_i}{\sum_{i=1}^N \phi'_g \phi'_g} + \sum_{i=1}^N \sum_{j=1}^N b_i b_j \frac{\sum_{i=1}^N \phi'_i \phi'_j}{\sum_{i=1}^N \phi'_g \phi'_g} = \\ &= 1 - 2 \sum_{i=1}^N b_i r_{gi} + \sum_{i=1}^N \sum_{j=1}^N b_i b_j r_{ij}, \end{aligned}$$

1431 donde

$$r_{gi} = \frac{\sum_{i=1}^N \phi'_g \phi'_i}{\sum_{i=1}^N \phi'_g \phi'_g} \quad \text{y} \quad r_{ij} = \frac{\sum_{i=1}^N \phi'_i \phi'_j}{\sum_{i=1}^N \phi'_g \phi'_g},$$

¹⁴³² son matrices de correlación entre el punto de malla y las estaciones, y
¹⁴³³ entre las estaciones, respectivamente.

¹⁴³⁴ Si derivamos ϵ respecto los coeficientes, obtenemos la condición de mini-
¹⁴³⁵ mización:

$$\frac{\partial \epsilon}{\partial b_i} = -2r_{gi} + 2 \sum_{j=1}^N b_j r_{ij} = 0 \quad i = 1, 2, \dots, N.$$

¹⁴³⁶

$$r_{gi} = \sum_{j=1}^N b_j r_{ij},$$

¹⁴³⁷ y los coeficientes en notación índice son

$$b_j = (r_{ij})^{-1} r_{gi}$$

¹⁴³⁸ Finalmente, el valor de la medida en el punto de malla es

$$\phi'_g = r_{gi} (r_{ij})^{-1} \phi'_i$$

¹⁴³⁹ o en notación matricial para un único punto de malla

$$\phi'_g = r_{gs} (r_{ss})^{-1} \phi',$$

¹⁴⁴⁰ donde ϕ'_g es el valor de la anomalía en un punto de malla (matriz ele-
¹⁴⁴¹ mento, 1×1), r_{gs} es un vector fila compuesto por las correlaciones entre
¹⁴⁴² el punto de malla y las estaciones de medida, r_{ss} es una matriz de cor-
¹⁴⁴³relaciones entre todas las estaciones, y ϕ' es un vector columna con las
¹⁴⁴⁴anomalías en las estaciones.

¹⁴⁴⁵ En el caso de que tengamos N puntos de malla y k estaciones de me-
¹⁴⁴⁶ dida, las ecuaciones básicas de la interpolación objetiva se pueden es-
¹⁴⁴⁷cribir en notación matricial como

$$\begin{pmatrix} \phi'_{g_1} \\ \phi'_{g_2} \\ \vdots \\ \phi'_{g_N} \end{pmatrix} = \begin{pmatrix} r_{g_11} & r_{g_12} & \dots & r_{g_1k} \\ r_{g_21} & r_{g_22} & \dots & r_{g_2k} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ r_{g_N1} & r_{g_N2} & \dots & r_{g_Nk} \end{pmatrix} \begin{pmatrix} r_{11} & r_{12} & \dots & r_{1k} \\ r_{21} & r_{22} & \dots & r_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ r_{k1} & r_{k2} & \dots & r_{kk} \end{pmatrix}^{-1} \begin{pmatrix} \phi'_1 \\ \phi'_2 \\ \vdots \\ \phi'_k \end{pmatrix}.$$

1448 $(N \times 1)$ $(N \times k)$ $(k \times k)$ $(k \times 1)$

\backslash

1450 El error normalizado ϵ asociado al mapa interpolado es

$$\begin{aligned} \epsilon &= 1 - 2 \sum_{j=1}^N b_j r_{gi} + \sum_{i=1}^N \sum_{j=1}^N b_i b_j r_{ij} = 1 - 2 \sum_{j=1}^N b_j \sum_{j=1}^N b_j r_{ij} + \sum_{i=1}^N \sum_{j=1}^N b_i b_j r_{ij} = \\ &= 1 - 2 \sum_{i=1}^N \sum_{j=1}^N b_i b_j r_{ij} + \sum_{i=1}^N \sum_{j=1}^N b_i b_j r_{ij} = 1 - \sum_{i=1}^N \sum_{j=1}^N b_i b_j r_{ij} = \\ &= 1 - \sum_{j=1}^N b_j \sum_{j=1}^N b_j r_{ij} = 1 - \sum_{i=1}^N r_{gi} b_i, \end{aligned}$$

1453 o en notación matricial para un único punto de malla

$$\epsilon = 1 - r_{gs} (r_{ss})^{-1} r_{gs}^T.$$

1454 En el caso de N puntos de malla y k estaciones

$$\begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{pmatrix} = \text{Diag} \left[\mathbf{I} - \begin{pmatrix} r_{g_11} & r_{g_12} & \dots & r_{g_1k} \\ r_{g_21} & r_{g_22} & \dots & r_{g_2k} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ r_{g_N1} & r_{g_N2} & \dots & r_{g_Nk} \end{pmatrix} \begin{pmatrix} r_{11} & r_{12} & \dots & r_{1k} \\ r_{21} & r_{22} & \dots & r_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ r_{k1} & r_{k2} & \dots & r_{kk} \end{pmatrix}^{-1} \begin{pmatrix} r_{g_11} & r_{g_21} & \dots & r_{g_N1} \\ r_{g_12} & r_{g_22} & \dots & r_{g_N2} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ r_{g_1k} & r_{g_2k} & \dots & r_{g_Nk} \end{pmatrix} \right] \begin{pmatrix} (N \times 1) \\ (N \times k) \\ (k \times k) \\ (k \times N) \end{pmatrix}$$

1456 Este error es tal vez la característica mas importante de la interpolación
1457 objetiva. En general solo se muestra el mapa interpolado en las regiones
1458 donde ϵ es menor que un cierto valor. El error solo depende en las local-
1459 izaciones de las estaciones y no en un valor particular de la medida. Es
1460 por ello que esta técnica puede ser usada para el diseño de experimen-
1461 tos. Es decir, nos sirve para saber cual debe ser la distribución óptima
1462 de las estaciones de medida para obtener el error mínimo en el mapa.1463 **Nota:** Si un punto de observación, $i = k$, coincide con un punto de
1464 malla, entonces $r_{gk} = r_{kk} = 1$, y esperamos que el método de regresión
1465 nos de $b_k = 1$ y todos los demás pesos sean igual a cero. En este caso
1466 el valor interpolado en el punto de malla es igual al valor medido en la
1467 estación $\phi' * g = r * gk(r_{kk}) - 1\phi'_k = 1(1) - 1\phi'_k = \phi'_k$. En este
1468 caso el error es cero, $\epsilon = 1 - r_{gk}(r_{kk})^{-1} r_{gk}^T = 1 - 1(1)^{-1} 1 = 0$, ya que
1469 hemos asumido que los datos son perfectos. Si los puntos de las esta-
1470 ciones estan decorrelacionados con el punto de malla en cuestión (i.e.,
1471 muy lejos de las estaciones), entonces $b_i = 0$ y $\epsilon = 1$, y recuperamos la
1472 media o climatología

$$\phi'_g = \sum_{i=1}^N b_i \phi'_i = 0 \rightarrow \phi'_g = \phi_g - \bar{\phi} = 0 \quad \text{and} \quad \phi_g = \bar{\phi}$$

Error observacional:

Vamos asumir ahora que las mediciones en las estaciones no son perfectas, es decir,

$$\phi'_i = E[\phi'_i] + \delta_i.$$

Igual que anteriormente asumimos que el error de instrumentación δ_i no esta correlacionado con la señal verdadera

$$\langle E[\phi_i]\delta_i \rangle = 0,$$

y que el error instrumental entre estaciones tampoco esta correlacionado

$$\langle \epsilon_i \epsilon_j \rangle = \begin{cases} \langle \delta^2 \rangle & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}$$

En este caso obtenemos

$$\epsilon = 1 - 2 \sum_{i=1}^N b_i r_{gi} + \sum_{i=1}^N \sum_{j=1}^N b_i b_j r_{ij} + \eta \sum_{i=1}^N b_i^2,$$

donde η es el cociente entre la varianza del error (ruido) y la varianza de las medidas, es decir el cociente ruido-señal

$$\eta = \frac{\langle \delta^2 \rangle}{\langle \phi'_g \phi'_g \rangle}.$$

La minimización del error nos da la condición

$$r_{gi} = \sum_{j=1}^N b_j r_{ij} + \eta b_i,$$

y los coeficientes en notación índice son

$$b_j = (r_{ij} + \eta I_{ij})^{-1} r_{gi},$$

donde I_{ij} es la matriz identidad. De esta expresión se deduce que cuando η es grande (mucho ruido en la medida) entonces los coeficientes son mas pequeños respecto al caso de observaciones perfectas. Consecuentemente nuestro mapa interpolado se acerca mas a la climatología ya que la anomalía es menor para coeficientes mas pequeños

$$\downarrow \sum_{i=1}^N b_i \phi'_i \rightarrow \downarrow \phi'_g \quad \text{y} \quad \phi_g \rightarrow \bar{\phi}.$$

Incluyendo errores observacionales, la interpolación objetiva tenderá a la climatología o media y las nuevas observaciones serán incluidas pero con menos pesos. También podemos añadir diferentes errores ruido-señal en

la diagonal principal para darle menos peso a las estaciones de medida que tienen mas incertidumbre asociada. Es conveniente entonces añadir errores observacionales al esquema de interpolación objetiva. Otra razón para ello es el caso en que existan dos estaciones que coincidan exactamente con un punto de malla. En este caso, si no hemos añadido error observacional la matriz de correlaciones entre las estaciones se convierte singular y el esquema de interpolación objetiva no se puede resolver. Por ejemplo para la interpolación en un único punto de malla a partir de dos estaciones de medida, la matriz de correlaciones sería singular

$$r_{ss} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

La anomalía interpolada en notación matricial en un punto de malla es ahora

$$\phi'_g = r_{gs}(r_{ss} + \eta I)^{-1}\phi',$$

y el error asociado al mapa interpolado en notación matricial en un único punto de malla es

$$\epsilon = 1 - r_{gs}(r_{ss} + \eta I)^{-1}r_{gs}^T.$$

Para el caso de N puntos de malla y k estaciones obtenemos el mismo sistema que para el caso de medidas perfectas pero añadiendo el error ruido-señal en la diagonal principal de la matriz de correlaciones entre estaciones

$$\begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{pmatrix} = \text{Diag} \left[\mathbf{I} - \begin{pmatrix} r_{g_11} & r_{g_12} & \dots & r_{g_1k} \\ r_{g_21} & r_{g_22} & \dots & r_{g_2k} \\ \vdots & \vdots & \ddots & \vdots \\ r_{g_N1} & r_{g_N2} & \dots & r_{g_Nk} \end{pmatrix} \begin{pmatrix} r_{11} + \eta & r_{12} & \dots & r_{1k} \\ r_{21} & r_{22} + \eta & \dots & r_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ r_{k1} & r_{k2} & \dots & r_{kk} + \eta \end{pmatrix}^{-1} \begin{pmatrix} r_{g_11} & r_{g_21} & \dots & r_{g_N1} \\ r_{g_21} & r_{g_22} & \dots & r_{g_N2} \\ \vdots & \vdots & \ddots & \vdots \\ r_{g_N1} & r_{g_N2} & \dots & r_{g_Nk} \end{pmatrix} \right].$$

$$(N \times 1) \quad (N \times k) \quad (k \times k) \quad (k \times N)$$

8 Funciones Empíricas Ortogonales (FEOs)

8.1 Interpretación de los sistemas ‘propios’

Antes de entrar en la teoría para las FEOs, vamos a ver que los vectores propios son equivalentes a modos de oscilación de sistemas físicos. Imaginemos oscilaciones verticales de bolas en una cuerda. Las bolas tienen masa m y están separadas por cuerdas elásticas de longitud d en el equilibrio. Supongamos que los desplazamientos y_n son tan pequeños que la tensión de la cuerda \mathbf{T} se puede considerar constante. El ángulo de cada cuerda es θ como se ilustra en la figura. Entonces, la ecuación del movimiento para la bola n es

$$m \frac{d^2 y_n}{dt^2} = -T \sin \theta_{n-1} - T \sin \theta_n.$$

1519

Bajo la suposición de que los desplazamientos son pequeños, el $\sin \theta_n = \tan \theta_n$, es decir, $\sin \theta_{n-1} = \tan \theta_{n-1} = y_n - y_{n-1}/d$ y $\sin \theta_n = \tan \theta_n = (y_n - y_{n+1})/d$. Entonces la ecuación queda

$$m \frac{d^2 y_n}{dt^2} = -T \frac{y_n - y_{n-1}}{d} - T \frac{y_n - y_{n+1}}{d},$$

1523 y si reagrupamos

$$m \frac{d^2 y_n}{dt^2} = \frac{T}{d} (y_{n-1} - 2y_n + y_{n+1}).$$

1524 Vamos ahora a substituir una solución osculatoria del tipo

$$y_n = Y_n e^{i\omega t}$$

1525 en la ecuación del movimiento

$$\begin{aligned} -m\omega^2 Y_n e^{i\omega t} &= \frac{T}{d} (Y_{n-1} e^{i\omega t} - 2Y_n e^{i\omega t} + Y_{n+1} e^{i\omega t}) \\ \frac{-m\omega^2 d}{T} Y_n e^{i\omega t} &= \frac{T}{d} (Y_{n-1} e^{i\omega t} - 2Y_n e^{i\omega t} + Y_{n+1} e^{i\omega t}). \end{aligned}$$

1527 Si definimos

$$\lambda = \frac{m\omega^2 d}{T},$$

1528 el sistema de ecuaciones a resolver es

$$-\lambda Y_n = (Y_{n-1} - 2Y_n + Y_{n+1})$$

$$Y_n (2 - \lambda) - Y_{n-1} - Y_{n+1} = 0,$$

1530 con las condiciones de frontera $Y_0 = Y_{n+1} = 0$ en las paredes.

1531 Vamos a suponer ahora el caso de dos bolas. Para la primera bola $n = 1$

$$Y_1 (2 - \lambda) - Y_0 - Y_2 = 0,$$

1532 y para la bola $n = 2$

$$Y_2 (2 - \lambda) - Y_1 - Y_3 = 0.$$

1533 Si aplicamos las condiciones de frontera $Y_0 = Y_3 = 0$, nos queda un sistema “propio”, donde λ son los autovalores.

$$\begin{vmatrix} 2 - \lambda & -1 \\ -1 & 2 - \lambda \end{vmatrix} = 0.$$

1535 El polinomio característico es

$$\lambda^2 - 4\lambda + 3 = 0,$$

1536 y tienes las raíces $\lambda_1 = 1$ y $\lambda_2 = 3$.

1537 Resolvamos para los vectores propios:\

1538 (1) $\lambda_1 = 1$ entonces

$$Y_1 - Y_2 = 0$$

1539 y el vector propio es

$$\mathbf{y} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

1540 \

1541 (2) $\lambda_2 = 3$ entonces

$$-Y_1 - Y_2 = 0,$$

1542 y el vector propio es

$$\mathbf{y} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

1543 Estas soluciones representan los modos oscilatorios de un sistema físico
 1544 de dos bolas oscilando verticalmente. Los modos de oscilación se mues-
 1545 tran en la figura. Los modos oscilan independientemente uno de otro,
 1546 y la evolución del sistema es una combinación lineal de los dos modos.
 1547 De esta forma, lo que estamos haciendo al resolver el problema de las
 1548 bolas en una cuerda elástica es precisamente la solución de un sistema
 1549 “propio”.

1550

1551 8.2 Definición de FEOs

1552 Un análisis en FEOs busca estructuras en los datos que explican la
 1553 mayor cantidad de varianza de un conjunto de datos bidimensional. La
 1554 primera dimensión es la dimensión en la que deseamos encontrar una
 1555 estructura, y la otra dimensión es la dimensión en la que se muestran
 1556 las diferentes realizaciones. Por ejemplo, un conjunto de series tempo-
 1557 rales de datos distribuidos espacialmente (i.e. arreglo de anclajes). La
 1558 primera dimensión es espacio y la segunda es tiempo. Las estructuras
 1559 en la dimensión espacial son las FEOs, mientras que las estructuras en
 1560 la dimensión de muestreo se denominan Componentes Principales (CPs).
 1561 \ Tanto las FEOs como las PCs son ortogonales en sus dimensiones. Las
 1562 FEOs/PCs pueden entenderse de diferentes formas: \ (i) Transforma
 1563 variables correlacionadas en un conjunto de variables no correlacionadas
 1564 que expresan mejor la relación dinámica entre los datos originales. \
 1565 (ii) Identifica y ordena los vectores ortogonales (o dimensiones) a lo

largo de los cuales nuestro conjunto de datos presenta la mayor varianza. \ (iii) Una vez definidas las FEOs, es posible encontrar la mejor aproximación de los datos originales con el mínimo número de vectores ortogonales.

En general, aplicaremos el análisis en FEOs para describir de manera mas sencilla conjuntos de datos organizados en matrices $M \times N$:

- (1) Una matriz espacio-tiempo: Medidas de una variable en M localizaciones y N tiempos.
- (2) Una matriz parámetro-tiempo: Medidas de M variables en una localización y N tiempos.
- (3) Una matriz parámetro-espacio: Medidas de M variables tomadas en N localizaciones al mismo tiempo.

Nota: Un error común es considerar que las FEOs se corresponden con modos de físicos oceánicos. Eso no es cierto!. Los modos físicos en el océano son modos de oscilación que se obtienen considerando las ecuaciones que rigen el movimiento y condiciones de frontera; las FEOs son simplemente funciones ortogonales que explican la mayor cantidad de varianza de un conjunto de datos.

Aunque los procesos físicos dominantes son representados por los primeros modos de oscilación, no existe una correspondencia uno a uno entre modos físicos y FEOs.

8.3 Teoría

Supongamos M localizaciones de medición con series temporales de temperatura de N elementos. Queremos descomponer la serie temporal de temperatura en una localización dada k como una combinación lineal de M funciones ortogonales \mathbf{b}_i , cuyas amplitudes son pesadas con M coeficientes dependientes del tiempo, es decir,

$$\mathbf{T}(t) = \sum_{i=1}^M [\alpha_i(t) \mathbf{b}_i],$$

donde $\alpha_i(t)$ es la amplitud del modo ortogonal i al tiempo $t = t_n$ ($1 \leq n \leq N$). Los coeficientes $\alpha_i(t)$ nos informan de como varian los modos \mathbf{b}_i con el tiempo. Necesitamos tantas funciones ortogonales como estaciones con series temporales tenemos para poder describir la varianza total de los datos originales de temperatura a cada tiempo. Sin embargo, en términos prácticos podemos explicar una gran cantidad de varianza de los datos originales con las primeras FEOs. Podemos ver el problema al revés, es decir, tenemos N funciones temporales cuyas amplitudes son pesadas por M coeficientes que varian en el espacio. En este caso hablamos de PCs. Ya sea la reducción de los datos en funciones ortogonales espaciales (FEOs) o temporales (PCs), obtenemos los mismos resultados.

1605 Puesto que queremos \mathbf{b}_i ser ortogonal, requerimos

$$\mathbf{b}_i^T \mathbf{b}_j = \delta_{ij},$$

1606 y los coeficientes temporales $\alpha_i = \mathbf{b}_i^T \mathbf{T}(t)$. Son precisamente estos
1607 coeficientes temporales las CPs, es decir, la proyección de los datos orig-
1608 inales sobre las FEOs o la expresión de los datos originales en la nueva
1609 base de vectores ortogonales (el nuevo sistema de coordenadas).

1610 El objetivo del análisis es encontrar una base de vectores ortogonales tal
1611 que las funciones $\alpha_i(t)$ no estén correlacionadas

$$\langle \alpha_i \alpha_j \rangle = \langle \mathbf{b}_i^T \mathbf{T} \mathbf{b}_j^T \mathbf{T} \rangle = \langle \mathbf{b}_i^T \mathbf{T} \mathbf{T}^T \mathbf{b}_j \rangle = \mathbf{b}_i^T \langle \mathbf{T} \mathbf{T}^T \rangle \mathbf{b}_j = \delta_{ij} \langle \alpha_i^2 \rangle,$$

1612 donde

$$\langle \alpha_i^2 \rangle = \frac{1}{N} \sum_{n=1}^N = \alpha_i^2(t_n).$$

1613 Es decir, la matriz de covarianza de $\alpha_i(t)$ será una matriz diagonal \mathbf{D} .

1614 Para M posiciones se puede reescribir como

$$\mathbf{B}^T \langle \mathbf{T} \mathbf{T}^T \rangle \mathbf{B} = \mathbf{D} \quad \text{o} \quad \mathbf{B}^T \mathbf{T} \mathbf{T}^T \mathbf{B} = N \mathbf{D}$$

1615 donde \mathbf{B} es una matriz ortogonal cuyas columnas son los vectores ortog-
1616 onales \mathbf{b}_i y \mathbf{D} es una matriz diagonal compuesta por las varianzas de
1617 las funciones temporales $\alpha_i(t)$. Si multiplicamos por \mathbf{B} llegamos a un
1618 sistema propio

$$\langle \mathbf{T} \mathbf{T}^T \rangle \mathbf{B} = \mathbf{B} \mathbf{D}.$$

1619 Este tipo de sistema propio es conocido. La diagonal de \mathbf{D} esta com-
1620 puesta por valores propios y las columnas de \mathbf{B} son los vectores propios.
1621 Los vectores propios son denominados FEOs, y los valores propios son
1622 las varianzas de las amplitudes α_i . Básicamente hemos realizado una
1623 transformación de coordenadas de tal forma que los vectores propios \mathbf{b}_i
1624 indican combinaciones lineales de datos que no están correlacionados
1625 (i.e., $\langle \alpha_i \alpha_j \rangle = \delta_{ij} \langle \alpha_i^2 \rangle$). Esta descomposición de los datos en
1626 FEOs es óptima en el sentido de mínimos cuadrados. Imaginemos que
1627 queremos un conjunto de K vectores que mejor aproxima \mathbf{T}

$$\langle (\hat{\mathbf{T}} - \mathbf{T})^T (\hat{\mathbf{T}} - \mathbf{T}) \rangle = \langle \mathbf{T}^T \mathbf{T} \rangle - \sum_{i=1}^K \langle \alpha_i^2 \rangle.$$

1628 El problema en mínimos cuadrados, bajo las restricciones que las fun-
1629 ciones \mathbf{b}_i sean ortogonales, se puede escribir a partir de los multipli-
1630 cadores de Lagrange

$$L = \sum_{i=1}^K \left[\mathbf{b}_i^T \langle \mathbf{T} \mathbf{T}^T \rangle \mathbf{b}_i - \lambda_i (\mathbf{b}_i^T \mathbf{b}_i - 1) \right].$$

1631 Si derivamos L respecto de \mathbf{b}_i obtenemos el sistema propio

$$\langle \mathbf{T}\mathbf{T}^T \rangle \mathbf{b}_i = \lambda_i \mathbf{b}_i.$$

1632 De este análisis deducimos que las primeras K funciones ortogonales o
 1633 FEOs son las mejores funciones que explican la máxima varianza de los
 1634 datos originales, donde los valores propios están ordenados de mayor
 1635 a menor. Es decir, no existe un subset de datos más pequeño que K
 1636 funciones ortogonales que produce el error cuadrático medio menor. En
 1637 este sentido las FEOs son los mejores ‘descriptores’ de la varianza de los
 1638 datos.

1639 Una matriz de datos de M localizaciones y N tiempos se puede descomponer
 1640

$$\mathbf{C}\mathbf{B} = \mathbf{B},$$

1641 donde

$$\mathbf{C} = \mathbf{T}\mathbf{T}^T = \begin{pmatrix} \sum_{i=1}^N T_1(t_i)T_1(t_i) & \sum_{i=1}^N T_1(t_i)T_2(t_i) & \dots & \sum_{i=1}^N T_1(t_i)T_M(t_i) \\ \sum_{i=1}^N T_2(t_i)T_1(t_i) & \sum_{i=1}^N T_2(t_i)T_2(t_i) & \dots & \sum_{i=1}^N T_2(t_i)T_M(t_i) \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^N T_M(t_i)T_1(t_i) & \sum_{i=1}^N T_M(t_i)T_2(t_i) & \dots & \sum_{i=1}^N T_M(t_i)T_M(t_i) \end{pmatrix},$$

1642 es la matriz de covarianza entre las series temporales de temperatura en
 1643 localizaciones espaciales, unas con otras;

$$\mathbf{T} = \begin{pmatrix} T_1(t_1) & T_1(t_2) & \dots & T_1(t_N) \\ T_2(t_1) & T_2(t_2) & \dots & T_2(t_N) \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ T_M(t_1) & T_M(t_2) & \dots & T_M(t_N) \end{pmatrix}$$

1644 es la

1645 matriz de datos de temperatura;

$$\mathbf{B} = \begin{pmatrix} b_{11} & b_{12} & \dots & b_{1M} \\ b_{21} & b_{22} & \dots & b_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ b_{M1} & b_{M2} & \dots & b_{MM} \end{pmatrix},$$

1646 es la matriz con los vectores propios \mathbf{b}_i como columnas, y

$$= \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ 0 & 0 & \dots & \lambda_M \end{pmatrix},$$

1647 es la matriz diagonal compuesta por los valores propios $\lambda_i = \langle \alpha_i^2 \rangle$
 1648 Otra forma de entender las FEOs (PCs) consiste en un análisis en val-
 1649 ores propios de las matrices de dispersión de nuestras matrices de datos.
 1650 La matriz de dispersión es el producto matricial de la matriz con su
 1651 transpuesta, o a la inversa. La primera matriz de dispersión es

$$\mathbf{C} = \mathbf{T}\mathbf{T}^T = \begin{pmatrix} T_1(t_1) & T_1(t_2) & \dots & T_1(t_N) \\ T_2(t_1) & T_2(t_2) & \dots & T_2(t_N) \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ T_M(t_1) & T_M(t_2) & \dots & T_M(t_N) \end{pmatrix} \begin{pmatrix} T_1(t_1) & T_2(t_1) & \dots & T_M(t_1) \\ T_1(t_2) & T_2(t_2) & \dots & T_M(t_2) \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ T_1(t_N) & T_2(t_N) & \dots & T_M(t_N) \end{pmatrix} =$$

$$= \begin{pmatrix} \sum_{i=1}^N T_1(t_i)T_1(t_i) & \sum_{i=1}^N T_1(t_i)T_2(t_i) & \dots & \sum_{i=1}^N T_1(t_i)T_M(t_i) \\ \sum_{i=1}^N T_2(t_i)T_1(t_i) & \sum_{i=1}^N T_2(t_i)T_2(t_i) & \dots & \sum_{i=1}^N T_2(t_i)T_M(t_i) \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ \sum_{i=1}^N T_M(t_i)T_1(t_i) & \sum_{i=1}^N T_M(t_i)T_2(t_i) & \dots & \sum_{i=1}^N T_M(t_i)T_M(t_i) \end{pmatrix},$$

$$(M \times M)$$

1652 y la segunda es

$$\mathbf{C} = \mathbf{T}^T\mathbf{T} = \begin{pmatrix} T_1(t_1) & T_2(t_1) & \dots & T_M(t_1) \\ T_1(t_2) & T_2(t_2) & \dots & T_M(t_2) \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ T_1(t_N) & T_2(t_N) & \dots & T_M(t_N) \end{pmatrix} \begin{pmatrix} T_1(t_1) & T_1(t_2) & \dots & T_1(t_N) \\ T_2(t_1) & T_2(t_2) & \dots & T_2(t_N) \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ \cdot & \cdot & \ddots & \cdot \\ T_M(t_1) & T_M(t_2) & \dots & T_M(t_N) \end{pmatrix} =$$

$$\begin{aligned}
&= \left(\begin{array}{cccc} \sum_{i=1}^M T_i(t_1)T_i(t_1) & \sum_{i=1}^M T_i(t_1)T_i(t_2) & \dots & \sum_{i=1}^M T_i(t_1)T_i(t_N) \\ \sum_{i=1}^M T_i(t_2)T_i(t_1) & \sum_{i=1}^M T_i(t_2)T_i(t_2) & \dots & \sum_{i=1}^M T_i(t_2)T_i(t_N) \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^M T_i(t_N)T_i(t_1) & \sum_{i=1}^M T_i(t_N)T_i(t_2) & \dots & \sum_{i=1}^M T_i(t_N)T_i(t_N) \end{array} \right) \\
&\quad (N \times N)
\end{aligned}$$

Ambas matrices de dispersión obtenidas del producto de la matriz de datos consigo misma son matrices de covarianza simétricas. La primera matriz de dispersión $\mathbf{T}\mathbf{T}^T$ es una matriz $M \times M$ con lo que hemos eliminado la dimensión temporal o dimensión de muestreo. En este caso, la matriz de dispersión es una matriz de covarianzas temporales (determinadas por sus variaciones temporales) de las estaciones unas con otras. En la segunda matriz $\mathbf{T}^T\mathbf{T}$ se invierten las dimensiones, la matriz resultante es $N \times N$, y es una matriz de covarianzas espaciales (determinadas por sus variaciones espaciales) entre los diferentes tiempos.

Ejemplo: Un ejemplo sencillo viene dado por el diagrama de dispersión de la figura. La primera EOF o vector propio que explica la mayor varianza sería la recta que se ajusta al conjunto de puntos y la segunda EOF sería la línea perpendicular a la ajustada.

1667

1668 Relación entre FEOs y CPs

Como ya hemos visto nuestro sistema propio es

$$\mathbf{B}^T < \mathbf{T}\mathbf{T}^T > \mathbf{B} = \mathbf{D} \quad \text{o} \quad \mathbf{B}^T \mathbf{T}^T \mathbf{T} \mathbf{B} = N \mathbf{D},$$

donde \mathbf{B} es una matriz cuyas columnas son los vectores propios y \mathbf{D} es una matriz cuadrada con los M valores propios en la diagonal principal. Si queremos expresar los datos originales en términos de los vectores propios, entonces debemos usar la definición

$$\alpha_i(t) = \mathbf{b}_i^T \mathbf{T}(t),$$

que en notación matricial se puede expresar como

$$\mathbf{Z} = \mathbf{B}^T \mathbf{T},$$

y finalmente para recuperar los datos originales a partir de la base de FEOs usamos

$$\mathbf{T} = \mathbf{BZ},$$

ya que $\mathbf{BB}^T = \mathbf{I}$. La matriz \mathbf{Z} contiene los vectores de las CPs, que no son mas que las amplitudes por las cuales multiplicamos las FEOs para obtener los datos originales de vuelta. De esta forma podemos ir de un espacio (vectores propios) al otro (datos originales) con la matriz de FEOs. Supongamos que tenemos un conjunto de vectores propios ortogonales y normalizados. El primero de ellos por ejemplo sería

$$\mathbf{e} = \begin{pmatrix} e_{11} \\ e_{21} \\ \vdots \\ \vdots \\ e_{M1} \end{pmatrix}.$$

Si ponemos todos los vectores propios en columna obtenemos la matriz cuadrada \mathbf{B} , la cual es ortonormal $\mathbf{B}^T\mathbf{B} = \mathbf{I}$. Si queremos proyectar un vector propio sobre los datos originales y obtener la amplitud de este vector propio en cada tiempo, debemos de hacer

$$\mathbf{e}^T \mathbf{T} = (e_{11} \ e_{21} \ \dots \ e_{M1}) \begin{pmatrix} T_1(t_1) & T_1(t_2) & \dots & T_1(t_N) \\ T_2(t_1) & T_2(t_2) & \dots & T_2(t_N) \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ T_M(t_1) & T_M(t_2) & \dots & T_M(t_N) \end{pmatrix} = (z_{11} \ z_{12} \ \dots \ z_{1N}),$$

donde, por ejemplo, $z_{11} = e_{11}T_1(t_1) + e_{21}T_2(t_1) + \dots + e_{M1}T_M(t_1)$. Si hacemos lo mismo para todos los otros vectores propios, obtenemos series temporales de longitud N para cada FEO, lo cual se denominan componentes principales de cada EOF

$$\mathbf{Z} = \mathbf{B}^T \mathbf{T}.$$

$$M \times N$$

Las CPs también son ortogonales. Si substituimos $\mathbf{T} = \mathbf{BZ}$, en $\mathbf{B}^T \mathbf{T} \mathbf{T}^T \mathbf{B} = \mathbf{ND}$ obtenemos

$$\mathbf{B}^T \mathbf{BZ} (\mathbf{BZ})^T \mathbf{B} = \mathbf{ND}$$

$$\mathbf{IZZ}^T \mathbf{B}^T \mathbf{B} = \mathbf{ND}$$

$$\mathbf{IZZ}^T \mathbf{I} = \mathbf{ND}$$

$$\mathbf{Z}\mathbf{Z}^T = N\mathbf{D} \quad \text{o} \quad <\mathbf{Z}\mathbf{Z}^T> = \mathbf{D}.$$

1694 Por lo tanto no solo las FEOs sino también las CPs son ortogonales.

1695 **Equivalencia con descomposición en valores singulares (SVD)**

Definición de SVD:

La descomposición en valores singulares es básicamente un método de reducción dimensional de un conjunto de datos inicialmente definidos sobre un espacio multidimensional. Esta puede ser usada para encontrar simultáneamente las FEOs y PCs de una matriz de datos.

Una matriz \mathbf{A} puede ser descompuesta en un producto de matrices: (i) una matriz ortogonal \mathbf{U} (i.e., $\mathbf{U}^T\mathbf{U} = \mathbf{I}$), una matriz diagonal \mathbf{S} , y la transpuesta de una matriz ortogonal \mathbf{V} (i.e., $\mathbf{V}^T\mathbf{V} = \mathbf{I}$)

$$\mathbf{A} = \mathbf{USV}^T.$$

Las columnas de \mathbf{U} son vectores propios ortogonales de \mathbf{AA}^T o los vectores singulares izquierdos de \mathbf{A} , las columnas de \mathbf{V} son vectores propios ortogonales de $\mathbf{A}^T\mathbf{A}$ o los vectores singulares derechos de \mathbf{A} , y \mathbf{S} es una matriz diagonal que contiene las raíces cuadradas de los valores propios positivos de las matrices \mathbf{U} o \mathbf{V} en orden descendente (o los valores singulares no-nulos de \mathbf{A}). con orden descendente nos referimos a que la primera columna esta asociada al valor propio mas grande, la segunda columna al segundo valor propio mas grande, y así sucesivamente.

Interpretación geométrica:

La SVD descompone la matriz \mathbf{A} en tres transformaciones algebraicas sucesivas: (i) una rotación inicial \mathbf{U} , un escalamiento \mathbf{S} a lo largo de los ejes coordenados, una rotación final \mathbf{V} . Las longitudes σ_1 y σ_2 de la elipse son los valores singulares de \mathbf{A} (ver script interpreta_svd.m).

1696 Supongamos la matriz de datos compuesta por M series temporales de
1697 temperatura de longitud N

$$\mathbf{T} = \begin{pmatrix} T_1(t_1) & T_1(t_2) & \dots & T_1(t_N) \\ T_2(t_1) & T_2(t_2) & \dots & T_2(t_N) \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ T_M(t_1) & T_M(t_2) & \dots & T_M(t_N) \end{pmatrix}.$$

1698 La matriz de dispersión es

$$<\mathbf{T}\mathbf{T}^T> = \frac{1}{N}\mathbf{T}\mathbf{T}^T.$$

1699 Sabemos que la matriz \mathbf{T} puede descomponerse en una matriz ortogonal
 1700 \mathbf{U} , una matriz diagonal \mathbf{S} , y la transpuesta de una matriz ortogonal \mathbf{V} .
 1701 Esto es

$$\mathbf{T} = \mathbf{USV}^T,$$

1702 donde el número de valores singulares no nulos indican el rango de \mathbf{T} .
 1703 Si $K < N$ y el número de filas (i.e., los datos) son linealmente indepen-
 1704 dientes entonces el rango será K . Ahora la matriz de covarianza es

$$\frac{1}{N}\mathbf{TT}^T = \frac{1}{N}(\mathbf{USV}^T)(\mathbf{USV}^T)^T = \frac{1}{N}\mathbf{USV}^T\mathbf{V}(\mathbf{US})^T = \frac{1}{N}\mathbf{USV}^T\mathbf{VS}^T\mathbf{U}^T = \frac{1}{N}\mathbf{USS}^T\mathbf{U}^T.$$

1705 La derecha del igual es la descomposición en valores propios de la ma-
 1706 triz de covarianza, donde \mathbf{SS}^T es cuadrada y diagonal con los elementos
 1707 igual a $N\lambda_i$; y las columnas de \mathbf{U} son las FEOs. Las amplitudes de las
 1708 FEOs vienen dadas por las filas de la matriz

$$\mathbf{U}^T\mathbf{T} = \mathbf{SV},$$

1709 asociado con valores singulares no nulos.

1710 Interpretación de las FEOs

1711 Como comentario final hay que decir que las FEOs no son muy fáciles
 1712 de interpretar. Matemáticamente son estructuras que representan la
 1713 mayor cantidad de varianza de los datos originales y que son ortogo-
 1714 nales entre ellas. En ocasiones estas estructuras nos dan estructuras con
 1715 sentido físico en un conjunto de datos, en otras no. Las estructuras par-
 1716 ticulares encontradas dependerán de cómo hemos acomodado nuestra
 1717 matriz bidimensional de datos. Algunas sugerencias para detectar si las
 1718 FEOs tienen sentido físico son las siguientes:

- 1719 (1) ¿La varianza de tu FEO es mas grande que lo que esperabas si los
 1720 datos originales no tenían estructura alguna?
- 1721 (2) ¿Existe una explicación apriori para las estructuras que has encon-
 1722 trado? ¿Se pueden explicar las estructuras en términos de alguna
 1723 teoría? ¿Las estructuras se comportan consistentemente con la
 1724 teoría apriori?
- 1725 (3) ¿Cuán robustas son las estructuras a la elección del dominio de la
 1726 estructura? ¿Si cambias el dominio del análisis, esas estructuras
 1727 cambian significantemente? ¿Si las estructuras están definidas
 1728 en un espacio geográfico, y cambias el tamaño de la región, las
 1729 estructuras cambian significativamente? ¿Si las estructuras es-
 1730 tan definidas en el espacio de parámetros y añades o eliminás un
 1731 parámetros, los resultados cambian de forma suave o aleatoria-
 1732 mente?

1733 (4) ¿Cuán robustas son las estructuras a los datos usados? ¿Si divides
 1734 los datos originales en fracciones menores y haces el análisis de cada
 1735 fracción, obtienes las mismas estructuras?

1736 **Ejemplo de descomposición en valores singulares**

1737 Supongamos la matriz

$$\mathbf{A} = \begin{pmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{pmatrix}.$$

1738 Para encontrar \mathbf{U} debemos resolver el problema en vectores y valores
 1739 propios de la matriz $\mathbf{A}\mathbf{A}^T$

$$\mathbf{A}\mathbf{A}^T = \begin{pmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{pmatrix} \begin{pmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 11 & 1 \\ 1 & 11 \end{pmatrix}$$

1740 El sistema de ecuaciones ‘propio’ es

$$\begin{pmatrix} 11 & 1 \\ 1 & 11 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \lambda \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

1741 Si resolvemos para λ

$$\begin{vmatrix} 11 - \lambda & 1 \\ 1 & 11 - \lambda \end{vmatrix} = 0,$$

1742 lo que deja el polinomio característico

$$(\lambda - 10)(\lambda - 12) = 0,$$

1743 con raíces (valores propios) $\lambda_1 = 12$ y $\lambda_2 = 10$.

1744 Si sustituimos en el sistema de ecuaciones ‘propio’ el primer valor pro-
 1745 pio $\lambda_1 = 12$

$$(11 - 12)x_1 + x_2 = 0$$

$$x_1 = x_2$$

1746 Para $x_1 = 1$ obtenemos que $x_2 = 1$. Entonces obtenemos el vector pro-
 1747 pio $\mathbf{v}_1 = [1, 1]^{“”}$

1748 Si sustituimos en el sistema de ecuaciones “propio” el primer valor pro-
 1749 pio $\lambda_1 = 10$

$$(11 - 10)x_1 + x_2 = 0$$

$$x_1 = -x_2$$

1750 Para $x_1 = 1$

1751 obtenemos que $x_2 = -1$. Entonces obtenemos el vector propio $\mathbf{v}_2 =$
 1752 $[1, -1]$.

1753 Si organizamos la matriz con columnas correspondientes a los vectores
 1754 propios asociados a los valores propios de mayor a menor, obtenemos

$$\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$$

1755 Finalmente, sabemos que \mathbf{U} tiene que ser ortonormal. Vamos a usar
 1756 el proceso de Gram-Schmidt para ortonormalizar las columnas de \mathbf{U} .
 1757 Empezamos normalizando la primera columna

$$\mathbf{u}_1 = \frac{\mathbf{v}_1}{|\mathbf{v}_1|} = \frac{[1, 1]}{\sqrt{2}} = \left[\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right],$$

1758 y calculamos el vector ortonormal como

$$\mathbf{w}_2 = \mathbf{v}_2 - \mathbf{u}_1 \cdot \mathbf{v}_2 \mathbf{u}_1 = [1, -1] - \left[\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right] \cdot [1, -1] \left[\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right] = [1, -1] - [0, 0] = [1, -1].$$

1759 Si lo normalizamos

$$\mathbf{u}_2 = \frac{\mathbf{w}_2}{|\mathbf{w}_2|} = \left[\frac{1}{\sqrt{2}}, \frac{-1}{\sqrt{2}} \right],$$

1760 dejando la matriz

$$\mathbf{U} = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix}.$$

1761 Similarmente, para calcular la matriz \mathbf{V} debemos resolver el problema
 1762 en vectores y valores propios de la matriz $\mathbf{A}^T \mathbf{A}$

$$\mathbf{A}^T \mathbf{A} = \begin{pmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{pmatrix} = \begin{pmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{pmatrix}$$

1763 El sistema de ecuaciones ‘propio’ es

$$\begin{pmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \lambda \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

$$(10 - \lambda)x_1 + 2x_3 = 0$$

$$(10 - \lambda)x_2 + 4x_3 = 0$$

1765

$$2x_1 + 4x_2 + (2 - \lambda)x_3 = 0$$

1766

Si resolvemos para λ

$$\begin{vmatrix} 10 - \lambda & 0 & 2 \\ 0 & 10 - \lambda & 4 \\ 2 & 4 & 2 - \lambda \end{vmatrix} = 0$$

1767

lo que deja el polinomio característico

$$\lambda(\lambda - 10)(\lambda - 12) = 0,$$

1768

1769

con raíces (valores propios) $\lambda_1 = 12$, $\lambda_2 = 10$, y $\lambda_3 = 0$. Substituyendo en el sistema ‘propio’ para $\lambda_1 = 12$

1770

$$(10 - 12)x_1 + 2x_3 = -2x_1 + 2x_3 = 0$$

$$x_1 = 1; x_3 = 1$$

1771

$$(10 - 12)x_2 + 4x_3 = -2x_2 + 4x_3 = 0$$

$$x_2 = 2x_3$$

$$x_2 = 2$$

1772

Entonces, para $\lambda_1 = 12$ obtenemos el vector propio $\mathbf{v}_1 = [1, 2, 1]$.

1773

Para $\lambda_2 = 10$

1774

$$(10 - 10)x_1 + 2x_3 = 2x_3 = 0$$

$$x_3 = 0$$

1775

$$2x_1 + 4x_2 = 0$$

$$x_1 = -2x_2$$

$$x_1 = 2; x_2 = -1$$

1776

y obtenemos $\mathbf{v}_2 = [2, -1, 0]$ para $\lambda_2 = 10$. Finalmente, para $\lambda_3 = 0$

1777

$$10x_1 + 2x_3 = 0$$

$$x_3 = -5$$

$$10x_1 - 20 = 0$$

$$x_2 = 2$$

1779

$$2x_1 + 8 - 10 = 0$$

$$x_1 = 1$$

1780

lo que implica que para $\lambda_3 = 0$ $\mathbf{v}_3 = [1, 2, -5]$.

1781

Si organizamos los vectores de acuerdo con el valor de los valores propios (de mayor a menor) obtenemos la matriz

$$\begin{pmatrix} 1 & 2 & 1 \\ 2 & -1 & 2 \\ 1 & 0 & -5 \end{pmatrix}$$

1783

Ahora vamos a ortonormalizarla con el proceso de Gram-schmidt

$$\mathbf{u}_1 = \frac{\mathbf{v}_1}{|\mathbf{v}_1|} = \frac{[1, 2, 1]}{\sqrt{6}},$$

1784

y calculamos el vector ortonormal como

$$\mathbf{w}_2 = \mathbf{v}_2 - \mathbf{u}_1 \cdot \mathbf{v}_2 \mathbf{u}_1 = [2, -1, 0]$$

1785

Si lo normalizamos

$$\mathbf{u}_2 = \frac{\mathbf{w}_2}{|\mathbf{w}_2|} = \left[\frac{2}{\sqrt{5}}, \frac{-1}{\sqrt{5}}, 0 \right]$$

1786

El último vector ortonormal a calcular es

$$\mathbf{w}_3 = \mathbf{v}_3 - \mathbf{u}_1 \cdot \mathbf{v}_3 \mathbf{u}_1 - \mathbf{u}_2 \cdot \mathbf{v}_3 \mathbf{u}_2 = \left[\frac{-2}{3}, \frac{-4}{3}, \frac{10}{3} \right]$$

1787

Si lo normalizamos

$$\mathbf{u}_3 = \frac{\mathbf{w}_3}{|\mathbf{w}_3|} = \left[\frac{1}{\sqrt{30}}, \frac{2}{\sqrt{30}}, \frac{-5}{\sqrt{30}} \right]$$

1788

dejando la matriz

$$\mathbf{V} = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{30}} \\ \frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{5}} & \frac{2}{\sqrt{30}} \\ \frac{1}{\sqrt{6}} & 0 & \frac{-5}{\sqrt{30}} \end{pmatrix}.$$

1789

Finalmente, lo que realmente queremos es

$$\mathbf{V}^T = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{30}} & \frac{-5}{\sqrt{30}} \end{pmatrix}.$$

Para calcular \mathbf{S} debemos tomar las raíces cuadradas de los valores propios diferentes de cero ($\lambda_i \neq 0$) y colocarlos en la diagonal principal en orden descendente. Es decir, el valor propio mayor en la posición s_{11} , el siguiente más grande en s_{22} , y así sucesivamente. Los valores propios diferentes de cero son iguales para \mathbf{U} y \mathbf{V} con lo que no importa de cuáles tomemos. Puesto que solo hay dos valores propios diferentes de cero y el orden de las matrices \mathbf{U} y \mathbf{V} es 3×3 , debemos añadir una columna de ceros a \mathbf{S}

$$\mathbf{S} = \begin{pmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{10} & 0 \end{pmatrix}.$$

Ahora ya tenemos todas las matrices de la descomposición en valores singulares:

$$\begin{aligned} \mathbf{A} = \mathbf{USV}^T &= \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{10} & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{30}} & \frac{-5}{\sqrt{30}} \end{pmatrix} = \\ &= \begin{pmatrix} \frac{12}{\sqrt{2}} & \frac{\sqrt{10}}{\sqrt{2}} & 0 \\ \frac{12}{\sqrt{2}} & -\frac{\sqrt{10}}{\sqrt{2}} & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{30}} \\ \frac{\sqrt{6}}{\sqrt{6}} & -\frac{1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{30}} & \frac{-5}{\sqrt{30}} \end{pmatrix} = \begin{pmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{pmatrix}. \end{aligned}$$

9 Análisis espectral o análisis de Fourier

9.1 Introducción

Una función periódica es aquella cuyos valores se repiten a intervalos regulares. El tiempo entre las sucesivas repeticiones se denomina periodo τ . Normalmente lo definimos entre sucesivas crestas. Matemáticamente, una función es periódica si $f(t) = f(t + T)$ para todo valor de T .

1807

1808 Función periódica $f(t) = f(t + \tau)$.

1809 La frecuencia de una función periódica se define como el inverso del periodo, $f = 1/\tau$, es decir el número de ciclos por unidad de tiempo (si es 1810 por segundo hablamos de Hercios, Hz). Si un ciclo equivale a 2π radianes, 1811 entonces el número de radianes por segundo es lo que se conoce 1812 por la frecuencia angular fundamental:

$$\omega = \frac{2\pi}{T}.$$

1814 Las funciones periódicas también se pueden definir en el espacio. En-
 1815 tonces el periodo se define como

$$\tau = \lambda/v_p,$$

1816 donde λ es la longitud de onda y $v_p = \lambda/\tau = \omega/k$ es la velocidad de
 1817 fase. La longitud de onda es una distancia entre estados de la onda que
 1818 se repiten, e.j. entre dos crestas. El número de onda k es el número de
 1819 ondas contenidas en una unidad de distancia

$$k = \frac{2\pi}{\lambda} = \frac{\omega}{v_p}$$

1820 El valor promedio de una función periódica es:

$$f_m = \frac{1}{\tau} \int_0^\tau f(t)dt,$$

1821 y su valor cuadrático medio (o RMS, en inglés) es:

$$f_{rms} = \sqrt{\frac{1}{\tau} \int_0^\tau f^2(t)dt},$$

1822 donde las integrales se han definido en el intervalo $0, \tau$, aunque se
 1823 pueden definir en cualquier intervalo que abarque un periodo, e.j. de
 1824 $-\tau/2$ a $\tau/2$.

1825 Una de las ondas periódicas mas utilizadas es la sinusoidal o cosenosoidal.

$$f(t) = A \sin(\omega t + \theta),$$

1826 siendo A la amplitud y θ su fase inicial. En este caso el valor medio es
 1827 cero y su rms es $A/\sqrt(2)$. % Recordar que existen dos frecuencias bási-
 1828 cas: (i) Frecuencia de Nyquist $f_N = 1/(2\Delta t)$ (la frecuencia mas alta que
 1829 podemos resolver) y (ii) Frecuencia fundamental $f_0 = 1/(\Delta t N) = 1/T$
 1830 (la frecuencia mas baja que podemos resolver).

1831 9.2 Serie de Fourier

1832 El principio básico del análisis de Fourier es que cualquier función per-
 1833 iódica $f(t)$ definida en el intervalo $[0, T]$ se puede descomponer en suma
 1834 de funciones simples, sinusoidales y cosinusoidales, o series de Fourier de
 1835 la forma

$$f(t) = \bar{f}(t) + \sum_p [A_p \cos(\omega_p t) + B_p \sin(\omega_p t)],$$

1836 donde $\bar{f}(t)$ es el valor medio de la serie temporal, A_p y B_p son con-
 1837 stantes denominados coeficientes de Fourier, y $\omega_p = 2\pi p f_0 = 2\pi p/\tau$ es
 1838 múltiplo de la frecuencia angular fundamental.

1839 Si tenemos suficientes componentes de Fourier cada valor de la serie
 1840 original se puede reconstruir. La contribución que cada componente

tiene sobre la varianza de la serie temporal es una medida de la importancia de una frecuencia particular en la serie original. El punto clave aqui es que el conjunto de coeficientes de Fourier con amplitudes A_p y B_p forman un espectro el cual define la contribución de cada componente oscilatoria ω_p sobre la ‘energía’ total de la señal original. En concreto, el spectro de potencia (Power spectrum) define la energía por unidad de banda de frecuencia de una serie temporal. Puesto que debemos definir dos amplitudes A_p y B_p , hay dos grados de libertad por estimación espectral.

Como ya hemos dicho el primer armónico ($p = 1$) oscila con frecuencia fundamental $\omega_1 = 2\pi f_1$. El armónico $N/2$, el cual nos da la componente con la frecuencia más alta que puede ser resuelta tiene frecuencia $f_N = N/2/N\Delta t = 1/(2\Delta T)$ ciclos por unidad de tiempo y un periodo de $2\Delta t$. Esta es la frecuencia de Nyquist.

Integrales de funciones trigonométricas útiles:

$$\int \cos ax dx = \frac{\sin ax}{a} + C$$

$$\int \sin ax dx = -\frac{\cos ax}{a} + C$$

$$\int \sin^2 ax dx = \frac{x}{2} - \frac{\sin 2ax}{4a} + C$$

$$\int \cos^2 ax dx = \frac{x}{2} + \frac{\sin 2ax}{4a} + C$$

Las series de Fourier se definen como

$$f(t) = \frac{1}{2}A_0 + \sum_{p=1}^{\infty} [A_p \cos(\omega_p t) + B_p \sin(\omega_p t)],$$

en la cual

$$\omega_p = 2\pi f_p = 2\pi p f_1 = 2\pi p/T; \quad p = 1, 2, \dots,$$

es la frecuencia de la componente p -ésima en radianes por unidad de tiempo (f_p es en ciclos por unidad de tiempo) y $A_0/2$ es la media de la serie temporal.

Para obtener los coeficientes A_p , debemos multiplicar la expresión de la descomposición de Fourier por $\cos(\omega_r t)$ e integrar sobre la serie completa.

$$\int_0^T f(t) \cos(\omega_r t) dt = \frac{1}{2} A_0 \int_0^T \cos(\omega_r t) dt +$$

$$+ \sum_{p=1}^{\infty} A_p \int_0^T \cos(\omega_p t) \cos(\omega_r t) dt +$$

1864

$$+ \sum_{p=1}^{\infty} B_p \int_0^T \sin(\omega_p t) \cos(\omega_r t) dt .$$

1865

Si usamos las siguientes condiciones de ortogonalidad:

$$\int_0^T \sin(\omega_p t) \cos(\omega_r t) dt = 0$$

1866

$$\int_0^T \cos(\omega_p t) \cos(\omega_r t) dt = \begin{cases} T, p = r = 0 \\ T/2, p = r > 0 \\ 0, p \neq r \end{cases}$$

1867

$$\int_0^T \sin(\omega_p t) \sin(\omega_r t) dt = \begin{cases} 0, p = r = 0 \\ T/2, p = r > 0 \\ 0, p \neq r \end{cases}$$

1868

entonces encontramos que para $r = 0; p \neq r$ la ecuación de arriba se reduce a

$$\int_0^T f(t) dt = \frac{A_0}{2} T ,$$

1869

es decir,

$$A_0 = \frac{2}{T} \int_0^T f(t) dt = 2\bar{f}(t) ,$$

1871

dos veces el valor medio de la serie $f(t)$. Es por ello que se añade el factor de $1/2$ en la serie de Fourier. Es decir, para que el primer término de la serie de Fourier sea igual a la media de la serie temporal $\bar{f}(t) = 1/2A_0$.

1872

Cuando $p \neq 0$ el único término no despreciable de la derecha de la expresión de arriba sucede cuando $r = p$

$$\int_0^T f(t) \cos(\omega_p t) dt = \frac{A_p}{2} T ,$$

1873

y entonces

$$A_p = \frac{2}{T} \int_0^T f(t) \cos(\omega_p t) dt, \quad p = 1, 2, \dots$$

1874

Los otros coeficientes B_p son obtenidos igualmente multiplicando por $\sin(\omega_r t)$ en lugar de $\cos(\omega_r t)$

$$B_p = \frac{2}{T} \int_0^T f(t) \sin(\omega_p t) dt, \quad p = 1, 2, \dots$$

Relaciones trigonométricas útiles:

$$\cos(\alpha - \beta) = \cos\alpha\cos\beta + \sin\alpha\sin\beta$$

$$\sin(\alpha - \beta) = \sin\alpha\cos\beta - \cos\alpha\sin\beta$$

$$\operatorname{tg}\gamma = \frac{\sin\gamma}{\cos\gamma}$$

De estas relaciones de arriba se puede llegar a:

$$A\cos\theta + B\sin\theta = C\cos(\theta - \theta_0),$$

donde

$$C = \sqrt{A^2 + B^2},$$

y

$$\theta_0 = \operatorname{arctg}\left(\frac{B}{A}\right)$$

A partir de esta relación

$$e^{i\theta} = \cos\theta + i\sin\theta,$$

llegamos a

$$\begin{aligned} \sin\theta &= \frac{e^{i\theta} - e^{-i\theta}}{2i} \\ \cos\theta &= \frac{e^{i\theta} + e^{-i\theta}}{2} \end{aligned}$$

1880 También podemos representar la serie de Fourier en notación compacta
1881 como:

$$f(t) = \frac{1}{2}C_0 + \sum_{p=1}^{\infty} C_p \cos(\omega_p t - \theta_p),$$

1882 en la cual la amplitud de la pésima componente es

$$C_p = \sqrt{A_p^2 + B_p^2}, \quad p = 1, 2, \dots$$

1883 donde $C_0 = A_0$ ($B_0 = 0$) es dos veces el valor promedio de la serie y

$$\theta_p = \operatorname{arctg}[B_p/A_p], \quad p = 1, 2, \dots$$

1884 es el ángulo de fase de la componente al tiempo $t = 0$. El ángulo de fase
1885 nos informa del “desfase” *lag* relativo de las componentes en radianes (o
1886 grados) medido en el sentido contrario a las agujas del reloj desde el eje
1887 real definido por $B_p = 0, A_p > 0$. El correspondiente tiempo de desfase
1888 para la componente pésima es $t_p = \theta_p/2\pi f_p$ en el cual θ_p esta medida en
1889 radianes. La energía espectral se define como las amplitudes de los coefi-
1890 cientes de Fourier al cuadrado, lo cual representa la varianza y entonces
1891 la energía

$$C_p^2 = A_p^2 + B_p^2.$$

1892 \ De igual forma con las relaciones trigonométricas de arriba se puede
 1893 expresar las series de Fourier en notación compleja. Usando

$$\text{sen}\omega_p t = \frac{e^{i\omega_p t} - e^{-i\omega_p t}}{2i} \quad y \quad \cos\omega_p t = \frac{e^{i\omega_p t} + e^{-i\omega_p t}}{2},$$

1894 obtenemos

$$\begin{aligned} f(x) &= \frac{1}{2}A_0 + \sum_{p=1}^{\infty} [A_p \cos(\omega_p t) + B_p \sin(\omega_p t)] = \\ &= \frac{1}{2}A_0 + \sum_{p=1}^{\infty} \left[A_p \frac{e^{i\omega_p t} + e^{-i\omega_p t}}{2} + B_p \frac{e^{i\omega_p t} - e^{-i\omega_p t}}{2i} \right] = \\ &= \frac{1}{2}A_0 + \sum_{p=1}^{\infty} \left[\frac{A_p e^{i\omega_p t}}{2} + \frac{A_p e^{-i\omega_p t}}{2} - \frac{iB_p e^{i\omega_p t}}{2} + \frac{iB_p e^{-i\omega_p t}}{2} \right] = \\ &= \frac{1}{2}A_0 + \sum_{p=1}^{\infty} e^{i\omega_p t} \frac{A_p - iB_p}{2} + \sum_{p=1}^{\infty} e^{-i\omega_p t} \frac{A_p + iB_p}{2} = \\ &= C_0^* + \sum_{p=1}^{\infty} C_p^* e^{i\omega_p t} + \sum_{p=1}^{\infty} C_{-p}^* e^{-i\omega_p t} = \sum_{p=-\infty}^{\infty} C_p^* e^{i\omega_p t}, \end{aligned}$$

1899 donde hemos definido las siguientes relaciones entre los coeficientes de
 1900 Fourier complejos y reales:

$$C_0^* = \frac{1}{2}A_0,$$

$$C_p^* = \frac{1}{2}(A_p - iB_p),$$

$$C_{-p}^* = \frac{1}{2}(A_p + iB_p).$$

1903 En resumen, podemos reconstruir la serie periódica $f(t)$ con la transformada de Fourier
 1904

$$f(x) = \sum_{p=-\infty}^{\infty} C_p^* e^{i\omega_p t},$$

1905 e inversamente podemos calcular los coeficientes de Fourier C_p^* a partir
 1906 de la $f(t)$

$$\begin{aligned} C_p^* &= \frac{1}{2}(A_p - iB_p) = \frac{1}{2} \left(\frac{2}{T} \int_0^T f(t) \cos(\omega_p t) dt - i \frac{2}{T} \int_0^T f(t) \sin(\omega_p t) dt \right) = \\ &= \frac{1}{T} \int_0^T f(t) [\cos(\omega_p t) - i \sin(\omega_p t)] dt = \frac{1}{T} \int_0^T f(t) e^{-i\omega_p t} dt, \end{aligned}$$

1908 es decir, podemos pasar del espacio temporal $f(t)$ al espacio espectral o
 1909 de Fourier C_p^* e inversamente regresar al espacio temporal de nuevo.

1910 El teorema de Parseval es precisamente el que demuestra que la el valor
 1911 cuadrático medio de la serie de Fourier es igual al error cuadrático

1912 medio de los coeficientes de Fourier. La varianza de la serie de Fourier
 1913 es

$$\begin{aligned}
 & \frac{1}{T} \int_0^T f^2(t) dt = \frac{1}{T} \int_0^T \left(\frac{1}{2} A_0 + \sum_{p=1}^{\infty} [A_p \cos(\omega_p t) + B_p \sin(\omega_p t)] \right) dt = \\
 & = \frac{1}{T} \frac{1}{4} A_0^2 \int_0^T dt + \frac{1}{T} A_0 \sum_{p=1}^{\infty} A_p \int_0^T \cos(\omega_p t) dt + \frac{1}{T} A_0 \sum_{p=1}^{\infty} B_p \int_0^T \sin(\omega_p t) dt + \\
 & + \frac{1}{T} \sum_{p=1}^{\infty} A_p^2 \int_0^T \cos^2(\omega_p t) dt + \frac{1}{T} \sum_{p=1}^{\infty} B_p^2 \int_0^T \sin^2(\omega_p t) dt + \\
 & + \frac{1}{T} 2 \sum_{p=1}^{\infty} A_p \sum_{p=1}^{\infty} B_p \int_0^T \sin(\omega_p t) \cos(\omega_p t) dt = \frac{1}{T} \frac{1}{4} A_0^2 T + \frac{1}{T} \sum_{p=1}^{\infty} A_p^2 \left[\frac{t}{2} + \frac{\sin(2\omega_p t)}{4\omega_p} \right]_0^T + \\
 & + \frac{1}{T} \sum_{p=1}^{\infty} B_p^2 \left[\frac{t}{2} - \frac{\sin(2\omega_p t)}{4\omega_p} \right]_0^T = \frac{1}{4} A_0^2 + \frac{1}{2} \sum_{p=1}^{\infty} A_p^2 + \frac{1}{2} \sum_{p=1}^{\infty} B_p^2 = \\
 & = \frac{1}{4} A_0^2 + \frac{1}{2} \sum_{p=1}^{\infty} A_p^2 + B_p^2.
 \end{aligned}$$

1919 Utilizando las siguientes identidades

$$|C_p^*|^2 = |C_{-p}^*|^2 = \frac{1}{4} (A_p^2 + B_p^2),$$

$$C_0^* = \frac{1}{2} A_0,$$

1920 el teorema de Parseval en términos de los coeficientes de Fourier complejos es

$$\begin{aligned}
 & \frac{1}{T} \int_0^T f^2(t) dt = (C_0^*)^2 + \frac{1}{2} \sum_{p=1}^{\infty} 4|C_p^*|^2 = (C_0^*)^2 + \sum_{p=1}^{\infty} |C_p^*|^2 + \sum_{p=1}^{\infty} |C_p^*|^2 = \\
 & = (C_0^*)^2 + \sum_{p=1}^{\infty} |C_p^*|^2 + \sum_{p=1}^{\infty} |C_{-p}^*|^2 = \sum_{p=-\infty}^{\infty} |C_p^*|^2
 \end{aligned}$$

El teorema de Parseval es una ley de conservación que demuestra que la suma de los módulos cuadrados de los coeficientes de Fourier complejos es igual al valor promedio de $f^2(x)$

$$\frac{1}{T} \int_0^T f^2(t) dt = \frac{1}{4} A_0^2 + \frac{1}{2} \sum_{p=1}^{\infty} A_p^2 + B_p^2 = \sum_{p=-\infty}^{\infty} |C_p^*|^2.$$

1924 Esto da lugar a la relación entre la amplitud de las componentes de
 1925 Fourier en el dominio espectral (de frecuencia) y la varianza de la serie
 1926 en el dominio temporal.

1927 **NOTA:** En el análisis de Fourier es importante recalcar que debemos
 1928 de eliminar la tendencia de la serie antes de calcular los coeficientes.
 1929 Sino lo hacemos, el análisis de Fourier pondrá erroneamente la varianza
 1930 de la tendencia en las componentes de baja frecuencia de la expansión
 1931 de Fourier. En Matlab eso lo podemos hacer con el comando detrend.m
 1932 o bien simplemente extrayendo el promedio temporal.

1933 {Ejemplo de cálculo de coeficientes de Fourier}

1934 Imaginemos la siguiente onda cuadrada representada por la función

$$f(t) = \begin{cases} -1, & \text{para } -\frac{1}{2}T \leq t < 0 \\ +1, & \text{para } 0 \leq t < \frac{1}{2}T \end{cases}$$

1935 Onda cuadrada.

1936 Puesto que función de arriba es impar, es decir cumple la condición de
 1937 simetría $-f(t) = f(-t)$, entonces la serie de Fourier resultante sola-
 1938 mente contendrá componentes sinusoidales. Entonces
 1939

$$\begin{aligned} B_p &= \frac{2}{T} \int_{-T/2}^{T/2} f(t) \sin(\omega_p t) dt = \\ &= \frac{2}{T} \int_{-T/2}^0 f(t) \sin(\omega_p t) dt + \frac{2}{T} \int_0^{T/2} f(t) \sin(\omega_p t) dt = \\ &= \frac{2}{T} \left[(-1) \int_{-T/2}^0 \sin(\omega_p t) dt + (1) \int_0^{T/2} \sin(\omega_p t) dt \right] = \\ &= \frac{2}{T} \left[\left| \frac{\cos(\omega_p t)}{\omega_p} \right|_{-T/2}^0 - \left| \frac{\cos(\omega_p t)}{\omega_p} \right|_0^{T/2} \right] = \end{aligned}$$

$$\begin{aligned}
 &= \frac{2}{\omega_p T} [1 - \cos(\omega_p T/2) - \cos(\omega_p T/2) + 1] = \frac{2}{\omega_p T} [2 - 2\cos(\omega_p T/2)] = \\
 &= \frac{4}{\omega_p T} [1 - \cos(\omega_p T/2)] = \frac{2}{\pi p} [1 - \cos(\pi p)]
 \end{aligned}$$

1944 \\ Los coeficientes son cero ($B_p = 0$) si p es par y $B_p = 4/\pi p$ si p es
 1945 impar. Finalmente nuestra serie de Fourier es

$$\begin{aligned}
 &f(t) = \sum_{p=1}^{\infty} B_p \sin(\omega_p t) = \\
 &= \sum_{p=1}^{\infty} B_p \sin\left(\frac{2\pi p}{T}t\right) = B_1 \sin\left(\frac{2\pi 1}{T}t\right) + B_3 \sin\left(\frac{2\pi 3}{T}t\right) + \\
 &\quad + B_5 \sin\left(\frac{2\pi 5}{T}t\right) + \dots = \frac{4}{\pi} \sin\left(\frac{2\pi 1}{T}t\right) + \\
 &\quad + \frac{4}{3\pi} \sin\left(\frac{2\pi 3}{T}t\right) + \frac{4}{5\pi} \sin\left(\frac{2\pi 5}{T}t\right) = \\
 &= \frac{4}{\pi} \left(\frac{\sin \omega_1 t}{1} + \frac{\sin 3\omega_1 t}{3} + \frac{\sin 5\omega_1 t}{5} \right) + \dots
 \end{aligned}$$

```

**Código Matlab para N=100 componentes*
N=100;
t=-30:0.1:30;
f=0;
for p=1:2:N;
f=f+(4/(p*pi))*sin(((2*pi*p)/(10))*t);
end
figure; plot(t,f);

```

1950

1951 Serie de Fourier para Onda cuadrada. Arriba para 5 componentes, medio
 1952 para 50 componentes, y abajo para 100 componentes.

1953 { Series de Fourier Discretas}

1954 En general, vamos a muestrear de forma discreta el océano y conse-
 1955 cuentemente las series temporales que obtenemos son discretas en el
 1956 tiempo. Segun el teorema de Parseval, la varianza de estas series disre-
 1957 tas

$$\sigma^2 = \frac{1}{N-1} \sum_{t=1}^N (f(t) - \bar{f(t)})^2$$

1958 se puede obtener sumando las contribuciones individuales de los armóni-
 1959 cos de Fourier. La descomposición de series temporales discretas en
 1960 armónicos específicos da lugar al concepto de espectro de Fourier. Para

1961 encontrar el espectro de Fourier debemos calcular los coeficientes A_p, B_p
 1962 o, equivalentemente, las amplitudes C_p y el ángulo de fase θ_p .

1963 Supongamos la serie de Fourier para un registro finito de longitud par
 1964 N definido en los tiempos t_1, t_2, \dots, t_N

$$f(t_n) = \frac{1}{2}A_0 + \sum_{p=1}^{N/2} [A_p \cos(\omega_p t_n) + B_p \sin(\omega_p t_n)],$$

1965 donde ya sabemos $\omega_p = 2\pi f_p = 2\pi p/T$. Sabiendo que $t_n = n\Delta t$, esta
 1966 serie se puede reescribir como

$$\begin{aligned} f(t_n) &= \frac{1}{2}A_0 + \sum_{p=1}^{N/2} [A_p \cos(2\pi pn\Delta t/\Delta t N) + B_p \sin(2\pi pn\Delta t/\Delta t N)] = \\ &= \frac{1}{2}A_0 + \sum_{p=1}^{N/2} [A_p \cos(2\pi pn/N) + B_p \sin(2\pi pn/N)] = \frac{1}{2}C_0 + \sum_{p=1}^{N/2} [C_p \cos((2\pi pn/N) - \theta_p)], \end{aligned}$$

1968 donde los términos $A_0/2$ y $C_0/2$ son los valores medios de toda la serie
 1969 $f(t)$. Los coeficientes se calculan de igual forma usando las condiciones
 1970 de ortogonalidad. La única diferencia es que en lugar de tratar con inte-
 1971 grales (serie continua) tratamos con sumatorios (serie discreta)

$$A_p = \frac{2}{N} \sum_{n=1}^N f(t_n) \cos(2\pi pn/N), \quad p = 1, 2, \dots, N/2$$

$$A_0 = \frac{2}{N} \sum_{n=1}^N f(t_n), \quad B_0 = 0$$

$$A_{N/2} = \frac{1}{N} \sum_{n=1}^N f(t_n) \cos(n\pi), \quad B_{N/2} = 0$$

$$B_p = \frac{2}{N} \sum_{n=1}^N f(t_n) \sin(2\pi pn/N), \quad p = 1, 2, \dots, N/2$$

1975 El $N/2$ se debe a que es el armónico con mayor frecuencia que pode-
 1976 mos resolver, es decir, aquel que oscila con frecuencia de Nyquist. Para
 1977 $p > N/2$ las funciones trigonométricas simplemente darán coeficientes
 1978 de Fourier repetidos ya obtenidos en el intervalo $1 \leq p \leq N/2$. Para
 1979 calcular la serie discreta de Fourier, primero debemos calcular los argu-
 1980 mentos de las funciones trigonométricas $2\pi np/N$ para cada entero p y
 1981 n . Segundo, evaluamos las funciones $\cos(2\pi np/N)$ y $\sin(2\pi np/N)$, y
 1982 sumamos para los términos $f(t_n) \cos(2\pi np/N)$ y $f(t_n) \sin(2\pi np/N)$.
 1983 Por último, incrementamos p y repetimos los dos pasos anteriores.

1984 {Ejemplo de Series Temporales Discretas (modificado de Emery and
 1985 Thompson, p387)}

1986 Considera la serie temporal de temperatura promedia mensual por un
 1987 periodo de tres años (ver tabla y Figura).

1988	Temperatura ($^{\circ}$ C)	9.6	9.3	9.8	10.3	10.7	11.3	11.5	12	12	9.8	8.1	7.3
	Año 2	7.6	8.7	10.5	12	14	14.3	15.8	16.2	15.4	12.9	11.9	8.5
	Año 3	9.1	8.9	10	9.9	10.1	11.3	11.5	12	12	14	14.3	14.8

1991 Utilizando las expresiones de arriba podemos calcular las frecuencias f_p ,
 1992 amplitudes A_p , B_p , C_p , las fases θ_p y finalmente la serie de Fourier $f(t)$.
 1993 Los valores para las primeras 8 componentes estan reflejados en la tabla

p	f (cpm)	T (mes)	A_p ($^{\circ}$ C)	B_p ($^{\circ}$ C)	C_p ($^{\circ}$ C)	θ_p ($^{\circ}$)
0	0	-	22.68	0	22.68	0
1	0.0278	36.0	-0.263	-0.61	0.67	-113
2	0.0556	18.0	1.95	0.55	2.03	15.76
3	0.1111	12.0	-1.16	-1.69	2.05	-124.48
4	0.1389	9.0	0.91	-0.25	0.95	-15.33
5	0.1667	7.2	0.59	-0.31	0.67	-27.53
6	0.1944	6	-0.11	-0.28	0.30	-112.69
7	0.2222	5.14	0.39	-0.3	0.49	-36.83
8	0.2500	4.5	0.34	-0.31	0.46	-42.78

1995 Serie temporal de temperatura promedia mensual por tres años de muestreo
 1996 (línea azul) y la reconstrucción con la serie de Fourier de 5 componentes
 1997 (línea roja).
 1998

1999 { Serie de Fourier para variables vectoriales (complejas) }

2000 En este caso la transformada de Fourier se aplica a una cantidad vec-
 2001 torial en lugar de una cantidad escalar como temperatura, salinidad,
 2002 densidad, etc. Supongamos que tenemos las dos componentes de la ve-
 2003 locidad u y v las cuales expandemos en series de Fourier

$$u(t) = \frac{1}{2}A_0 + \sum_{p=1}^{N/2} [A_p \cos(\omega_p t_n) + B_p \sin(\omega_p t_n)]$$

$$v(t) = \frac{1}{2}C_0 + \sum_{p=1}^{N/2} [C_p \cos(\omega_p t_n) + D_p \sin(\omega_p t_n)],$$

2004 lo cual se puede escribir en versión compleja como

$$R(t) = u(t) + iv(t) = \frac{1}{2}A_0 + \sum_{p=1}^{N/2} [A_p \cos(\omega_p t_n) + B_p \sin(\omega_p t_n)] + \\ + i \left(\frac{1}{2}C_0 + \sum_{p=1}^{N/2} [C_p \cos(\omega_p t_n) + D_p \sin(\omega_p t_n)] \right) =$$

2007

$$= \left[\frac{1}{2}A_0 + i\frac{1}{2}C_0 \right] + \sum_{p=1}^{N/2} [(A_p + iC_p)\cos(\omega_p t_n) + (B_p + iD_p)\sin(\omega_p t_n)] ,$$

donde $\frac{1}{2}A_0 + i\frac{1}{2}C_0 = \overline{u(t)} + i\overline{v(t)}$ es la velocidad media, $\omega_p = 2\pi f_p = 2\pi p/N\Delta t$ la frecuencia angular, $t_n = n\Delta t$ es el eje de tiempo, y (A_p, B_p, C_p, D_p) y son las amplitudes y fases de cada componente de Fourier, tanto las reales como las imaginarias. A diferencia de la serie de Fourier real en este caso las componentes van de $p = 1$ hasta $p = N$ y, por lo tanto, estamos cubriendo ambas frecuencias *positivas* y *negativas*.

2015 Si extraemos la velocidad media

$$R'(t) = R(t) - [\overline{u(t)} + i\overline{v(t)}] = \sum_{p=1}^{N/2} [(A_p + iC_p)\cos(\omega_p t_n) + (B_p + iD_p)\sin(\omega_p t_n)] .$$

2016 Ahora vamos a escribir la anomalía de la serie compleja $R'(t)$ en términos de dos componentes rotatorias ortogonales, es decir, una componente que gira en el sentido de las agujas del reloj con amplitud R^- y otra que gira en el sentido opuesto a las agujas del reloj y amplitud R^+

$$\begin{aligned} R'(t) &= \sum_{p=1}^{N/2} [e^{i\omega_p t} + e^{-i\omega_p t}] = \\ &= \sum_{p=1}^{N/2} R_p^+ [\cos(\omega_p t_n) + i\sin(\omega_p t_n)] + \sum_{p=1}^{N/2} R_p^- [\cos(\omega_p t_n) - i\sin(\omega_p t_n)] = \\ &= \sum_{p=1}^{N/2} [(R_p^+ + R_p^-)\cos(\omega_p t_n) + (R_p^+ - R_p^-)i\sin(\omega_p t_n)] \end{aligned}$$

2022 Note que $e^{i\omega_p t} = \cos(\omega_p t_n) + i\sin(\omega_p t_n)$ rota en el sentido contrario a las agujas del reloj y $e^{-i\omega_p t} = \cos(\omega_p t_n) - i\sin(\omega_p t_n)$ rota en el sentido de las agujas del reloj. Si comparamos las dos expresiones obtenemos las siguientes identidades

$$A_p + iC_p = R_p^+ + R_p^-$$

$$B_p + iD_p = (R_p^+ - R_p^-)i$$

2027 y de ahí obtenemos que

$$R_p^+ = \frac{1}{2} [A_p + D_p + i(C_p - B_p)]$$

$$R_p^- = \frac{1}{2} [A_p - D_p + i(C_p + B_p)] ,$$

2029 y las magnitudes de las componentes rotatorias es

$$2030 \quad |R_p^+| = \frac{1}{2} [(A_p + D_p)^2 + (C_p - B_p)^2]^{1/2}$$

$$2031 \quad |R_p^-| = \frac{1}{2} [(A_p - D_p)^2 + (C_p + B_p)^2]^{1/2},$$

2032 y las fases de las componentes rotatorias son

$$2033 \quad \epsilon_p^+ = \operatorname{actan} \left(\frac{C_p - B_p}{A_p + D_p} \right),$$

$$2034 \quad \epsilon_p^- = \operatorname{actan} \left(\frac{C_p + B_p}{A_p - D_p} \right).$$

2035 La rotación de las componentes *clockwise* y *anticlockwise* dibujan una
 2036 elipse en el plano u vs v . Puesto que ambas componentes rotan en sen-
 2037 tido contrario pero con la misma frecuencia, habrán momentos que
 2038 ambás apuntaran en la misma dirección (aditivas), otras ocasiones en
 2039 dirección opuesta (cancelativas). Esos tiempos de adición y cancelación
 2040 definen el eje mayor de la elipse $L_E = R_p^+ + R_p^-$ y el eje menor de la
 elipse $L_e = R_p^+ - R_p^-$. La orientación (inclinación) y la fase de estas
 elipses a $t = 0$ es

$$2041 \quad \theta_e = \frac{1}{2}(\epsilon_p^+ + \epsilon_p^-),$$

$$2042 \quad \phi_e = \frac{1}{2}(\epsilon_p^+ - \epsilon_p^-).$$

Una propiedad interesante es el coeficiente rotatorio

$$2043 \quad r(\omega) = \frac{R_p^+ - R_p^-}{R_p^+ + R_p^-},$$

2044 que toma valores entre 0 y 1. Para $r = -1$ tenemos movimiento en
 2045 el sentido de las agujas del reloj, para $r = 0$ tenemos un flujo unidirec-
 2046 cional, y para $r = +1$ tenemos movimiento en el sentido contrario de las
 agujas del reloj.

2047 { Transformada Rápida de Fourier y espectros de potencia }

2048 La FFT (por sus siglas en inglés) es un algoritmo para calcular la se-
 2049 serie de Fourier discreta de forma mas eficiente computacionalmente
 2050 hablando. En este caso la FFT se debería aplicar a series temporales
 2051 con longitudes múltiples de 2. En caso contrario, es útil llenar de
 2052 ceros nuestra serie para obtener longitudes múltiplos de 2. A eso se le
 2053 llama ‘padding’. Básicamente, el algoritmo obtiene los coeficientes de la
 2054 serie discreta de Fourier

$$2055 \quad f(t) = \sum_{p=-\infty}^{\infty} C_p^* e^{i\omega_p t_n} \quad ; \quad \omega_p = 2\pi p f_0 = 2\pi p / T,$$

2055

$$F(p) = C_p^* = \frac{1}{2}(A_p - iB_p) = \frac{1}{N} \sum_{n=0}^{N-1} f(t_n) e^{-i\omega_p t_n} = \frac{1}{N} \sum_{n=0}^{N-1} f(t_n) [\cos(\omega_p t_n) - i \sin(\omega_p t_n)].$$

2056

La parte real de la FFT me da las amplitudes A_p y la parte imaginaria
2057 me da las amplitudes $-B_p$

2058

$$\text{Re}[F(p)] = A_p = \frac{2}{N} \sum_{n=0}^{N-1} f(t_n) \cos(2\pi p n / N), \quad p = 0, 1, \dots, N/2$$

$$\text{Im}[F(p)] = -B_p = -\frac{2}{N} \sum_{n=0}^{N-1} f(t_n) \sin(2\pi p n / N), \quad p = 0, 1, \dots, N/2$$

2059

En general, debemos de normalizar las amplitudes A_p y B_p por la longitud del registro N . Así que en Matlab la amplitud de la FFT es
2060

$$\text{abs}(\text{fft}(f(t))) / N,$$

2061

y la potencia de la FFT es

$$\text{abs}(\text{fft}(f(t)))^2 / N^2.$$

2062

La FFT ha descompuesto una señal de N elementos, $f(t)$, en un conjunto de $N/2 + 1$ ondas cosinusoidales y $N/2 + 1$ ondas sinusoidales, con las frecuencias definidas por el índice $p = 0, 1, \dots, N/2$, i.e. $\omega_p = 2\pi p / N$. Las amplitudes de los cosenos están contenidas en $\text{Re}[F(p)]$ y las amplitudes de los senos en $\text{Im}[F(p)]$. Note que las frecuencias son siempre *positivas*, es decir, los índices k siempre van de cero a $N/2$. Las frecuencias entre $N/2$ y $N - 1$ son *negativas*. Recuerda que el espectro frecuencial de una señal discreta es periódico, y entonces las frecuencias son negativas entre $N/2$ y $N - 1$ al igual que en el intervalo $-N/2$ y -1 . Los puntos 0 y $N/2$ separan las frecuencias negativas de las positivas. Es por ello que, generalmente, solamente centramos nuestra atención en la parte positiva del espectro. La magnitud (o norma) de la transformada de Fourier discreta es
2063
2064
2065
2066
2067
2068
2069
2070
2071
2072
2073
2074

$$\text{Magnitud} = |F(p)| = \sqrt{\text{Re}[F(p)]^2 + \text{Im}[F(p)]^2},$$

2075

y la fase es

$$\text{Phase} = \tan^{-1} \left(\frac{\text{Im}[F(p)]}{\text{Re}[F(p)]} \right).$$

2076

La FFT organiza los coeficientes de Fourier (imaginarios y reales) en frecuencias *negativas* y *positivas* y reparte la varianza de la señal equitativamente entre ellas. En $p = 0$ tenemos la media de la serie temporal, aunque debido a que hemos eliminado la media y la tendencia de la serie temporal no debemos de preocuparnos por ella. Entre
2077
2078
2079
2080

2081 $p = 1, \dots, N/2$ tenemos los valores de los coeficientes de Fourier reales y
 2082 entre $p = N/2 + 1, \dots, N - 1$ tenemos los complejos conjugados de los
 2083 primeros $N/2$ coeficientes. Si calculamos el valor absoluto de la trans-
 2084 formada de Fourier (en Matlab $\text{abs}(\text{fft}(f(t)))/N$) estamos calculando
 2085 $A_p^2 + B_p^2$ y si solo nos quedamos con los primeros $N/2$ elementos de
 2086 la FFT, debemos de multiplicar por un factor de 2 para conservar la
 2087 energía espectral.

2088 **9.2.1 Estimaciones espectrales o autoespectros**

2089 (1) *Espectro de amplitud*

2090 La gráfica de la magnitud de los coeficientes complejos $|C_p^*|$ de la serie
 2091 de Fourier

$$f(t) = \sum_{p=-\infty}^{\infty} C_p^* e^{i\omega_p t_n}$$

2092 frente a (versus) la frecuencia ω_p se denomina espectro de amplitud de
 2093 la función periódica $f(t)$. En Matlab (para las primeras $N/2$ compo-
 2094 nentes),

$$\text{Amplitud} = 2 * |C_p^*| = \text{abs}(\text{fft}(f(t)))/N.$$

2095 (2) **Espectro de densidad de potencia** (Power Spectral Density,
 2096 PSD)

2097 El espectro de densidad de potencia (PSD, por sus siglas en inglés) es la
 2098 potencia de la FFT por unidad de frecuencia

$$PSD(p) = 2 * |C_p^*|^2 / \Delta f$$

2099 donde $\Delta f = 1/N\Delta t$ es la frecuencia fundamental.

2100 La gráfica de $PSD(p)$ de la frente a (versus) la frecuencia ω_p se denom-
 2101 ina espectro de densidad de potencia de la función periódica $f(t)$. Si
 2102 solo nos quedamos con las $N/2$ primeras componentes en Matlab se
 2103 escribe

$$PSD(p) = 2 * \text{abs}(\text{fft}(f(t)))^2 / N^2 / \Delta f.$$

2104 Esta normalización tiene su fundamento en el cumplimiento del teorema
 2105 de Parseval, de tal forma que la energía total de la señal en el dominio
 2106 temporal $f(t)$ (por unidad de tiempo) sea igual a la energía total de la
 2107 señal en el dominio frecuencial definido por C_p^* :

$$\frac{1}{T} \sum_{n=1}^N |f(t_n)|^2 \Delta t = \frac{1}{N} \sum_{n=1}^N |f(t_n)|^2 = \text{var}(f(t)) = \sum_{p=-\infty}^{\infty} |C_p^*|^2 = \sum_{p=0}^{N/2} PSD(p) * \Delta f.$$

2108 Este teorema de conservación de energía nos informa de que la integral
 2109 bajo la curva espectral $PSD(p)$ debe ser igual a la varianza total de la
 2110 serie temporal.
 2111

Efectos de los extremos en estimaciones espectrales

En general, para calcular un espectro promedio debemos fragmentar nuestra serie temporal en bloques de igual tamaño que contengan las frecuencias de interés, realizar espectros individuales de dichos fragmentos, y promediar todos ellos. Este método se le conoce como Welch. Los fragmentos pueden ser únicos, es decir, sin superposición o bien pueden ser recursivos, es decir, cuando utilizamos superposición de fragmentos. Por ejemplo, una superposición del 50% significa que cada fragmento empieza en la mitad del fragmento anterior. Además de eliminar el ruido, el método de Welch también reduce la transferencia de energía de las frecuencias pico hacia frecuencias colindantes (*leakage'* en inglés). El método de Welch reduce el ruido causado por el uso de datos imperfectos y por el efectoleakage'. Aquí les muestro un ejemplo de como promediar un espectro de densidad espectral con fragmentos de tamaño M :

Matlab

Ejemplo del método de pWelch para calcular espectros de frecuencia promediados o suavizados de series temporales o espaciales, $u(t)$ o $u(x)$, de tamaño N .

```
% Suavizado con pwelch
% (a mano y con subrutina de librería MATLAB)
M=500;
M2=floor(M/2);
nintervals=N/M;
PWuu=zeros(M2+1,1);
s=0;
for k=0:M:N-M s=s+1; uu=[];
% seleccionamos la serie sobre la ventana M
uu=u(k+1:k+M);
% Frecuencia de muestreo
dfM=1./(M*dt);
% PSD
spctuu0=[];
spctuu=abs(fft(uu)).^2/M.^2/dfM;
PSD=[spctuu(1),2*spctuu(2:M2),spctuu(M2+1)];
%
PWuu = PWuu + PSD(:);
PWuu=PWuu/nintervals;
fPWuu=[0:M2]*dfM;
PWuu=PWuu/nintervals;
fPWuu=[0:M2]*dfM;
```

```
% Librería MATLAB
Fs=M*dt;
[PWuuMatlab,FMatlab]=pwelch(u(:,1),M,0,[],Fs,'psd','oneside');
```

Este problema de transferencia de energía o ‘leakage’ es intrínseco al problema de que las series temporales oceanográficas son finitas y, por lo tanto, no son necesariamente periódicas, condición necesaria en el

2130 análisis de Fourier. Veamos esto con un ejemplo de una onda cosinoidal
 2131 periódica y no-periódica.

2132

2133 Podemos observar como en el caso de la serie no-periódica existe una
 2134 transferencia de energía del pico espectral hacia las frecuencias colin-
 2135 dantes de forma que se reduce la amplitud del pico de interés.

2136

Correlación

RECORDATORIO: La función de covarianza cruzada se debe definir en función de un desfase τ como

$$C_{xy}(\tau) = \frac{1}{N-m} \sum_{n=0}^{N-m} x(n\Delta t)y(n\Delta t + \tau),$$

donde $m = 0, 1, \dots, M$ es el número de desfases $\tau_m = m\Delta t$ y $M < N$. Su correspondiente correlación cruzada es

$$\rho_{xy}(\tau) = \frac{C_{xy}}{C_{xx}(0)C_{yy}(0)} = \frac{C_{xy}}{s_x s_y},$$

donde s_x y s_y son las varianzas de las variables x e y , respectivamente.

2137

y s_y son las varianzas de las variables x e y , respectivamente. \end{framed}

2138

Kundu (1976b) define la función de correlación cruzada desfasada entre
 2139 dos series de velocidad en las profundidades 1 y 2 como

$$\rho_\tau = \frac{\overline{u'_1(t)u'_2(t-\tau)}}{\left[\overline{u'_1(t)^2}\overline{u'_2(t)^2}\right]^{1/2}},$$

2140

donde las primas ' indican anomalías. Esta función fue utilizada para
 2141 estudiar la propagación vertical de ondas inercio-gravitatorias y la ve-
 2142 locidad de fase de estas ondas $c = \Delta_{12}/\tau$. Kundu (1976a) introduce el
 2143 coeficiente de correlación complejo

$$\rho = \frac{\overline{w_1^*(t)w_2(t)}}{\left[\overline{w_1^*(t)w_1^*(t)}\overline{w_2^*(t)w_2(t)}\right]^{1/2}},$$

2144

donde $w = u + iv$, los asteriscos * indican complejo conjugados, y los
 2145 subíndices 1 y 2 se refieren a dos estaciones de medida. La cantidad
 2146 ρ es un número complejo cuya magnitud (≤ 1) nos da una medida de
 2147 correlación promedio y cuyo ángulo de fase da el angulo promedio, me-
 2148 dido en el sentido contrario a las agujas del reloj, del segundo vector
 2149 con respecto del primero. Por ejemplo, un ángulo de fase negativo en-
 2150 tre las profundidades 50 y 100 m implica que la señal llega primero a

2151 $z = -100 \text{ m}$ y luego a $z = -50 \text{ m}$, es decir, podría tratarse de una onda
2152 interna cuyas fases se propagan hacia arriba.

2153 9.2.2 *Espectro cruzado*

2154 Con análisis de espectros cruzados pretendemos comprender la relación
2155 entre dos series temporales en función de la frecuencia. Por ejemplo,
2156 observamos en dos localizaciones espectros con picos en las mismas fre-
2157 cuencias y queremos saber si dichos armónicos están relacionados.

2158 Supongamos dos series de Fourier $x(t)$ e $y(t)$

$$\begin{aligned} x(t) &= \bar{x} + \sum_{p=1}^{N/2} A_{xp} \cos(\omega_p t_n) + B_{xp} \sin(\omega_p t_n), \end{aligned}$$

$$\begin{aligned} y(t) &= \bar{y} + \sum_{p=1}^{N/2} A_{yp} \cos(\omega_p t_n) + B_{yp} \sin(\omega_p t_n). \end{aligned}$$

2160 Utilizando las condiciones ortogonalidad entre las funciones sinusoidales
2161 y cosinusoidal, la covarianza entre las variables x e y es

$$\overline{x'y'} = \sum_{p=1}^{N/2} \frac{1}{2} (A_{xp} A_{yp} + B_{xp} B_{yp}) = \sum_{p=1}^{N/2} Co(p),$$

2162 donde $Co(p)$ es el co-espectro de x e y .

2163 Supongamos dos series de Fourier $x(t)$ e $y(t)$ definidas en la forma com-
2164 pleja (el asterisco ha sido eliminado en esta notación)

$$\begin{aligned} x(t) &= \bar{x} + \sum_{p=1}^{N/2} C_{xp} e^{i\omega_p t_n} = \bar{x} + \sum_{p=1}^{N/2} \frac{1}{2} (A_{xp} - iB_{xp}) e^{i\omega_p t_n} = \bar{x} + \sum_{p=1}^{N/2} F_x(p) \\ y(t) &= \bar{y} + \sum_{p=1}^{N/2} C_{yp} e^{i\omega_p t_n} = \bar{y} + \sum_{p=1}^{N/2} \frac{1}{2} (A_{yp} - iB_{yp}) e^{i\omega_p t_n} = \bar{y} + \sum_{p=1}^{N/2} F_y(p). \end{aligned}$$

2166 Si ahora calculamos las varianzas

$$\overline{x'^2} = \sum_{p=-N/2}^{N/2} F_{xx}(p),$$

2167 donde

$$F_{xx}(p) = 2 \frac{1}{2} (A_{xp} - iB_{xp}) e^{i\omega_p t_n} \frac{1}{2} (A_{xp} + iB_{xp}) e^{-i\omega_p t_n} = 2F_x(p)F_x^*(p) = |C_{xp}|^2,$$

2168 y el asterisco indica complejo conjugado. Para la variable y de igual
2169 forma obtenemos:

$$\overline{y'^2} = \sum_{p=-N/2}^{N/2} F_{yy}(p); \quad F_{yy}(p) = 2F_y(p)F_y^*(p) = |C_{yp}|^2$$

2170 De las expresiones anteriores se deduce que covarianza se puede calcular
 2171 en el espacio espectral como

$$\overline{x'y'} = \operatorname{Re} \left[\sum_{p=-N/2}^{N/2} F_{xy}(p) \right],$$

2172 donde

$$F_{xy}(p) = 2 \frac{1}{2} (A_{xp} - iB_{xp}) e^{i\omega_p t_n} \frac{1}{2} (A_{yp} + iB_{yp}) e^{-i\omega_p t_n} = 2F_x(p)F_y^*(p) = |C_{xp}||C_{yp}|e^{i(\theta_{xp}-\theta_{yp})}.$$

2173 El factor $e^{i(\theta_{xp}-\theta_{yp})}$ aparece para considerar que ambas series periódicas
 2174 no están en fase.

2175 (4) Espectro cruzado complejo

2176 Si escribimos $F_{xy}(p)$ en términos de los coeficientes de Fourier reales

$$\begin{aligned} F_x(p)F_y^*(p) &= \frac{1}{2} (A_{xp} - iB_{xp}) e^{i\omega_p t_n} \frac{1}{2} (A_{yp} + iB_{yp}) e^{-i\omega_p t_n} = \\ &= \frac{1}{4} [A_{xk}A_{yk} + B_{xk}B_{yp} + i(A_{xp}B_{yp} - A_{yp}B_{xp})]. \end{aligned}$$

2177 Para el caso de series $x(t)$ e $y(t)$ reales sabemos que las frecuencias
 2179 negativas son los complejos conjugados de las frecuencias positivas y
 2180 entonces

$$A_k = A_{-k} \quad y \quad B_k = B_{-k},$$

2181 y

$$F_x(p)F_y^*(p) = F_x(-p)F_y^*(-p),$$

2182 y como conclusión

$$F_{xy}(p) + F_{xy}(-p) = \frac{1}{2} [A_{xp}A_{yp} + B_{xp}B_{yp} + i(A_{xp}B_{yp} - A_{yp}B_{xp})],$$

2183 que es espectro cruzado de x e y para el armónico p . De esta expresión
 2184 encontramos que

$$F_{xy}(p) + F_{xy}(-p) = 2F_{xy}(p) = Co(p) + iQ(p),$$

2185 donde $Co(p) = \frac{1}{2}(A_{xp}A_{yp} + B_{xp}B_{yp})$ es el co-espectro del armónico p

2186 y $Q(p) = \frac{1}{2}(A_{xp}B_{yp} - A_{yp}B_{xp})$ es el espectro de cuadratura del armónico
 2187 k .

2188 En notación compleja el espectro cruzado

$$F_{xy}(p) = C_{xp}C_{yp}e^{i(\theta_{xp}-\theta_{yp})} = C_{xp}C_{yp} (\cos(\theta_{xp} - \theta_{yp}) + i\sin(\theta_{xp} - \theta_{yp})).$$

2187 $\theta_{xp} = \theta_{yp}$ entonces $F_{xy}(p)$ es real

2189

$$\theta_{xp} \neq \theta_{yp} = \pm \frac{\pi}{2} \text{ entonces } F_{xy}(p) \text{ es complejo}$$

2190

Entonces el co-espectro (la parte real del espectro cruzado) esta en fase con la señal y el espectro de cuadratura esta totalmente desfasado.

2192

(5) Espectro de coherencia

2193

Para una única componente p , el espectro de coherencia al cuadrado entre dos series x e y se define

2195

$$Coh^2(p) = \frac{|F_{xy}(p)|^2}{F_{xx}F_{yy}} = \frac{|C_{xp}C_{yp}|^2}{C_{xp}^2C_{yp}^2},$$

2196

donde $|Coh^2(p)|^{1/2}$ es su magnitud y $\phi_{xy}(p)$ es el ángulo de desfase entre las dos componentes p de x e y .

2197

El espectro de coherencia al cuadrado nos indica el grado de correlación existente entre dos señales. Dos señales estan altamente correlacionadas si la magnitud del espectro de coherencia al cuadrado es $\simeq 1$ y su fase es $\phi_{xy}(p) \simeq 0$.

2201

10 Métodos de filtrado y suavizado

2202

10.1 Convolución y funciones respuesta (ventanas espectrales)

2203

La convolución de dos funciones $f(t)$ y $g(t)$ sobre un registro finito $[0, T]$ se define como

2204

$$[f * g](t) = \frac{1}{T} \int_0^T f(\tau)g(t - \tau)d\tau.$$

O también se puede expresar sobre un registro infinito como

$$[f * g](t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau = \int_{-\infty}^{\infty} g(\tau)f(t - \tau)d\tau.$$

2205

La convolución satisface las siguientes propiedades

•

$$f * g = g * f$$

•

$$f * (g * h) = (f * g) * h$$

•

$$f * (g + h) = (f * g) + (f * h)$$

2207

Ahora retomemos las definiciones de serie de Fourier y la transformada de Fourier:

$$f(t) = F^{-1}[F(\omega)](t) = \sum_{p=-\infty}^{\infty} F(\omega_p) e^{i\omega_p t}; \quad \text{serie de Fourier}$$

y

$$F(\omega_p) = C_p^* = \frac{1}{T} \int_0^T f(t) e^{-i\omega_p t} dt; \quad \text{Transformada de Fourier}$$

También se pueden escribir alternativamente en forma integral (contínua) como:

$$f(t) = \int_{-\infty}^{\infty} F(\omega) e^{i\omega t} d\omega,$$

y

$$F(\omega) = \int_{-\infty}^{\infty} f(t) e^{-i\omega t} dt$$

Vamos ahora a deducir el teorema de la convolución. Para ello vamos a partir de la definición de convolución:

$$\begin{aligned} f * g &= \frac{1}{T} \int_0^T f(\tau) g(t - \tau) d\tau = \frac{1}{T} \int_0^T f(\tau) \sum_{p=-\infty}^{\infty} G(\omega_p) e^{i\omega_p(t-\tau)} d\tau = \\ &= \sum_{p=-\infty}^{\infty} G(\omega_p) \left[\frac{1}{T} \int_0^T f(\tau) e^{-i\omega_p \tau} d\tau \right] e^{i\omega_p t} = \sum_{p=-\infty}^{\infty} G(\omega_p) F(\omega_p) e^{i\omega_p t} = F^{-1}[G(\omega)F(\omega)](t). \end{aligned}$$

Si aplicamos transformada de Fourier a ambos lados del igual obtenemos:

$$F(f * g) = G(\omega_p)F(\omega_p) = F[g(t)]F[f(t)],$$

es decir, la transformada de Fourier de la convolución de f y g es equivalente a multiplicar en el espacio espectral las transformadas de Fourier de las funciones individuales. La correlación cruzada desfasada de $f(t)$ y $g(t)$ en forma integral se puede definir como

$$C_{fg}(\tau) = \frac{1}{T} \int_0^T f(\tau)g(t+\tau)d\tau = F^{-1}[G(\omega)F(-\omega)](t) = F^{-1}[G(\omega)F^*(\omega)](t),$$

es decir, si multiplicamos la transformada de Fourier de una función por el complejo conjugado de la transformada de Fourier de otra función es equivalente a la transformada de Fourier de la correlación cruzada desfasada entre ellas. Este se conoce por el teorema de correlación. Para el caso particular que sea la misma función $g(t)$ la que se correlaciona, entonces:

$$F[C_{gg}(\tau)] = G(\omega)G^*(\omega) = |G(\omega)|^2,$$

es decir, la transformada de Fourier de la autocorrelación es igual al espectro de potencia de la función $g(t)$. Este se denomina el teorema de Weiner-Khinchin.

El concepto de convolución es útil en el filtrado de señales periódicas. En general vamos a convolucionar nuestra señal $f(t)$ con la denominada función respuesta $r(t)$. La función $r(t)$ es típicamente una función pico que cae a cero en ambas direcciones desde el máximo (o pico).

Puesto que la función respuesta es mas ancha que algunas estructuras de pequeña escala de nuestra señal original, estas serán suavizadas tras realizar la convolución. \\ {\bf NOTA:} Por el teorema de convolución filtrar en el dominio temporal convolucionando es equivalente a multiplicar la transformada de Fourier de la señal con la transformada de Fourier de la función respuesta.

Las ventanas mas comunes para suavizar señales son las de:

(1) ‘Boxcar’

$$r(t) = \begin{cases} 1 & \text{if } 0 \leq t \leq T \\ 0 & \text{if } t > T \end{cases}$$

La transformada de Fourier es la función *sinc*

$$R(\omega) = \text{sinc} = \frac{\sin(\frac{\omega T}{2})}{\frac{\omega T}{2}}.$$

Esta función respuesta tiende a cero cuando $\omega T/2$ se acerca a cero, es decir, para $\omega T = 2n\pi$; para $n = 1, 2, 3, \dots$. Esta no es una ventana o función respuesta recomendable debido a los lóbulos de menor amplitud alrededor del pico. En general respuestas tipo ondas sinusoidales o cosinusoidales amortiguadas a ambos lados del pico no son deseables.

2247 (2) **Hanning**

$$r(t) = \begin{cases} \frac{1}{2}(1 - \cos\frac{2\pi t}{T}) & \text{if } -T/2 \leq t \leq T/2 \\ 0 & \text{if contrario} \end{cases}$$

2248 (3) **Hamming**

$$r(t) = \begin{cases} (0.54 + 0.46\cos(\frac{\pi t}{T})) & \text{if } -T/2 \leq t \leq T/2 \\ 0 & \text{if contrario} \end{cases}$$

2249

2250 Es evidente que este tipo de filtro es un suavizado o filtro pasa bajo.
 2251 Sin embargo, siempre podemos recuperar facilmente la señal de alta fre-
 2252 cuencia (filtro pasa altas) restando a la señal original la serie suavizada
 2253 con convolución.

2254 Imaginemos que tenemos una serie temporal $u(t)$ con un paso temporal
 2255 de $dt = 1$ h. Entonces, para suavizar $u(t)$ de tal forma que se elimi-
 2256 nen las señales con periodos menores de $T = 48$ h, es decir, un filtro
 2257 pasa baja con frecuencia de corte $1/48$ h $^{-1}$ debemos convolucionar $u(t)$
 2258 con una función de respuesta $r(t)$ o ventana. En este ejemplo *Matlab* se
 2259 muestra como programar un suavizado

Matlab:

```
%Crea función respuesta r(t) o ventana "espectral"
T=48; p1=hanning(48);
r1=p1./sum(p1); %Normaliza (0,1)
p2=hamming(48);
r2=p2./sum(p2); %Normaliza (0,1)
%Convolución u(t) y r(t)
%'same' mantiene las dimensiones de la serie filtrada
us1=conv(u,r1,'same');
us2=conv(u,r2,'same');
```

2260 Ya hemos visto que podemos suavizar una señal simplemente con la con-
 2261 volución en el dominio temporal de la señal con una ventana o función
 2262 respuesta (Boxcar, Hanning, Hamming,etc.). Suavizar una señal es com-
 2263 parable a un filtro de pasa baja, es decir, un filtro que solamente deja
 2264 pasar las frecuencias bajas y elimina (pone a cero) las altas frecuencias.
 2265 De forma ideal los filtros en el dominio frecuencial los representamos
 2266 como: \

2267 (1) Pasa baja (filtra las altas frecuencias),

$$|R(\omega)| = \begin{cases} 1 & \text{si } |\omega| \leq \omega_c \\ 0 & \text{si } \omega_c \leq \omega \end{cases}$$

2268 \
 2269 (2) Pasa banda (filtra las frecuencias fuera de la banda)

$$|R(\omega)| = \begin{cases} 1 & \text{si } \omega_{c1} \leq |\omega| \leq \omega_{c2} \\ 0 & \text{si (lo contrario)} \end{cases}$$

2270 \

2271 (3) Pasa alta (filtra las bajas frecuencias)

$$|R(\omega)| = \begin{cases} 0 & \text{si } |\omega| \leq \omega_c \\ 1 & \text{si } \omega_c \leq \omega \end{cases}$$

2272

2273 10.2 Promedio corrido

2274 Veamos primero un ejemplo sencillo de filtrado paso bajo con un prome-
 2275 dio corrido de dos puntos. Este sería el caso de filtrar utilizando la
 2276 función *smooth.m* de Matlab. Para dos puntos sería $>> f_{suavizada} =$
 2277 $smooth(f, 2);$. \ Promedio corrido con dos puntos es simplemente el
 2278 valor promedio

$$y(n) = \frac{s(n) + s(n-1)}{2},$$

2279 donde $s(n)$ es una señal periódica, $s(-1) = s(N)$, $N \geq 2$. La función
 2280 $y(n)$ es una versión suavizada con altas frecuencias eliminadas y bajas
 2281 frecuencias mantenidas. Para ver esto definimos $s(n) = \sin(2\pi fn/N)$,
 2282 y entonces

$$\begin{aligned} y(n) &= \frac{1}{2}s(n) + \frac{1}{2}s(n-1) = \frac{1}{2}\sin(2\pi fn/N) + \frac{1}{2}\sin(2\pi f(n-1)/N) = \\ &= \frac{1}{2}\sin(2\pi fn/N) + \frac{1}{2}[\sin(2\pi fn/N)\cos(2\pi f/N) - \cos(2\pi fn/N)\sin(2\pi f/N)] = \\ &= \frac{1}{2}[1 + \cos(2\pi f/N)]\sin(2\pi fn/N) - \frac{1}{2}\cos(2\pi fn/N)\sin(2\pi f/N) = \\ &= A_1 \sin(2\pi fn/N) - A_2 \cos(2\pi fn/N), \end{aligned}$$

2286 donde

$$A_1 = \frac{1}{2}[1 + \cos(2\pi f/N)]; \quad A_2 = \sin(2\pi f/N).$$

2287 Para bajas frecuencias, es decir, $f \sim 0$ se cumple que $A_1 \sim 1$ y $A_2 \sim 0$ y
 2288 entonces

$$y(n) \sim \sin(2\pi fn/N) = s(n)$$

2289 y las bajas frecuencias son prácticamente mantenidas. Por el contrario
 2290 para altas frecuencias, es decir, $f \sim N/2$, $A_1 \sim 0$, $A_2 \sim 0$, y entonces
 2291 $y(n) \sim 0$ y consecuentemente las altas frecuencias son prácticamente
 2292 eliminadas.

2293 La fórmula general para el promedio corrido es

$$y(n) = \frac{1}{M} \sum_{p=-(M-1)/2}^{(M-1)/2} s(n+p),$$

2294 donde $y()$ es el valor de la serie filtrada y $s()$ es la serie original sin fil-
 2295 trar, M es el número de puntos usados en el promedio. Por ejemplo, en
 2296 un promedio corrido de 5 puntos, el valor en el punto 30 será

$$y(30) = \frac{s(28) + s(29) + s(30) + s(31) + s(32)}{5}.$$

2297 Es evidente que este tipo de filtro es un suavizado o filtro pasa bajo.
 2298 Sin embargo, podemos recuperar facilmente la señal de alta frecuencia
 2299 restando a la señal original la serie filtrada.

Matlab:

```
%Suavizado/filtrado con ventana corrida (moving average)
us3=[];
Ws=48;
for n=Ws:length(u)
us3_Hamming(n)=sum(u(n-Ws+1:n).*hamming(Ws))/Ws;
us3_Hanning(n)=sum(u(n-Ws+1:n).*hanning(Ws))/Ws;
end
```

2300 10.3 Filtros generales coseno

2301 Supongamos un simple filtro simétrico obtenido como la convolución
 2302 entre una función de pesos $r(t)$ y la señal $x(t)$

$$y_n = \sum_{p=-\infty}^{\infty} r_p x_{n-p} \text{ donde } r_p = r_{-p},$$

2303 son pesos elegidos adecuadamente. El efecto de filtrado se observa mejor
 2304 en el dominio frecuencial. Queremos calcular la transformada de Fourier
 2305 de una serie temporal $f(t)$, la cual ha sido desfasada un tiempo $\Delta t = a$:

$$f(t \pm a) = \int_{-\infty}^{\infty} F(\omega) e^{i\omega(t \pm a)} d\omega = \int_{-\infty}^{\infty} [F(\omega) e^{i\omega t}] e^{\pm i\omega a} d\omega$$

2306 De esta expresión deducimos que la transformada de Fourier de una se-
 2307 rie desfasada por un intervalo de tiempo Δt es igual a la transformada
 2308 de Fourier de la serie no desfasada multiplicada por un factor

$$e^{\pm i\omega \Delta t}.$$

2309 Usando este resultado, la transformada de Fourier de y_n se puede es-
 2310 cribir como

$$Y(\omega) = F[y_n] = \sum_{p=-\infty}^{\infty} r_p e^{-i\omega_p \Delta t} X(\omega),$$

2311 donde $X(\omega)$ y $Y(\omega)$ son la transformada de Fourier de $y(t)$ y $x(t)$, y la
 2312 función respuesta en el dominio frecuencial es

$$R(\omega) = \frac{Y(\omega)}{X(\omega)} = \sum_{p=-\infty}^{\infty} r_p e^{-i\omega_p \Delta t}.$$

2313 Puesto que $r_p = r_{-p}$ y

$$\cos(x) = \frac{e^{ix} + e^{-ix}}{2},$$

2314 podemos escribir la función respuesta del filtrado deseado como

$$\begin{aligned} R(\omega) &= \sum_{p=-\infty}^{\infty} r_p e^{-i\omega_p \Delta t} = r_0 + \sum_{p=1}^{\infty} r_p e^{i\omega_p \Delta t} + \sum_{p=1}^{\infty} r_{-p} e^{-i\omega_p \Delta t} = r_0 + \sum_{p=1}^{\infty} r_p [e^{i\omega_p \Delta t} + e^{-i\omega_p \Delta t}] = \\ &= r_0 + 2 \sum_{p=1}^{\infty} r_p \left[\frac{e^{i\omega_p \Delta t} + e^{-i\omega_p \Delta t}}{2} \right] = r_0 + 2 \sum_{p=1}^{\infty} r_p \cos(\omega_p \Delta t) \end{aligned}$$

2315 En general los pesos r_p se van a calcular utilizando la siguiente expresión:
2316

$$r_p = \frac{1}{\omega_N} \int_0^{\omega_N} R(\omega_p) \cos(\omega_p \Delta t) d\omega$$

2318 Por ejemplo para un filtro pasa bajo $R(\omega) = 1$ para $0 < |\omega_p| \leq \omega_c$ y la
2319 integral para calcular los pesos queda

$$\begin{aligned} r_p &= \frac{1}{\omega_N} \int_0^{\omega_c} R(\omega_p) \cos(\omega_p \Delta t) d\omega = \frac{\omega_c}{\omega_N} \frac{\sin(\omega_c p \Delta t)}{\omega_c p \Delta t} = \frac{1}{\omega_N} \frac{\sin(\pi p \omega_c / \omega_N)}{\pi p / \omega_N} = \\ &= \frac{\sin(\pi p \omega_c / \omega_N)}{\pi p} \quad p = 1, 2, \dots, N \end{aligned}$$

2320 Para $p = 0$ entonces
2321

$$r_0 = \frac{1}{\omega_N} \int_0^{\omega_c} R(\omega_p) \cos(\omega_p \Delta t) d\omega = \frac{1}{\omega_N} \int_0^{\omega_c} d\omega = \frac{\omega_c}{\omega_N}.$$

2322 Y la función respuesta es

$$R(\omega) = \frac{\omega_c}{\omega_N} + 2 \sum_{p=1}^{\infty} \frac{\sin(\pi p \omega_c / \omega_N)}{\pi p} \cos(\pi p \omega / \omega_N)$$

2323 Veamos que forma tiene este filtro en el dominio frecuencial, asumiendo
2324 un número finito de N coeficientes de Fourier, i.e., $p = 1, 2, \dots, N$, fre-
2325 cuencia de Nyquist $f_N = 1$ y frecuencia de corte $f_c = 1$:

2326

2327 En la figura observamos oscilaciones con longitud de onda

$$\lambda = \frac{4f_N}{2N+1},$$

2328 Esta longitud de onda coincide con el ancho de banda de transición del
2329 filtro, es decir, del pico hasta la base indicado en la figura por las líneas
2330 rojas. Para filtrar únicamente debemos:

- 2331 (i) multiplicar la respuesta espectral $R(f)$ por la transformada de
 2332 Fourier de la señal y regresar con la transformada inversa

$$x(t)[\text{filtrado}] = F^{-1}[R(f)X(f)],$$

- 2333 (ii) convolucionar la respuesta en el dominio temporal $r(t)$ por la serie
 2334 temporal.

$$x(t)[\text{filtrado}] = [r(t) * x](t).$$

2335 Si queremos un filtro pasa alta, usamos r_p (pasa alto) = $1 - r_p$. Y la fun-
 2336 ción respuesta sería

$$R(\omega)[\text{pasa alto}] = 1 - R(\omega) = 1 - \frac{\omega_c}{\omega_N} - 2 \sum_{p=1}^{\infty} \frac{\sin(\pi p \omega_c / \omega_N)}{\pi p} \cos(\pi p \omega / \omega_N)$$

2337 Veamos ahora de nuevo el promedio corrido pero esta vez usando el
 2338 método de Fourier. De nuevo decir que el promedio corrido reemplaza
 2339 el valor central de la ventana por el promedio de los valores que rodean
 2340 a ese punto. Para este ejemplo los pesos son siempre iguales $r_p = 1/T$
 2341 para el intervalo $-N < p < N$, donde $T = 1/(2N + 1)$ es el tamaño de
 2342 la ventana ‘boxcar’. De esta forma

$$T = 2N + 1 = 3 \quad R(\omega) = \frac{1}{3} + \frac{2}{3} \cos(\omega \Delta t) \quad 0 < \omega < \pi / \Delta t$$

$$T = 2N + 1 = 5 \quad R(\omega) = \frac{1}{5} + \frac{2}{5} \cos(\omega \Delta t) + \frac{2}{5} \cos(2\omega \Delta t) \quad 0 < \omega < \pi / \Delta t$$

$$T = 2N + 1 = 7 \quad R(\omega) = \frac{1}{7} + \frac{2}{7} \cos(\omega \Delta t) + \frac{2}{7} \cos(2\omega \Delta t) + \frac{2}{7} \cos(3\omega \Delta t) \quad 0 < \omega < \pi / \Delta t$$

2343 Como volvemos a observar, las transformadas de Fourier de funciones
 2344 de peso cuadradas (‘boxcar’) no son adecuadas debido a las oscilaciones
 2345 o lóbulos menores.

2347 10.4 Filtro Lanczos pasabajo

2348 Sea $R(f)$ la función respuesta de un filtro pasa bajo, en donde f corre-
 2349 sponde a la frecuencia en ciclos por unidad de tiempo, f_N es la frecuen-
 2350 cia de Nyquist, y fc es la frecuencia de corte.

2351 Lanzcos se dio cuenta que las oscilaciones de los filtros cosinusoidales
 2352 con longitud de onda $\lambda(f) = 4f_N/2N + 1$ podían ser reducidas si se
 2353 realiza un suavizado de la función respuesta $H(f)$. Para ello realizó un

2355 promedio corrido de tamaño igual a la longitud de onda de las oscila-
2356 ciones, es decir, λ . Esto se puede escribir como

$$\widetilde{R}(f) = \frac{1}{\lambda(f)} \int_{f-\lambda/2}^{f+\lambda/2} R(f) df,$$

2357 donde ya hemos visto que

$$R(f) = \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \cos(\pi p f / f_N).$$

2358 Un filtro de media corrida no tiene efecto en el promedio, entonces

$$\begin{aligned} \widetilde{R}(f) &= \frac{f_c}{f_N} + \frac{1}{\lambda} \int_{f-\lambda/2}^{f+\lambda/2} 2 \sum_{p=1}^N r_p \cos(\pi p f / f_N) df = \\ &= \frac{f_c}{f_N} + \frac{2}{\lambda} \sum_{p=1}^N r_p \left[\frac{1}{\pi p / f_N} \sin \left(\frac{\pi p f}{f_N} \right) \right]_{f-\lambda/2}^{f+\lambda/2} = \\ &= \frac{f_c}{f_N} + \frac{2}{\lambda} \sum_{p=1}^N r_p \frac{f_N}{\pi p} \left[\sin \left(\frac{\pi p (f + \lambda/2)}{f_N} \right) - \sin \left(\frac{\pi p (f - \lambda/2)}{f_N} \right) \right] = \\ &= \frac{f_c}{f_N} + \frac{2}{\lambda} \sum_{p=1}^N r_p \frac{f_N}{\pi p} \left[2 \cos \left(\frac{\pi p f}{f_N} \right) \sin \left(\frac{\lambda \pi p}{2 f_N} \right) \right] = \frac{f_c}{f_N} + \frac{2}{\lambda} \sum_{p=1}^N r_p \frac{f_N}{\pi p} \left[2 \cos \left(\frac{\pi p f}{f_N} \right) \sin \left(\frac{2 \pi p}{2N+1} \right) \right] = \\ &= \frac{f_c}{f_N} + \frac{2(2N+1)}{4f_N} \sum_{p=1}^N r_p \frac{f_N}{\pi p} \left[2 \cos \left(\frac{\pi p f}{f_N} \right) \sin \left(\frac{2 \pi p}{2N+1} \right) \right] = \\ &= \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \frac{2N+1}{2\pi p} \left[\cos \left(\frac{\pi p f}{f_N} \right) \sin \left(\frac{2 \pi p}{2N+1} \right) \right] = \\ &= \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \frac{1}{\frac{2\pi p}{2N+1}} \left[\cos \left(\frac{\pi p f}{f_N} \right) \sin \left(\frac{2 \pi p}{2N+1} \right) \right] = \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \sigma_p \cos \left(\frac{\pi p f}{f_N} \right), \end{aligned}$$

2359 donde

$$\sigma_p = \frac{\sin \left(\frac{2 \pi p}{2N+1} \right)}{\frac{2 \pi p}{2N+1}} = \text{sinc} \left(\frac{2 \pi p}{2N+1} \right),$$

2360 es una función *sinc* como la respuesta espectral de un filtro rectangular
2361 o *boxcar*. A este factor de suavizado se le suele llamar peso sigma.

2362

2363 En la figura se observa que la frecuencia de corte es la la frecuencia que
 2364 corta el 50% de la magnitud de la respuesta. La frecuencia efectiva es
 2365 $f = f_c + \lambda/2$.

MATLAB:

Programa para crear el filtro de Lanczos (Autor: Dr. Modesto Ortiz)

```
N=10; %tamano filtro
p=1:N; %indices de tiempo
fc=0.5; %frecuencia de corte a 0.5
fn=1.0; %frecuencia de Nyquist
f=-fn:0.01:fn; %generamos vector de frecuencias (positivas y negativas)
k=length(f); %dimension vector frecuencias
%funcion pesos o respuesta en el dominio temporal
rp=sin(pi*p*fc/fn)./(pi*p);
%calculamos el factor sigma de suavizado (factores lanczos)
sigma=sin(2*pi*p/(2*N+1))./(2*pi*p/(2*N+1));
%Calculamos la funcion respuesta de un filtro general en el %dominio espectral
R=[];
for m=1:k; %recorremos todas las frecuencias
R(m) = fc/fn +
2*sum(rp.*sigma.*cos(p*pi*f(m)/fn));
end
lambda=4*fn/(2*N+1);
y0=[-0.2:0.1:1.2];x0=0.4*ones(1,length([-0.2:0.1:1.2]));
y1=[-0.2:0.1:1.2];x1=0.4+lambda*ones(1,length([-0.2:0.1:1.2]));
%Graficamos
f1=figure;
plot(f,R,'b');
hold on;
plot(x0,y0,'r-');
hold on;
plot(x1,y1,'r-');
grid on;
xlabel('f(ciclos/tiempo)', 'fontsize', 18);
ylabel('R(f)', 'fontsize', 18);
set(gca, 'fontsize', 18);
axis([-1 1 -0.2 1.2]);
```

2366

10.5 Filtro Lanczos pasabanda

2367 En el dominio de las frecuencias, el filtro de pasa-banda se obtiene con-
 2368 volucionando el filtro pasa-bajas con la transformada de Fourier de la
 2369 función coseno:

$$\tilde{R}_b(f) = \tilde{R}(f) * [\delta(f - f_o) + \delta(f + f_0)] ,$$

2370 donde * significa convolución,

$$F[\cos(2\pi f_0 x)](f) = \int_{-\infty}^{\infty} e^{-2\pi i f x} \cos(2\pi f_0 x) dx = \int_{-\infty}^{\infty} e^{-2\pi i f x} \left(\frac{e^{2\pi i f_0 x} + e^{-2\pi i f_0 x}}{2} \right) dx =$$

2371

$$= \frac{1}{2} \int_{-\infty}^{\infty} [e^{-2\pi i (f-f_0)x} + e^{-2\pi i (f+f_0)x}] dx$$

2372

$$= \frac{1}{2} [\delta(f - f_0) + \delta(f + f_0)] ,$$

2373 y la delta de dirac se define como

$$\delta(x) = F[1](f \pm f_0) = \int_{-\infty}^{\infty} e^{-2\pi i (f \pm f_0)x} dx$$

2374 Vemos que la transformada de Fourier del coseno se ha multiplicado
 2375 por un factor de 2 para que la respuesta del filtro sea unitaria (normal-
 2376 ización). El resultado de la convolución es

$$\widetilde{R}_b(f) = \widetilde{R}(f) * [\delta(f - f_o) + \delta(f + f_0)] = \widetilde{R}(f - f_0) + \widetilde{R}(f + f_0) =$$

$$= \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \sigma_p \cos \left(\frac{\pi p (f - f_0)}{f_N} \right) + \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \sigma_p \cos \left(\frac{\pi p (f + f_0)}{f_N} \right) =$$

$$= 2 \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \sigma_p \left[\cos \left(\frac{\pi p f}{f_N} - \frac{\pi p f_0}{f_N} \right) + \cos \left(\frac{\pi p f}{f_N} + \frac{\pi p f_0}{f_N} \right) \right] =$$

$$= 2 \frac{f_c}{f_N} + 2 \sum_{p=1}^N r_p \sigma_p \left[2 \cos \left(\frac{\pi p f}{f_N} \right) \cos \left(\frac{\pi p f_0}{f_N} \right) \right] =$$

$$= 2 \frac{f_c}{f_N} + 4 \sum_{p=1}^N r_p \sigma_p \left[\cos \left(\frac{\pi p f}{f_N} \right) \cos \left(\frac{\pi p f_0}{f_N} \right) \right]$$

2377

MATLAB:

Programa para crear el filtro de Lanczos pasa-banda (Autor: Dr. Modesto Ortiz)

```

N=10; %tamano filtro
p=1:N; %indices de tiempo
fc=0.2; %frecuencia de corte a 0.5
f0=0.2; %frecuencia central del filtro
fn=1.0; %frecuencia de Nyquist
f=-fn:0.01:fn; %generamos vector de frecuencias (positivas y negativas)
k=length(f); %dimension vector frecuencias
%funcion pesos o respuesta en el dominio temporal
rp=sin(pi*p*fc/fn)./(pi*p);
%calculamos el factor sigma de suavizado (factores lanczos)
sigma=sin(2*pi*p/(2*N+1))./(2*pi*p/(2*N+1));
%dominio espectral
R=[];
for m=1:k; R(m) = 2*fc/fn + 4*sum(rp.*sigma.*cos(p*pi*f0/fn).*cos(p*pi*f(m)/fn)); end
lambda=4*fn/(2*N+1);
y0=[-0.2:0.1:1.2];x0=0.4*ones(1,length([-0.2:0.1:1.2]));
y1=[-0.2:0.1:1.2];x1=0.4+lambda*ones(1,length([-0.2:0.1:1.2]));
%Graficamos
f1=figure;
plot(f,R,'b');
hold on;
plot(x0,y0,'r-');
hold on;
plot(x1,y1,'r-');
grid on;
xlabel('f(ciclos/tiempo)', 'fontsize', 18);
ylabel('R(f)', 'fontsize', 18);
set(gca, 'fontsize', 18);
axis([-1 1 -0.2 1.2]);

```

2378 Para el filtro pasa bajas:

$$x(t)[\text{filtrado}] = [r_p \sigma_p * x](t),$$

2379 O

$$x(t)[\text{filtrado}] = F^{-1}[\widetilde{R}(f)X(f)].$$

2380 Para el filtro pasa-banda:

$$x(t)[\text{filtrado}] = [r_p \sigma_p \cos\left(\frac{\pi p f_0}{f_N}\right) * x](t),$$

2381 O

$$x(t)[\text{filtrado}] = F^{-1}[\widetilde{R}_b(f)X(f)].$$

²³⁸² Todo esto se puede programar facilmente en *Matlab* como se muestra en
²³⁸³ el siguiente:

MATLAB:

Programa para calcular los coeficientes de Lanczos pasa-baja y
 pasa-banda (Autor: Dr. Modesto Ortiz)
 function [h,Fh,Rh]=lnz_co(fo,fc,fn,N,df);
 % INPUT:
 % fo = frecuencia central del filtro
 % fc = frecuencia de corte (al 50% de la señal)= medio ancho de
 banda del filtro.
 % fn = frecuencia de Nyquist de los datos que se van a filtrar.
 % df = 1/(N*dt) de los datos que vamos a filtrar
 % N = longitud del filtro
 % El número total de coeficientes es (N+1+N). Con esta definicion
 % aseguramos que le número total de coeficientes sea impar. Esto
 significa
 % que el filtro no cambia la fase de la señal filtrada.

²³⁸⁴ % OUTPUT\

% h = coeficientes del filtro Lanczos en el dominio del tiempo

```
% Fh = vector de frecuencias
% Rh = respuesta en el dominio espectral
%*****
Fh=[]; Rh=[];
lambda = 4*fn/(2*N+1); % ancho de banda de transición
% este valor debe ser menor que 1
lambda/(2*fc)
p= -N : N;
rp=sin(pi*p*fc/fn)./(pi*p); %coeficientes de Fourier del pulso
cuadrado.
%esta operación da una división por cero pero
%no te asustes, se evalua con la función sinc.
%rp=(fc/fn)*sinc(p*fc/fn); % esta es la misma pero no da division
por cero
Sigma=sin(2*pi*p/(2*N+1))./(2*pi*p/(2*N+1)); %factores de
Lanczos, division por cero
%Sigma=sinc(2*p/(2*N+1)); % lo mismo pero sin division por cero
Co=fc/fn;
ind=find(p==0); % se encuentra el índice de la división por cero.
h=rp.*Sigma;
h(ind)=Co; % se suple el valor del coeficiente cero y ya tenemos
%*****
if abs(fo) > 0
banda=cos(2*pi*p*fo/(2*fn));
h=2*h.*banda; % coeficientes del filtro lanczos pasa banda centrado
en fo
end
%*****
```

```
% Por comodidad generamos la respuesta en frecuencia del filtro.
Fh=-fn:df:fn; Fh=Fh';
% for k=1:length(Fh);
% Rh(k)=sum( h.*cos( 2*pi*p*Fh(k)/(2*fn) ) );
% end;
%
xdum=length(Fh); ydum=length(p);
A = zeros(xdum,ydum);
dum=2*pi/(2*fn);
A = cos(dum*Fh*p);
M=length(h);
h=reshape(h,M,1);
Rh = A*h;%multiplicamos la matriz de cosenos por la señal (= a
suma comentada de arriba)
```

2385
2386

Y una vez tenemos los coeficientes solamente tenemos que convolucionar o multiplicar:

MATLAB:

Programa para filtrar con Lanczos en el dominio temporal (Autor: Dr. Modesto Ortiz)

```
% Función lnz_hi.m
%INPUT:
% z = serie de tiempo sin filtrar
% h = coeficientes del filtro
%OUTPUT
% zf = serie de tiempo filtrada
%*****
function [zf] = lnz_hi(z,h);
m = length(z);
zf = conv (z , h);
% se obtiene la serie filtrada convolucionando la serie original con los pesos o coeficientes del filtro.
zf = wkeep(zf,m); % esta rutina trunca los extremos de zf para que el número de datos de la serie filtrada sea igual al número de datos de la serie original. El objetivo de esto es poder graficar en un mismo eje de tiempo ambas series para poder observar la bondad del filtro.
```

2387
2388

Aquí se muestra un ejemplo sintético del uso de las subrutinas presentadas.

MATLAB:

Ejemplo de filtrado con Lanczos (Autor: Dr. Modesto Ortiz)

```
dt=1; k=200; T=k*dt; df=1/(k*dt); t=(0:1:k-1)*dt; %eje de tiempo.
f1=0.005; f2=0.1; f3=0.25; % tres frecuencias
z=cos(2*pi*f1*t)+cos(2*pi*f2*t)+cos(2*pi*f3*t); %serie de tiempo sintética.
%filtramos pasa-banda para quedarnos con la frecuencia f2.
fo=f2; %frecuencia central del filtro
%Medio ancho de banda del filtro
fc=0.03;
fn=0.5; % frecuencia de Nyquist
N = 30; % recordemos que el número total de coeficientes será N+1+N.
[h, Fh, Rh]=lnz_co(fo,fc,fn,N,df);
zf = lnz_hi(z,h); %serie filtrada y lista.
```

2389
2390
2391
2392**11 Temas selectos****11.1 Análisis Armónico**

Se trata de un ajuste por mínimos cuadrados de una serie temporal dominada por armónicos específicos. Por ejemplo, en el caso del océano,

2393 es muy común encontrar en series temporales de temperatura, salinidad,
 2394 velocidad, etc.. señales de las mareas que no son nada mas que corri-
 2395 entes periódicas generadas por fuerzas astronómicas con una frecuencia
 2396 de oscilación determinada (24h, 12h, etc...).

2397 El método consiste en elejir las frecuencias de los armónicos y usar
 2398 cuadrados mínimos para ajustarlos a la serie temporal. Supongamos M
 2399 armónicos a ajustar

$$y(t_n) = \overline{y(t)} + \sum_{q=1}^M C_q \cos(\omega_q t_n - \theta_q) + y_r(t_n),$$

2400 donde $\overline{y(t)}$ es el promedio de la serie, y $y_r(t_n)$ es el residuo de la se-
 2401 rie temporal (donde hay el resto de armónicos presentes en la serie),
 2402 $\omega_q = 2\pi q/N\Delta t$. En términos de las amplitudes A_q y B_q

$$y(t_n) = \overline{f(t)} + \sum_{q=1}^M [A_q \cos(\omega_q t_n) + B_q \sin(\omega_q t_n)] + y_r(t_n),$$

2403 donde

$$C_q = \sqrt{A_q^2 + B_q^2}, \quad q = 1, 2, \dots$$

$$\theta_q = \arctg[B_q/A_q], \quad q = 1, 2, \dots$$

2405 Antes de empezar el análisis debemos de extraer la media, \bar{y} , a la serie
 2406 temporal. El método de mínimos cuadrados consiste en minimizar la
 2407 suma de los errores cuadrados SEC , es decir,

$$2408 SEC = \sum_{n=1}^N y_r^2(t_n) = \sum_{n=1}^N \left(y(t_n) - \left[\overline{y(t)} + \sum_{q=1}^M A_q \cos(\omega_q t_n) + B_q \sin(\omega_q t_n) \right] \right)^2 = \\ = \sum_{n=1}^N \left(y(t_n) - \left[\overline{y(t)} + \sum_{q=1}^M A_q \cos(2\pi q n / N) + B_q \sin(2\pi q n / N) \right] \right)^2$$

2409 Como siempre derivamos respecto los coeficientes e igualamos a cero
 2410 para obtener un sistema de $2M + 1$ ecuaciones

$$\frac{\partial SEC}{\partial A_q} = 0 = 2 \sum_{n=1}^N \left(y(t_n) - \left[\overline{y(t)} + \sum_{q=1}^M A_q \cos(2\pi q n / N) + B_q \sin(2\pi q n / N) \right] - \cos(2\pi q n / N) \right)$$

$$\frac{\partial SEC}{\partial B_q} = 0 = 2 \sum_{n=1}^N \left(y(t_n) - \left[\overline{y(t)} + \sum_{q=1}^M A_q \cos(2\pi q n / N) + B_q \sin(2\pi q n / N) \right] - \sin(2\pi q n / N) \right)$$

²⁴¹² Soluciones del sistema requiere una equación matricial de la forma
²⁴¹³ $\mathbf{Dz} = \mathbf{y}$, donde

$$\mathbf{D} = \begin{pmatrix} N & c_1 & c_2 & \dots & c_M & s_1 & s_2 & \dots & s_M \\ c_1 & cc_{11} & cc_{12} & \dots & cc_{1M} & cs_{11} & cs_{12} & \dots & cs_{1M} \\ c_2 & cc_{21} & cc_{22} & \dots & cc_{2M} & cs_{21} & cs_{22} & \dots & cs_{2M} \\ \dots & \dots \\ \dots & \dots \\ c_M & cc_{M1} & cc_{M2} & \dots & cc_{MM} & cs_{M1} & cs_{M2} & \dots & cs_{MM} \\ s_1 & sc_{11} & sc_{12} & \dots & sc_{1M} & ss_{11} & ss_{12} & \dots & ss_{1M} \\ s_2 & sc_{21} & sc_{22} & \dots & sc_{2M} & ss_{21} & ss_{22} & \dots & ss_{2M} \\ \dots & \dots \\ \dots & \dots \\ s_M & sc_{M1} & sc_{M2} & \dots & sc_{MM} & ss_{M1} & ss_{M2} & \dots & ss_{MM} \end{pmatrix}$$

²⁴¹⁴ y

$$\mathbf{y} = \begin{pmatrix} yc_0 \\ yc_1 \\ yc_2 \\ \dots \\ \dots \\ yc_M \\ ys_1 \\ ys_2 \\ \dots \\ \dots \\ ys_M \end{pmatrix} \quad \mathbf{z} = \begin{pmatrix} A_0 \\ A_1 \\ A_2 \\ \dots \\ \dots \\ A_M \\ B_1 \\ B_2 \\ \dots \\ \dots \\ B_M \end{pmatrix}$$

²⁴¹⁵ Los coeficientes de las matrices son:

$$yc_i = \sum_{n=1}^N y(t_n) \cos(\omega_i t_n) , \quad ys_i = \sum_{n=1}^N y(t_n) \sin(\omega_i t_n)$$

$$\text{c}_i = \sum_{n=1}^N \cos(\omega_i t_n) , \quad s_i = \sum_{n=1}^N \sin(\omega_i t_n)$$

$$cc_{ij} = cc_{ji} = \sum_{n=1}^N [\cos(\omega_i t_n) \cos(\omega_j t_n)]$$

$$ss_{ij} = ss_{ji} = \sum_{n=1}^N [\sin(\omega_i t_n) \sin(\omega_j t_n)]$$

$$cs_{ij} = sc_{ji} = \sum_{n=1}^N [\cos(\omega_i t_n) \sin(\omega_j t_n)] ,$$

²⁴²⁰ donde $t_n = n\Delta$, $\omega_i = 2\pi f_i$ es la frecuencia angular de las componentes
²⁴²¹ de interés i , y $\phi_i(n) = \omega_i t_n$ es el argumento de las funciones de Fourier.

²⁴²² {Ejemplo de Ajuste de armónicos (Emery and Thompson, p395)}

2423 Asumamos la siguiente serie temporal de temperatura promedia men-
 2424 sual. \

T (°C)	7.6	7.4	8.2	9.2	10.2	11.5	12.4	13.4	13.7	11.8	10.1	9
Año 2	8.9	9.5	10.6	11.4	12.9	12.7	13.9	14.2	13.5	11.4	10.9	8.1

2426 \\ \\

2427 Deseamos encontrar las componentes mareales dominantes en la se-
 2428 rie temporal de temperatura. A simple vista podemos ver que ex-
 2429iste una frecuencia dominante semianual. Por tanto, vamos buscar
 2430 las amplitudes y frecuencias de interés, es decir, de las componentes
 2431 anual y semianual que tienen unas frecuencias de $f_1 = 1/12$ meses
 2432 ($= 0.0833$ cpm) y $f_2 = 1/24$ meses ($= 0.1667$ cpm). Los argumentos de
 2433 las funciones de Fourier son $\phi_1(n) = \omega_1 t_n = 2\pi(1/12) * n * \Delta t = (\pi/6) *$
 2434 $n * 1 = n\pi/6$ y $\phi_2(n) = \omega_2 t_n = 2\pi(1/6) * n * \Delta t = (\pi/3) * n * 1 = n\pi/3$
 2435 Para este problema las matrices son \

$$\begin{aligned}
 \mathbf{D} &= \begin{pmatrix} N & c_1 & c_2 & s_1 & s_2 \\ c_1 & cc_{11} & cc_{12} & cs_{11} & cs_{12} \\ c_2 & cc_{21} & cc_{22} & cs_{21} & cs_{22} \\ s_1 & sc_{11} & sc_{12} & ss_{11} & ss_{12} \\ s_2 & sc_{21} & sc_{22} & ss_{21} & ss_{22} \end{pmatrix} = \\
 &= \begin{pmatrix} N & c_1 & c_2 & s_1 & s_2 \\ c_1 & \sum_{n=1}^N [\cos(\phi_1(n))\cos(\phi_1(n))] & cc_{12} & cs_{11} & cs_{12} \\ c_2 & cc_{21} & \sum_{n=1}^N [\cos(\phi_1(n))\cos(\phi_2(n))] & cs_{21} & cs_{22} \\ s_1 & sc_{11} & sc_{12} & \sum_{n=1}^N [\sin(\phi_1(n))\sin(\phi_1(n))] & ss_{12} \\ s_2 & sc_{21} & sc_{22} & ss_{21} & \sum_{n=1}^N [\sin(\phi_2(n))\sin(\phi_2(n))] \end{pmatrix} = \\
 &= \begin{pmatrix} 24 & 0 & 0 & 0 & 0 \\ 0 & 12 & 0 & 0 & 0 \\ 0 & 0 & 12 & 0 & 0 \\ 0 & 0 & 0 & 12 & 0 \\ 0 & 0 & 0 & 0 & 12 \end{pmatrix}
 \end{aligned}$$

2438 La matriz

$$\mathbf{y} = \begin{pmatrix} \sum_{n=1}^N y(t_n)\cos(\omega_0 t_n) \\ \sum_{n=1}^N y(t_n)\cos(\omega_1 t_n) \\ \sum_{n=1}^N y(t_n)\cos(\omega_2 t_n) \\ \sum_{n=1}^N y(t_n)\sin(\omega_1 t_n) \\ \sum_{n=1}^N y(t_n)\sin(\omega_2 t_n) \end{pmatrix} = \begin{pmatrix} 262.5 \\ -21.45 \\ -5.4 \\ -23.76 \\ -0.51 \end{pmatrix} {}^\circ C$$

Finalmente encontramos las amplitudes de los armónicos resolviendo el sistema

$$\mathbf{z} = (\mathbf{D}^T \mathbf{D})^{-1} \mathbf{D}^T \mathbf{y} = \mathbf{D}^{-1} \mathbf{y} = \begin{pmatrix} 10.93 \\ -1.78 \\ -0.45 \\ -1.98 \\ -0.04 \end{pmatrix}$$

El coeficiente de correlación entre la señal original y la serie de Fourier con 2 armónicos es $r^2 = 0.92$, es decir, solamente con 2 armónicos podemos explicar el 92% de la varianza total.

11.2 Demodulación compleja

Este método es utilizado para conocer el comportamiento de una componente o armónico con frecuencia particular ω , tal como la marea diurna, o semidiurna, o las ondas inerciales. Aquí vamos a mostrar la forma clásica de demodular que consiste en ajustar por fragmentos de la serie un armónico teórico utilizando mínimos cuadrados. Cada fragmento de la serie debe, como mínimo, contener un ciclo del armónico a demodular. Para cada segmento, la anomalía de la componente de velocidad a la frecuencia de interés ω es

$$\mathbf{u} - \bar{\mathbf{u}} = [u(t) - \overline{u(t)} + iv(t) - \overline{v(t)}] = R^+ e^{i(\omega t + \epsilon^+)} + R^- e^{-i(\omega t + \epsilon^-)},$$

donde $\overline{u(t)}$, $\overline{v(t)}$ son las componentes de la velocidad promedio, R^+ , R^- y ϵ^+ ϵ^- son las amplitudes y fases de las componentes rotatorias que giran en el sentido de las agujas del reloj (+) y en el sentido contrario (-). La serie temporal esta definida para cada t_k ($k = 1, 2, \dots, N$) y las soluciones son encontradas resolviendo el sistema de ecuaciones

$$\mathbf{z} = \mathbf{D}^{-1} \mathbf{y},$$

donde

$$\mathbf{y} = \begin{pmatrix} u(t_1) \\ u(t_2) \\ \dots \\ u(t_n) \\ v(t_1) \\ v(t_2) \\ \dots \\ v(t_n) \end{pmatrix}; \quad \mathbf{z} = \begin{pmatrix} R^+ \cos(\epsilon^+) \\ R^+ \sin(\epsilon^+) \\ R^- \cos(\epsilon^-) \\ R^- \sin(\epsilon^-) \end{pmatrix} = \begin{pmatrix} ACP \\ ASP \\ ACM \\ ASM \end{pmatrix},$$

y la matriz \mathbf{D} es

$$\mathbf{D} = \begin{pmatrix} \cos(\omega t_1) & -\sin(\omega t_1) & \cos(\omega t_1) & \sin(\omega t_1) \\ \cos(\omega t_2) & -\sin(\omega t_2) & \cos(\omega t_2) & \sin(\omega t_2) \\ \dots & & & \\ \cos(\omega t_n) & -\sin(\omega t_n) & \cos(\omega t_n) & \sin(\omega t_n) \\ \sin(\omega t_1) & \cos(\omega t_1) & -\sin(\omega t_1) & \cos(\omega t_1) \\ \sin(\omega t_2) & \cos(\omega t_2) & -\sin(\omega t_2) & \cos(\omega t_2) \\ \dots & & & \\ \sin(\omega t_n) & \cos(\omega t_n) & -\sin(\omega t_n) & \cos(\omega t_n) \end{pmatrix}.$$

Una vez los valores de \mathbf{z} son encontrados a partir de la solución de mínimos cuadrados de arriba, podemos encontrar los parámetros de la elipse como:

$$R^+ = \sqrt{(ASP^2 + ACP^2)}; \quad R^- = \sqrt{(ASM^2 + ACM^2)}$$

$$\epsilon^+ = \tan^{-1} \left(\frac{ASP}{ACP} \right); \quad \epsilon^- = \tan^{-1} \left(\frac{ASM}{ACM} \right)$$

Por ejemplo, si queremos demodular la amplitud y fase de las ondas inerciales observadas en un anclaje situado en latitudes medias, debemos de usar una frecuencia $\omega = 2\Omega \sin \phi$ y ajustar por mínimos cuadrados segmentos de 24 h sin superposición. La serie temporal medida por el anclaje debería de ser horaria para que existan mas datos por segmento que parámetros a ajustar.

Otra forma, tal vez mas sencilla, es la siguiente. Imaginemos que la serie original es $X(t)$ y se asume como una señal periódica con frecuencia igual a la de interés mas otras cosas que llamamos $Z(t)$

$$X(t) = A(t) \cos(\omega t + \varphi(t)) + Z(t) = \frac{1}{2} A(t) [e^{i(\omega t + \varphi(t))} + e^{-i(\omega t + \varphi(t))}] + Z(t),$$

donde la amplitud $A(t)$ y la fase $\varphi(t)$ de la señal periódica se asumen que dependen del tiempo pero que varían “lentamente” en comparación a la frecuencia ω .

Para demodular tenemos que: \

(1) Multiplicar $X(t)$ por $e^{-i\omega t}$:

$$\begin{aligned} Y(t) &= X(t)e^{-i\omega t} = \frac{1}{2} A(t) [e^{i(\omega t + \varphi(t))} + e^{-i(\omega t + \varphi(t))}] e^{-i\omega t} + Z(t)e^{-i\omega t} = \\ &= \underbrace{\frac{1}{2} A(t) e^{i(\omega t + \varphi(t))} e^{-i\omega t}}_{(a)} + \underbrace{\frac{1}{2} A(t) e^{-i(\omega t + \varphi(t))} e^{-i\omega t}}_{(b)} + \underbrace{Z(t)e^{-i\omega t}}_{(c)} = \\ &= \underbrace{\frac{1}{2} A(t) e^{i\varphi(t)}}_{(a)} + \underbrace{\frac{1}{2} A(t) e^{-i(2\omega t + \varphi(t))}}_{(b)} + \underbrace{Z(t)e^{-i\omega t}}_{(c)}. \end{aligned}$$

El término (a) varía lentamente ya que $\varphi(t)$ también lo hace y no tiene energía (potencia espectral) a la frecuencia de demodulación ω o arriba de ella. El término (b) oscila a dos veces la frecuencia de demodulación, i.e., 2ω . El término (c) varía a la frecuencia ω . Debido a que $Z(t)$ no tiene energía a la frecuencia ω , entonces el término (c) no tendrá tampoco energía en la frecuencia cero, i.e., $\omega = 0$. \

(2) Filtro pasa-bajas de la serie $Y(t)$ para eliminar las ondas con frecuencia ω o por encima de ω . Esto eliminará prácticamente los términos (b) y (c), y suavizará (a). El resultado es

$$Y_s(t) = \frac{1}{2} A_s(t) e^{i\varphi_s(t)},$$

donde el subíndice s significa suavizado o filtro pasa-bajas. \

2491 (3) Extraer $A_s(t)$ y $\varphi_s(t)$:

$$\frac{1}{2}A_s(t) = |Y_s(t)| = 2(Re[Y_s]^2 + Im[Y_s]^2)^{1/2}$$

$$e^{i\varphi(t)} = 2 \frac{Y_s(t)}{A_s(t)}; \quad \varphi_s(t) = \tan^{-1} \left(\frac{Im[Y_s]}{Re[Y_s]} \right)$$

2493 Al suavizar hacemos dos cosas. Primero, eliminamos los términos no
 2494 deseados (a) y (b). El tipo de filtrado o suavizado determina la anchura
 2495 de la banda de frecuencias de las oscilaciones retenidas. Por ejemplo,
 2496 si usamos un triángulo (ventana triangular) de longitud $2T - 1$ donde
 2497 $T = 2\pi/\omega$ es el periodo de demodulación, entonces para la banda para
 2498 la potencia-media (3 dB desde el pico) será $\omega \in [T/(1+0.44295), T/(1 -$
 2499 $0.44295)]$. Potencia media se refiere a la frecuencia a la cual la potencia
 2500 se ha reducido a la mitad de su valor medio de la banda. Segundo, el
 2501 filtrado suaviza las series de amplitud y la fase. \

2502 (4) La elección de la frecuencia de demodulación ω se puede validar
 2503 ajustando localmente una línea a la fase, $\varphi \simeq a + bt$. Típicamente
 2504 esto lo haremos en fragmentos de longiutd T . De esta forma si se-
 2505 leccionamos el origen en el tiempo central de cada fragmento (tal
 2506 que $a \simeq 0$) obtenemos que $\cos(\omega t + \varphi) \simeq \cos(\omega t + bt) = \cos(\hat{\omega}t)$.

2507 La frecuencia ajustada $\hat{\omega} = \omega + a$ es una validación de la elección inicial
 2508 de nuestra frecuencia de demodulación ω .

2510 **12 Acknowledgments**

2511 Ayuda de Muchos

2512 **13 Open research**

2513 Disponible para todos

2514 **References**